

Notas del curso de modelo lineal

Introducción

H Vaquera H
2024

Modelos lineales

Nota

No se requieren conocimientos previos de modelos lineales, el enfoque es de carácter teórico, por lo que cierta familiaridad con La teoría de la distribuciones, inferencia estadística y el álgebra lineal es deseable.

Modelos Lineales

Objetivos Generales

- Comprender la teoría y la estimación de los Modelos lineales y sus extensiones (modelos no lineales, modelos gaussianos generalizados) y deben poder aplicarlos en la práctica en una amplia gama de problemas estadísticos. Los estudiantes deben poder ajustar estos modelos a datos reales, realizar evaluaciones de incertidumbre, derivar intervalos de confianza y predicción, dar una interpretación científica sólida a los resultados (por ejemplo, obtenidos del software estadístico R).
- Formar criterios para el manejo profesional de problemas típicos de modelos lineales.

Tipos de modelos:

Algunas clases bien conocidas de modelos lineales son:

1. Regresión: todas las variables son cuantitativas.
2. Análisis de varianza (ANOVA): todas las variables independientes son cualitativas.
3. Análisis de covarianza (ANCOVA): algunas de las variables independientes son cuantitativas y otras cualitativa

Los modelos lineales en una de las metodologías estadísticas más utilizadas en la modelación y el análisis de datos de todo tipo. En este curso se explican estos fundamentos y se desarrollan sus aplicaciones prácticas con todo detalle.

Relación entre variables

Podemos distinguir las variables **predictoras** y las variables de **respuesta**.

Otros nombres que se ven con frecuencia son:

- Variable predictiva: variable de entrada, variable x , regresor, covariable, variable independiente, exogena, causal
- Variable de respuesta: variable de salida, predicho, variable y , variable dependiente, endogena, efecto

Estaremos interesados en descubrir cómo los cambios en la las variables predictoras afectan los valores de una variable de

Modelos estadísticos:

Un modelo estadístico es un modelo matemático que incluye un **componente estocástico**, de un proceso que genera (real o potencial) datos.

$$\text{variable respuesta} = \text{modelo} + \text{error}$$

donde el componente del modelo contiene de una o más variables predictoras (categóricas y/o continuas) y sus parámetros que juntos representan el efecto de las variables predictoras sobre la media de la variable de respuesta. El componente de error representa el "ruido" en el modelo. Es decir, representa las diferencias entre las respuestas observadas y las respuestas predichas por el componente del modelo.

Modelos estadísticos:

$$respuesta = componente\ determinístico + componente\ estocástico$$

lo que refleja que el valor de una observación dada depende de las influencias medidas (componente determinista o sistemático) como de otras influencias aleatorias no medidas (componente estocástico).

Un parámetro y su(s) variable(s) predictora(s) asociada(s) se denominan **término del modelo**. Se ajusta un modelo estadístico a los datos observados para estimar los parámetros del modelo y probar las hipótesis sobre estos parámetros (coeficientes).

Modelos estadísticos

En particular considere:

$$y = f(X, \beta) + \varepsilon$$

con:

- $X = (x_1, \dots, x_p)^t$ vector de predictores
- $\beta = (\beta_1, \dots, \beta_p)^t$ vector de parametros
- $f(X, \beta)$ componente sistematico
- ε vector aleatorio

El modelo se denomina **lineal** si la función f es lineal en los parámetros y es no lineal si f no es lineal en los parámetros.

Modelo lineal

Si las derivadas parciales de y con respecto a cada uno de los parámetros $(\beta_1, \beta_2, \dots, \beta_p)$ son independientes de los parámetros, entonces el modelo se dice es lineal.

Si alguna de las derivadas parciales de y con respecto a cualquiera de las $(\beta_1, \beta_2, \dots, \beta_p)$ no es independiente de los parámetros, el modelo es llamado no lineal.

Tenga en cuenta que la linealidad o no linealidad del modelo no es descrito por la linealidad o no linealidad de las variables explicatorias en el modelo.

Modelo lineal

La relación lineal del modelo lineal. se describe mediante los términos de los parámetros que no están influenciados por las variables explicativas ($X_1, \dots, X_p$) en el modelo.

Si todas las derivadas parciales de y con respecto a cada uno de los parámetros $\beta_1, \dots, \beta_p$ son independientes de los parámetros, se denomina modelo lineal, si alguna de las derivadas parciales de y con respecto a cualquiera de los $\beta_1, \dots, \beta_p$ no es independiente de los parámetros, el modelo se llama no lineal.

Modelo lineal

Por ejemplo

$$y = \beta_1 X_1^2 + \beta_2 \sqrt{X_2} + \beta_3 \log X_3 + e \quad (1)$$

es un modelo lineal, porque:

$$\begin{aligned} \frac{\partial y}{\partial \beta_1} &= X_1^2 \\ \frac{\partial y}{\partial \beta_2} &= \sqrt{X_2} \\ \frac{\partial y}{\partial \beta_3} &= \log X_3 \end{aligned}$$

son independientes de los parámetros β_i , ($i = 1, 2, 3$).

Modelo no lineal

Por otro lado,

$$y = \beta_1^2 X_1 + \beta_2 X_2 + \beta_3 \log X_3 + e \quad (2)$$

es un modelo no lineal, porque:

$$\frac{\partial y}{\partial \beta_1} = 2\beta_1 X_1$$

$$\frac{\partial y}{\partial \beta_2} = X_2$$

$$\frac{\partial y}{\partial \beta_3} = \log X_3$$

podemos ver $\frac{\partial y}{\partial \beta_1} = 2\beta_1 X_1$ depende de β_1 .

Básicamente, el modelado estadístico lineal esencial consiste en desarrollar enfoques y herramientas para determinar $\beta_1, \dots, \beta_K$ en el modelo lineal:

$$y = \beta_1 X_1 + \dots + \beta_K X_K + e \quad (3)$$

dadas las observaciones sobre y y $X_1, \dots, X_K$.

Modelos Lineales en Investigación

Los modelos lineales se utilizan comúnmente para describir y analizar datos en el ámbito biológico y Ciencias Sociales. El modelo necesita representar la naturaleza del muestreo de los datos. El vector de datos contiene medidas en unidades experimentales o de muestreo. Las observaciones son variables aleatorias. El modelo generalmente consta de factores las cuales son variables, ya sean discretas o continuas, que tienen un efecto sobre los datos observados.

Los diferentes factores del modelo son:

- Factores discretos o variables de clase como sexo, año, rebaño, etc
- Factores continuos o covariables como la edad, peso, tiempos, etc.

Modelo Lineal en forma Matricial

Modelo lineal general de la forma

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

donde:

- y es un vector $N \times 1$ de respuestas observadas,
- X es una matriz diseño de $N \times p$ de respuestas fijas constantes,
- β es un vector $p \times 1$ de parámetros fijos pero desconocidos, y
- ε es un vector de errores $N \times 1$ (no observados) con media cero.

Este modelo se llama modelo lineal. porque la media del vector de respuesta y es lineal en los parámetros desconocidos β .

Experimento con genotipos de Maiz



3 genotipos



Rendimiento

$$\text{Rendimiento} = f(\text{genotipos}) + \text{error}$$

Swanson-Wagner, Jia, DeCook, Borsuk, Nettleton, Schnable (2006)
Proceeding of the National Academy of Science. **103**, 6805-6810.

Modelo Lineal

Ejemplos conocidos

- Modelo de regresión
- Modelo de diseños experimentales
- Modelo de componentes de varianza
- Modelo Mixto
- Modelo análisis de covarianza
- Regresión ponderada
- Ecuaciones simultaneas

Ejemplo

Se sabe que entre mas coches circulan por una carretera, menor es la velocidad del trafico. El estudio de este problema tiene como objetivo la mejora del transporte y la reduccion del tiempo de viaje.


La tabla adjunta proporciona los datos de la densidad (en vehículos por km) y su correspondiente velocidad (en km por hora).

Como la congestión afecta a la velocidad, estamos interesados en determinar el efecto de la densidad en la velocidad.

Dato	Densidad	Velocidad	Dato	Densidad	Velocidad
1	12.7	62.4	13	18.3	51.2
2	17	50.7	14	19.1	50.8
3	66	17.1	15	16.5	54.7
4	50	25.9	16	22.2	46.5
5	87.8	12.4	17	18.6	46.3
6	81.4	13.4	18	66	16.9
7	75.6	13.7	19	60.3	19.8
8	66.2	17.9	20	56	21.2
9	81.1	13.8	21	66.3	18.3
10	62.8	17.9	22	61.7	18
11	77	15.8	23	66.6	16.6
12	89.6	12.6	24	67.8	18.3

Relacion

$$Y_i = \beta_0 + \beta_1 * x_i + \beta_2 * x_i^2 + \varepsilon_i; \quad i = 1, 2, \dots, n$$



Ejemplo

Modelo Matricial

$$\begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_N \end{pmatrix} = \begin{pmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & & \\ 1 & x_N & x_N^2 \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_N \end{pmatrix}$$

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Ejemplo 2: Modelo ANOVA de una vía de clasificación

Tiempo de coagulación de la sangre de 6 ratas sometidas a 3 dietas bajo un diseño completamente al azar

Diet 1	Diet 2	Diet 3
$Y_{11} = 62$ $Y_{12} = 60$	$Y_{21} = 71$	$Y_{31} = 72$ $Y_{32} = 68$ $Y_{33} = 67$

Modelo de efectos anova de una via de clasificacion

$$Y_{i,j} = \mu + \tau_i + \varepsilon_{i,j}$$

$$\begin{aligned} Y_{1,1} &= \mu + \tau_1 + \varepsilon_{1,1} \\ Y_{1,2} &= \mu + \tau_1 + \varepsilon_{1,2} \\ Y_{2,1} &= \mu + \tau_2 + \varepsilon_{2,1} \\ Y_{3,1} &= \mu + \tau_3 + \varepsilon_{3,1} \\ Y_{3,2} &= \mu + \tau_3 + \varepsilon_{3,2} \\ Y_{3,3} &= \mu + \tau_3 + \varepsilon_{3,3} \end{aligned} \quad \begin{bmatrix} Y_{11} \\ Y_{12} \\ Y_{21} \\ Y_{31} \\ Y_{32} \\ Y_{33} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \tau_3 \end{bmatrix} + \begin{bmatrix} \varepsilon_{11} \\ \varepsilon_{12} \\ \varepsilon_{21} \\ \varepsilon_{31} \\ \varepsilon_{32} \\ \varepsilon_{33} \end{bmatrix}$$

Ejemplo en Genetica Animal:

La principal ventaja práctica de un modelo lineal es que puede dar cuenta apropiadamente de todos efectos que influyen en una medición. Esto es particularmente útil cuando los datos están desbalanceados, que es casi siempre el caso en los datos de campo, y a menudo también en los datos experimentales relacionados con animales. El siguiente ejemplo ilustra por qué un enfoque simple no funcionará.

Ejemplo en Genetica Animal:

Datos: Variable respuesta: Peso, Factores de estudio Raza y Régimen.

Vaca	Raza	Régimen de Alimentación	Peso (kg)
1	Angus	intensive	494
2	Angus	intensive	556
3	Angus	extensive	542
4	Hereford	extensive	473
5	Hereford	intensive	632
6	Hereford	extensive	544

Necesitaríamos saber el efecto del régimen de alimentación y corregir para esto. Sin embargo, la diferencia entre alimentación intensiva y extensiva también se ve afectada por la representación desigual de las razas.

Ejemplo en Genetica Animal:

Un modelo lineal explicará exactamente qué efectos son afectando qué observación y los diferentes efectos (como la raza y el régimen de alimentación) son estiman simultáneamente y durante este proceso se corrigen entre sí. El modelo:

$$y = X\beta + \varepsilon$$

. Determine X

El ANOVA de dos vías de clasificación

Un experimento que utiliza cada combinación de niveles de factores como tratamientos se llama experimento factorial.

En un experimento factorial con el factor A en niveles a y el factor B en niveles b , el modelo para el diseño general se puede escribir como

$$Y_{ijk} = \mu + \tau_i + \beta_j + \gamma_{ij} + \epsilon_{ijk}$$

,

$$i = 1, 2, \dots, a; \quad j = 1, 2, \dots, b; \quad k = 1, 2, \dots, r,$$

donde μ es el efecto de la media, τ_i es el efecto del i – *esimo* nivel del factor A , β_j es el efecto debido a j – *esimo* nivel del factor B y γ_{ij} es el efecto de la interacción entre el i – *esimo* nivel de A y el j – *esimo* nivel de B . ϵ_{ijk} es el término de error aleatorio.

El ANOVA de dos vías de clasificación

Vaca	Raza	Regimen	Peso(kg)	μ	τ_1	τ_2	β_1	β_2	γ_{11}	γ_{12}	γ_{21}	γ_{22}
1	Angus	intensive	494	1	1	0	1	0	1	0	0	0
2	Angus	intensive	556	1	1	0	1	0	1	0	0	0
3	Angus	extensive	542	1	1	0	0	1	0	1	0	0
4	Hereford	extensive	473	1	0	1	0	1	0	0	0	1
5	Hereford	intensive	632	1	0	1	1	0	0	0	1	0
6	Hereford	extensive	544	1	0	1	0	1	0	0	0	1

Forma Matricial

$$\begin{pmatrix} y_{11} \\ y_{11} \\ y_{12} \\ y_{22} \\ y_{21} \\ y_{22} \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \beta_1 \\ \beta_2 \\ \gamma_{11} \\ \gamma_{12} \\ \gamma_{21} \\ \gamma_{22} \end{pmatrix} + \begin{pmatrix} \epsilon_{11} \\ \epsilon_{11} \\ \epsilon_{12} \\ \epsilon_{22} \\ \epsilon_{21} \\ \epsilon_{22} \end{pmatrix}$$

$$Y = X\beta + \epsilon$$

Analisis de Covarianza (ANCOVA)

Una forma de ampliar el ANOVA y los modelos de regresión es tener variables predictoras tanto categóricas como continuas. El ANCOVA otro ejemplo de un modelo lineal $y = X\beta + \epsilon$.

Ejemplo Clase: ANCOVA

Considere un estudio de dinero apostado el juegos(gamble) entre adolescentes en Gran Bretaña y su género y estatus socioeconómico.

Una pregunta que podría interesarnos es cómo se relacionan el género y los ingresos con la cantidad de juego que juega una persona. Pero ¿cuál debería ser el efecto del género?

Modelo ANCOVA

$$y_{ij} = \mu + \tau_j + \beta x_{ij} + \epsilon_{ij}$$

- y_{ij} es la respuesta para el i -ésimo sujeto en el j -ésimo nivel de tratamiento
- $\mu \in R$ es una constante común a todos los individuos
- $\tau_j \in R$ es el efecto del tratamiento del j -ésimo nivel de tratamiento
- $x_{ij} \in R$ es la covariable para el i -ésimo sujeto en el j -ésimo nivel de tratamiento
- $\beta \in R$ es la pendiente de regresión correspondiente a la covariable x_{ij}
- ϵ_{ij} son $iid \sim N(0, \sigma^2)$ es un término de error gaussiano

Datos ejemplo ancova

```
##          1    2 3    4    5    6    7    8    9   10   11   12   13   14   15   16   17
## sex      1 1.0 1 1.0  1.0 1.00 1.00 1.00 1.0 1.0 1.0 1.00 1.0 1.0 1.0 1.0 1.0
## income   2 2.5 2 7.0  2.0 3.47 5.50 6.42 2.0 6.0 3.0 4.75 2.2 2.0 3.0 1.5 9.5
## gamble  0 0.0 0 7.3 19.6 0.10 1.45 6.60 1.7 0.1 0.1 5.40 1.2 3.6 2.4 3.4 0.1
##          18 19  20 21  22  23  24    25  26    27 28  29  30 31    32 33 34    35
## sex      1.0  1 0.0  0 0.0 0.0  0  0.0 0.0  0.00  0 0.0 0.0  0  0.0  0  0  0.0
## income 10.0  4 3.5  3 2.5 3.5  10  6.5 1.5  5.44  1 0.6 5.5 12  7.0 15  2  1.0
## gamble  8.4 12 0.0  1 1.2 0.1 156 38.5 2.1 14.50  3 0.6 9.6 88 53.2 90  3 14.0
##          36  37  38 39  40  41  42  43  44  45  46  47
## sex      0.0  0.0  0.0  0  0.0 0.0  0.0  0.0 0.00  0.00  0.0  0.0
## income  4.5  2.5  8.0 10  1.6 2.0 15.0  3.0 3.25  4.94  1.5  2.5
## gamble 70.0 38.5 57.2  6 25.0 6.9 69.7 13.3 0.60 38.00 14.4 19.2
```


Modelo ANCOVA forma matricial

$$\begin{bmatrix} y_1 \\ \vdots \\ y_{19} \\ y_{20} \\ \vdots \\ y_{47} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & x_1 \\ \vdots & \vdots & \vdots & \\ 1 & 1 & 0 & x_{19} \\ 1 & 0 & 1 & x_{20} \\ \vdots & \vdots & \vdots & \\ 1 & 0 & 1 & x_{47} \end{bmatrix} \begin{bmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \beta \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \vdots \\ \epsilon_{19} \\ \epsilon_{20} \\ \vdots \\ \epsilon_{47} \end{bmatrix}$$

$$Y = X\beta + \epsilon$$

Ejemplo clase

A study was designed to evaluate whether socioeconomic factors had an effect on verbalization skills of young children. Four socioeconomic classes were defined, and 20 children under the age of six were selected for the study. The research hypothesis was that the mean verbalization skills would be different for the four classes. The researchers determined that for young children there may be significant gains in verbalization skills over only a few months. Thus, they decided to record the exact age (in months) of each child. The verbalization skills (measured by testing) were determined for each child. The data are given here.

1	1	2	2	3	3	4	4
Age	Verbal	Age	Verbal	Age	Verbal	Age	Verbal
months)	Skill	(months)	Skill	(months)	Skill	(months)	Skill
40	26.2	20	20.8	54	34.3	27	33.1
37	37.5	65	39	27	25.1	36	37.1
30	19.6	51	34.3	25	27	23	47.3
61	43.2	56	39.4	44	29.1	31	47.3
41	32.4	16	23.7	31	33.3	48	53.7
21	23.5	29	23.8	39	38.4	48	59.6
18	15.6	20	37.2	25	14.9	16	36
36	18.5	20	33	18	38.7	32	41.2
16	23.6	17	21.9	17	32.7	31	44.2
41	21	35	36.1	22	34	24	48.9

Justificaciones de uso del modelo lineal

¿Por qué deberíamos utilizar modelos lineales?

- Si se conoce la forma funcional que relaciona los parámetros de Y con x y son no lineales, entonces no deberíamos utilizar modelos lineales.
- Sin embargo, en muchas áreas de la investigación científica y en la mayoría de las áreas de la medicina, las ciencias sociales y los negocios, no se conoce modelo. Entonces, si aproximamos localmente la función verdadera, pero desconocida

$$\mu(x) = g(x; \theta);$$

Usando una expansión en serie de Taylor, truncada después de términos de orden inferior, tenemos obtener modelos de regresión

Ejercicio clase: Cuadro latino

los efectos de cinco formulaciones diferentes de un propulsor de cohete utilizado en sistemas de escape de tripulaciones aéreas sobre la tasa de combustión observada. Elimina dos factores de error: **lotes de materia prima** y **operadores**. El diseño del cuadrado latino se utiliza para eliminar dos fuentes de ruido y permite bloquear en dos direcciones (filas y columnas).

Table 4-9 Latin Square Design for the Rocket Propellant Problem

Batches of Raw Material	Operators				
	1	2	3	4	5
1	<i>A</i> = 24	<i>B</i> = 20	<i>C</i> = 19	<i>D</i> = 24	<i>E</i> = 24
2	<i>B</i> = 17	<i>C</i> = 24	<i>D</i> = 30	<i>E</i> = 27	<i>A</i> = 36
3	<i>C</i> = 18	<i>D</i> = 38	<i>E</i> = 26	<i>A</i> = 27	<i>B</i> = 21
4	<i>D</i> = 26	<i>E</i> = 31	<i>A</i> = 26	<i>B</i> = 23	<i>C</i> = 22
5	<i>E</i> = 22	<i>A</i> = 30	<i>B</i> = 20	<i>C</i> = 29	<i>D</i> = 31

Ejercicio clase: Cuadro latino

El modelo estadístico para un cuadro latino:

$$y_{ij} = \mu + \tau_i + \alpha_j + \beta_k + \epsilon_{ij}; \quad i = j = k = 1, \dots, p$$

- y_{ij} es la respuesta para el i -ésimo sujeto en el j -ésimo nivel de tratamiento
- $\mu \in R$ es una constante común a todos los individuos
- $\tau_j \in R$ es el efecto del tratamiento del j -ésimo nivel de tratamiento
- $\alpha_j \in R$ es el efecto de renglon j -ésimo
- $\beta_k \in R$ es el efecto de columna k -ésima
- ϵ_{ij} son $iid \sim N(0, \sigma^2)$ es un término de error gaussiano