

Notas del curso de modelo lineal

Estimación por Mínimos Cuadrados Ordinarios

Humberto Vaquera Huerta
2024

Historia de Método de mínimos cuadrados

- En 632 **Galileo Galilei**, con datos de **Tycho Brahe's** (1572) indica que todas las observaciones están sujetas a *errores que están simétricamente distribuidos alrededor del cero y que los errores pequeños son más frecuentes que los grandes*.
- Junio de 1801 el astrónomo Zach estudiaba las posiciones orbitales de "Ceres", **Gauss** predijo la posición del "Ceres" usando un método nuevo con pocos datos..
- En 1805 **Legendre** publica el método de los mínimos cuadrados.
- En 1809 **Gauss** justifica el método de los mínimos cuadrados de Legendre.
- 1823 Gauss prueba el **teorema de Gauss-Markov**.
- Regresión y correlación fue **Francis Galton**, al estudiar en "Hereditary Genius" en 1869, la herencia de la estatura.
- 1890, **Weldon** introduce el concepto de "coeficiente de correlación"
- **Karl Pearson** en 1896 extiende las ideas de Galton y Weldon a "p" variables correlacionadas deriva la "superficie normal multivariada".
- Entre 1922 y 1935 **Fisher** extiende la inferencia y pruebas de hipótesis.

Método de mínimos cuadrados

Considere el **modelo lineal general**

$$Y = X\beta + \varepsilon,$$

; Donde:

- Y es un vector $n \times 1$ de respuestas observadas,
- X es una matriz diseño de $n \times p$ de constantes fijas,
- β es un vector $p \times 1$ de parámetros fijos pero desconocidos, y
- ε es un vector $n \times 1$ de errores aleatorios.

Si $E(\varepsilon) = 0$, entonces

$$E(Y) = E(X\beta + \varepsilon) = X\beta :$$

Dado que β es desconocido, todo lo que realmente sabemos es que $E(Y) = X\beta \in C(X)$. Para estimar $E(Y)$, parece natural tomar el vector en $C(X)$ que está más cerca de Y .

Método de mínimos cuadrados

Definición : Un estimador $\hat{\beta}$ es un estimador de mínimos cuadrados de β si $X\hat{\beta}$ es un vector en $C(X)$ que es el mas cercano a Y . En otras palabras, $\hat{\beta}$ es el estimador de mínimos cuadrados de β si

$$\hat{\beta} = \operatorname{argmin}_{\beta \in R^p} (Y - X\beta)'(Y - X\beta) :$$

Mínimos cuadrados

Sea $\beta = (\beta_1, \beta_2, \dots, \beta_p)$ y definimos la sumas de cudrados del error

$$Q(\beta) = (Y - X\beta)'(Y - X\beta);$$

Método de mínimos cuadrados

Donde $Q(\beta) = (Y - X\beta)'(Y - X\beta)$ es la suma de cuadrados del error

El punto donde $Q(\beta)$ es minimizado satisface

$$\frac{\partial Q(\beta)}{\partial \beta} = \mathbf{0}$$

Resultado .

Sea a y b vectores de dimension $p \times 1$ y A es una matriz de constantes $p \times p$.

Entonces $\frac{\partial a'b}{\partial b} = a$ y $\frac{\partial b'Ab}{\partial b} = (A + A')b$.

Si A es simetrica $\frac{\partial b'Ab}{\partial b} = 2Ab$

Ecuaciones Normales

$$Q(\beta) = (Y - X\beta)'(Y - X\beta)$$

$$Q(\beta) = (Y'Y - Y'X\beta - \beta'X'Y + \beta'X'X\beta) \quad Q(\beta) = (Y'Y - \beta'X'Y - \beta'X'Y + \beta'X'X\beta)$$

$$Q(\beta) = (Y'Y - 2\beta'X'Y + \beta'X'X\beta)$$

$$\frac{\partial Q(\beta)}{\partial \beta} = \frac{\partial Y'Y}{\partial \beta} - \frac{2\beta'X'Y}{\partial \beta} + \frac{\partial \beta'X'X\beta}{\partial \beta}$$

$$\frac{\partial Q(\beta)}{\partial \beta} = -2X'Y + 2X'X\beta$$

$$0 = -2X'Y + 2X'X\beta$$

$$0 = -X'Y + X'X\beta$$

Ecuaciones Normales

$$X'X\beta = X'Y$$

Estimación caso rango completo

Modelos de Regresión con predictores continuos

En general: Para un conjunto de datos con n observaciones $(y_i, x_{i1}, \dots, x_{ik})$, el modelo es:

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} + \varepsilon_i, \\ i = 1, \dots, n.$$

- suponiendo que ε_i son independientes con media 0 y varianza común σ^2 .
- es decir $E(\varepsilon) = 0$ y $var(\varepsilon) = \sigma^2$.

Usualmente $\varepsilon \sim N(0, \sigma^2)$, entonces y es normalmente distribuido, i.e., $y \sim N(\mu, \sigma^2)$, donde

$$\mu = E(y) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p. \tag{1}$$

En forma matricial

El modelo es:

$$y = X\beta + \epsilon$$

$$, E(\epsilon) = 0, \text{ cov}(\epsilon) = \sigma^2 I$$

donde:

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \dots & x_{1k} \\ 1 & x_{21} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n_1} & \dots & x_{n_k} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

- X , es una matriz de $n \times p$, es llamada la **matriz diseño**, donde $p = k + 1$.
- β es un vector de los coeficientes de regresión.
- ϵ es un vector de errores aleatorios.
- Si X es de rango completo $X^t X$ tiene inversa $(X^t X)^{-1}$ y es unica.

Estimador de mínimos cuadrados de β

Estimador de mínimos cuadrados de β minimiza

$$L = \sum_{i=1}^n \epsilon_i^2 = \epsilon^T \epsilon = (y - X\beta)^T (y - X\beta)$$

sea

$$\frac{\partial L}{\partial \beta} = -2X^T(y - X\beta) = 0$$

Las **ecuaciones normales** son

$$X^T X \beta = X^T y$$

El **Estimador de Mínimos Cuadrados** (ECM) es

$$\hat{\beta} = (X^T X)^{-1} X^T y,$$

Los *valores predichos o ajustados*

Los *valores predichos o ajustados* son

$$\begin{aligned}\hat{y} &= X\hat{\beta} \\ &= X(X^T X)^{-1} X^T y \\ &= Hy,\end{aligned}$$

donde

$$H = X(X^T X)^{-1} X^T$$

es la *hat matrix*.

- la *hat matrix* juega un rol importante en análisis de residuales.
- Propiedad: H es idempotente, i.e., $H^2 = H$.

Residuales

Los residuales son

$$\begin{aligned}\hat{\epsilon} &= y - X\hat{\beta} \\ &= y - Hy \\ &= (I - H)y\end{aligned}$$

La suma de cuadrados de residuales (SCE) es

$$\begin{aligned}SCE &= \hat{\epsilon}^t \hat{\epsilon} \\ &= y^t (I - H)(I - H)y \\ &= y^t (I - H)y\end{aligned}$$

Un estimador insesgado de σ^2 es

$$\hat{\sigma}^2 = \frac{RSS}{n - p} = CME,$$

donde $n - p$ son los **grados de libertad del error**.

Propiedades de los estimadores de los MCO

Las propiedades de $\hat{\beta}$ tienen una distribución normal multivariada con

- $\hat{\beta}$ es un estimador insesgado de β , i.e., $E(\hat{\beta}) = \beta$.
- la covarianza depende de σ y la matriz de diseño, $cov(\hat{\beta}) = \sigma^2(X^T X)^{-1}$.
- $\hat{\beta}$ es el estimador de máxima verosimilitud (MLE) si ϵ tiene una distribución normal.
- **Teorema de Gauss-Markov:** Si el modelo es correcto y $E(\epsilon) = 0$ y $cov(\epsilon) = \sigma^2 I$, entonces $\hat{\beta}$ es el mejor estimador lineal insesgado (MELI).

Ejemplo

Márgenes brutos (y_i) de vacas lecheras explicado por factores de producción.

Vaca	Proteina(kg)	Calif	TasaNR	Vel_Ordeña	CelulasSom	Margen(\$)
1	246	75	66	3	3.5	-284
2	226	80	63	4	3.3	-402
3	302	82	60	2	3.1	-207
4	347	77	58	3	4.3	267
5	267	71	66	5	3.7	-201
6	315	86	71	4	3.5	283
7	241	90	68	3	3.6	-45
8	290	83	70	2	3.9	246
9	271	78	67	1	4.1	70
10	386	80	64	3	3.4	280
10	386	80	64	3	3.4	280

Modelo de regresión

Suponga el modelo:

$$y_i = \mu + b_1P_i + b_2T_i + b_3NRR_i + b_4MS_i + b_5SCS_i + e_i$$

Supuestos:

$$E(y_i) = \mu + b_1P_i + b_2T_i + b_3NRR_i + b_4MS_i + b_5SCS_i$$

$$Var(y_i) = Var(e_i) = \sigma_e^2$$

- σ_e^2 es constante para todas las observaciones (Homocedasticidad)
- No tenemos mas predictores disponibles
- las vacas son todas de la misma edad y raza
- las vacas no están relacionadas (INDEPENDENCIA)

En Notación Matricial

$$\begin{pmatrix} -284 \\ -402 \\ -207 \\ 267 \\ -201 \\ 283 \\ -45 \\ 246 \\ 70 \\ 280 \end{pmatrix} = \begin{pmatrix} 1 & 246 & 75 & 66 & 3 & 3.5 \\ 1 & 226 & 80 & 63 & 4 & 3.3 \\ 1 & 302 & 82 & 60 & 2 & 3.1 \\ 1 & 347 & 77 & 58 & 3 & 4.3 \\ 1 & 267 & 71 & 66 & 5 & 3.7 \\ 1 & 315 & 86 & 71 & 4 & 3.5 \\ 1 & 241 & 90 & 68 & 3 & 3.6 \\ 1 & 290 & 83 & 70 & 2 & 3.9 \\ 1 & 271 & 78 & 67 & 1 & 4.1 \\ 1 & 386 & 80 & 64 & 3 & 3.4 \end{pmatrix} \begin{pmatrix} \mu \\ b_1 \\ b_2 \\ b_3 \\ b_4 \\ b_5 \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \\ \epsilon_4 \\ \epsilon_5 \\ \epsilon_6 \\ \epsilon_7 \\ \epsilon_8 \\ \epsilon_9 \\ \epsilon_{10} \end{pmatrix}$$

$$\mathbf{y} = \mathbf{X}\beta + \epsilon$$
$$r(\mathbf{X}) = 6, \quad \text{Var}(\epsilon) = \mathbf{I}\sigma_\epsilon^2$$

Ejemplo de las vacas

Ecuaciones Normales $\mathbf{X}'\mathbf{X}\beta = \mathbf{X}'\mathbf{y}$.

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} 10 & 2891 & 802 & 653 & 30 & 36.40 \\ 2891 & 858337 & 231838 & 188256 & 8614 & 10547.60 \\ 802 & 231838 & 64588 & 52444 & 2393 & 2915.00 \\ 653 & 188256 & 52444 & 42795 & 1961 & 2377.10 \\ 30 & 8614 & 2393 & 1961 & 102 & 108.20 \\ 36.4 & 10547.60 & 2915 & 2377.10 & 108.2 & 133.72 \end{pmatrix}$$

$$\mathbf{X}'\mathbf{y} = \begin{pmatrix} 7 \\ 92442 \\ 4420 \\ 2593 \\ -679 \\ 469 \end{pmatrix},$$

$$\mathbf{y}'\mathbf{y} = 622,729.$$

Ejemplo de las vacas

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y},$$

$$\hat{\beta} = \begin{pmatrix} -4909.611560 \\ 4.158675 \\ 14.335441 \\ 20.833125 \\ 1.493961 \\ 327.871209 \end{pmatrix}$$

Modelo estimado

$$\hat{y}_i = -4909.61 + 4.15P_i + 14.33T_i + 20.83NRR_i + 1.49MS_i + 327.87SCS_i$$

Modelo sin predictores

modelo solo con la media:

$$y_i = \mu + \epsilon_i$$

$$X = \mathbf{1}_n,$$

$$\beta = \mu,$$

$$\begin{aligned}\hat{\beta} &= (X^T X)^{-1} X^T y \\ &= (\mathbf{1}^T \mathbf{1})^{-1} \mathbf{1}^T y \\ &= \frac{1}{n} \mathbf{1}^T y = \bar{y}\end{aligned}$$

Note

$$\hat{\beta} = \bar{y}$$

Regresión lineal simple

regresión lineal simple (un predictor):

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

$$y = X\beta + \epsilon \text{ es } \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_1 \\ \vdots & \\ 1 & x_n \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

Un enfoque simple:

$$y_i = \beta_0 + \beta_1 \bar{x} + \beta_1 (x_i - \bar{x}) + \epsilon_i = \beta'_0 + \beta_1 (x_i - \bar{x}) + \epsilon_i$$

regresión lineal simple (un predictor)

entonces

$$X = \begin{pmatrix} 1 & x_1 - \bar{x} \\ \vdots & \vdots \\ 1 & x_n - \bar{x} \end{pmatrix}, X^T X = \begin{pmatrix} n & 0 \\ 0 & \sum (x_i - \bar{x})^2 \end{pmatrix}$$

$$\begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} = (X^T X)^{-1} X^T$$

$$= \begin{pmatrix} \frac{1}{n} & 0 \\ 0 & \frac{1}{\sum (x_i - \bar{x})^2} \end{pmatrix} \begin{pmatrix} 1 & \cdots & 1 \\ x_1 - \bar{x} & \cdots & x_n - \bar{x} \end{pmatrix} \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

$$\hat{\beta}'_0 = \frac{1}{n} \sum y_i = \bar{y}, \quad \hat{\beta}_1 = \frac{\sum (x_i - \bar{x}) y_i}{\sum (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Ejemplo Jugos:

¿El sabor del Jugo de frutas se puede explicar por la proporción de ingredientes?. Considere un experimento realizado por un investigador con un catador experimentado en sabores de jugos

unidad	Y=índice de sabor	x1=fracción de jugo sandia	x2=fracción de jugo de naranja	x3=fracción de jugo de piña	x4=fracción de jugo de uva
1	6.5	0.8	0.2	0	0
2	6.96	0.8	0	0.2	0
3	6	0.8	0	0	0.2
4	7.21	0.4	0.3	0.3	0
5	6.53	0.4	0.3	0	0.3
6	6.88	0.4	0	0.3	0.3

Considere el modelo

$$Y_i = \beta_0 + \beta_1 X_1 + \dots + \beta_4 X_4 + \epsilon$$

Obtenga X y $Rango(X)$

Caso Rango Incompleto

Modelos con variables categoricas

En los modelos ANOVA los predictores son variables categóricas y la matrix diseño X resultante es de ceros y unos con rango incompleto.

- En los ejemplos previos tratamos el caso X con columnas de rango completo, entonces $X'X$ tiene un determinante no-cero, es no-singular, y tiene una inversa.
- Muchos modelos tienen $r(X)$ menor al numero de columnas, entonces $X'X$ tiene determinante cero, es singular, y por lo tanto no tiene inversa.

Ejemplo: Datos de crecimiento en becerros de engorda

<i>Calf Tattoo</i>	<i>Age of Dam (yr)</i>	<i>Breed of calf</i>	<i>PWG (kg)</i>
16K	2	AN	346
18K	3	AN	355
22K	4	AN	363
101L	5+	HE	388
121L	5+	HE	384
98L	2	HE	366
115L	3	HE	371
117L	3	HE	375
52J	4	SM	412
49J	5+	SM	429
63J	2	SM	396
70J	2	SM	404

Modelo de dos vias de clasificacion sin interaccion

Modelo para datos de becerros

$$Y_{ijk} = \mu + \tau_i + \beta_j + \epsilon_{ijk}$$

,

$$\text{para } i = 1, 2, \dots, 4, j = 1, 3, \dots, b, k = 1, 2, \dots, r_{ij}, \quad (2)$$

donde

- Y_{ijk} es el peso del becerro
- μ es el efecto de la media general,
- τ_i es el efecto de la i – *esima* edad de la madre,
- β_j es el efecto debido a la j – *esima* raza.
- ϵ_{ij} es el termino de error aleatorio.

Matriz diseño X

$$y = X\beta + \epsilon$$

$$\begin{pmatrix} 346 \\ 355 \\ 363 \\ 388 \\ 384 \\ 366 \\ 371 \\ 375 \\ 412 \\ 429 \\ 396 \\ 404 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu \\ A_2 \\ A_3 \\ A_4 \\ A_{5+} \\ B_{AN} \\ B_{HE} \\ B_{SM} \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \\ \epsilon_4 \\ \epsilon_5 \\ \epsilon_6 \\ \epsilon_7 \\ \epsilon_8 \\ \epsilon_9 \\ \epsilon_{10} \\ \epsilon_{11} \\ \epsilon_{12} \end{pmatrix}$$

Ecuaciones Normales en el caso Rango Incompleto

$$X^t X \beta = X^t y$$

El sistema de ecuaciones normales es consistente, y la forma general para resolver el sistema es

$$\hat{\beta} = (X^t X)^- X^t Y + [I - (X^t X)^- X^t X]z,$$

donde $z \in R^p$, y $(X^t X)^-$ es una inversa generalizada de $X^t X$.

CONSISTENCIA : Un sistema lineal $Ax = c$ es consistente si existe un x^* tal que $Ax^* = c$; cuando $c \in C(A)$. (o $Rango(A) = Rango(A|c)$)

Las EN son consistentes si $X^t Y \in C(X^t X)$. ($Rango(X^t X) = Rango(X^t X | X^t y)$)

INVARIANZA: si $\tilde{\beta}$ y $\hat{\beta}$ resuelven las ecuaciones normales, entonces $X\tilde{\beta} = X\hat{\beta}$. En otras palabras, $X\hat{\beta}$ es invariante a la elección de $\hat{\beta}$.

Uso de inversa generalizada

G es una inversa generalizada de A si $AGA = A$.

Una inversa generalizada de A , usualmente se denota como A^- es decir $G = A^-$

Teorema: Sea A una matriz $m \times n$, G una matriz $n \times m$ y p un numero entero positivo. Entonces $X = GB$ es una solución al sistema $AX = B$ para cualquier matriz B de $m \times p$ para el cual es sistema es consistente si y solo si G es una inversa generalizada de A .

Ejemplo: Sistema de ecuaciones

$$Ax = b$$

$$\begin{pmatrix} 5 & 2 & -1 & 2 \\ 2 & 2 & 3 & 1 \\ 1 & 1 & 4 & -1 \\ 2 & -1 & -3 & -1 \\ 3 & 0 & 1 & -2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 7 \\ 9 \\ 5 \\ -6 \\ -1 \end{pmatrix}$$

Una Inversa Generalizada de A

$$G = \frac{1}{15} \begin{pmatrix} 5 & -9 & 8 & 0 & 0 \\ -5 & 21 & -17 & 0 & 0 \\ 0 & -3 & 6 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

Ejemplo: Sistema de ecuaciones..cont..

Por tanto, al sustituir en la formula de todas las soluciones

$$x = Gb + (GA - I)z$$

$$x = \frac{1}{15} \begin{pmatrix} 5 & -9 & 8 & 0 & 0 \\ -5 & 21 & -17 & 0 & 0 \\ 0 & -3 & 6 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 7 \\ 9 \\ 5 \\ -6 \\ -1 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 & -7/15 \\ 0 & 0 & 0 & 28/15 \\ 0 & 0 & 0 & -9/15 \\ 0 & 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} z_1 \\ z_2 \\ z_3 \\ z_4 \end{pmatrix}$$

$$x = \frac{1}{15} \begin{pmatrix} -6 - 7z_4 \\ 69 + 28z_4 \\ 3 - 9z_4 \\ -15z_4 \end{pmatrix}$$

Note que z_4 puede ser cualquier numero real y esto genera todas las soluciones

Uso de inversa generalizada

$$X^t X \beta = X^t y$$

El sistema de ecuaciones normales es consistente, y la forma general para resolver el sistema es

En el caso rango incompleto una inversa generalizada de $(\mathbf{X}'\mathbf{X})$ es: $\mathbf{G} = (\mathbf{X}'\mathbf{X})^-$

Una solución es:

$$\tilde{\beta} = (\mathbf{X}^t \mathbf{X})^- \mathbf{X}^t \mathbf{y}$$

es una solución

- Numero Infinito de inversas generalizadas
- Otros vectores de soluciones

$$\hat{\beta} = (X^t X)^- X^t Y + [I - (X^t X)^- X^t X]z,$$

Inversa de Moore-Penrose

Siempre existe un inverso generalizado, pero puede no ser único Una opción común es la inversa generalizada de Moore-Penrose

Definición: Sea A una matriz de $m \times n$. Entonces, la **inversa de Moore-Penrose** de A es la matriz $A^\dagger$ que satisface las siguientes condiciones (de Penrose):

$$\begin{aligned} AA^\dagger A &= A, & A^\dagger AA^\dagger &= A^\dagger, \\ AA^\dagger &= (AA^\dagger)^*, & A^\dagger A &= (A^\dagger A)^*. \end{aligned}$$

Ejemplo de Becerros de engorda

$$X^t X = \begin{pmatrix} 12 & 4 & 3 & 2 & 3 & 3 & 5 & 4 \\ 4 & 4 & 0 & 0 & 0 & 1 & 1 & 2 \\ 3 & 0 & 3 & 0 & 0 & 1 & 2 & 0 \\ 2 & 0 & 0 & 2 & 0 & 1 & 0 & 1 \\ 3 & 0 & 0 & 0 & 3 & 0 & 2 & 1 \\ 3 & 1 & 1 & 1 & 0 & 3 & 0 & 0 \\ 5 & 1 & 2 & 0 & 2 & 0 & 5 & 0 \\ 4 & 2 & 0 & 1 & 1 & 0 & 0 & 4 \end{pmatrix}$$

$$X^t y = \begin{pmatrix} 4589 \\ 1512 \\ 1101 \\ 775 \\ 1201 \\ 1064 \\ 1884 \\ 1641 \end{pmatrix}$$

Una inversa generalizada de $X^t X$ es:

$$(X^t X)^- = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \frac{162}{227} & \frac{51}{227} & \frac{73}{227} & -\frac{71}{227} & -\frac{94}{227} & -\frac{31}{227} \\ 0 & 0 & \frac{51}{227} & \frac{180}{227} & \frac{44}{227} & -\frac{77}{227} & -\frac{38}{227} & -\frac{56}{227} \\ 0 & 0 & \frac{73}{227} & \frac{44}{227} & \frac{152}{227} & -\frac{39}{227} & -\frac{90}{227} & -\frac{49}{227} \\ 0 & 0 & -\frac{71}{227} & -\frac{77}{227} & -\frac{39}{227} & \frac{125}{227} & \frac{44}{227} & \frac{29}{227} \\ 0 & 0 & -\frac{94}{227} & -\frac{38}{227} & -\frac{90}{227} & \frac{44}{227} & \frac{119}{227} & \frac{32}{227} \\ 0 & 0 & -\frac{31}{227} & -\frac{56}{227} & -\frac{49}{227} & \frac{29}{227} & \frac{32}{227} & \frac{83}{227} \end{pmatrix}$$

Solucion a EN ejemplo becerros

Una solución a las EN $X^t X \beta = X^t y$ es:

$$\tilde{\beta} = (X^t X)^{-1} X^t y$$

$$\tilde{\beta} = \begin{pmatrix} 0 \\ 0 \\ \frac{2049}{227} \\ \frac{3079}{227} \\ \frac{5560}{227} \\ \frac{78\,800}{227} \\ \frac{82\,490}{227} \\ \frac{90\,967}{227} \end{pmatrix}$$

Todas las soluciones de las EN Becerros

$$\hat{\beta} = (X^t X)^{-} X^t Y + [I - (X^t X)^{-} X^t X] z,$$

$$\begin{pmatrix} -11a - 4b - 3c - 2d - 3f - 5g - 4h - 3e \\ -4a - 3b - f - g - 2h \\ -3a - b - c - f - 2g \\ -2a - b - f - h \\ -3a - b - 2g - h - e \\ -2a - c - d - f \\ -4a - 2c - 3g - 2e \\ -3a - b - d - 2h - e \end{pmatrix}$$

con $z = (a, b, c, d, e, f, g, h)^t$ un vector de números reales cualesquiera

Ejemplo Becerros en R

ID	Edad	Raza
16K	2	AN
18K	3	AN
22K	4	AN
101L	5+	HE
121L	5+	HE
98L	2	HE
115L	3	HE
117L	3	HE
52J	4	SM
49J	5+	SM
63J	2	SM
70J	2	SM

Ejemplo Becerros en R

Matriz Diseño(X) y Respuesta (Y)

m	e2	e3	e4	e5	r1	r2	r3
1	1	0	0	0	1	0	0
1	0	1	0	0	1	0	0
1	0	0	1	0	1	0	0
1	0	0	0	1	0	1	0
1	0	0	0	1	0	1	0
1	1	0	0	0	0	1	0
1	0	1	0	0	0	1	0
1	0	1	0	0	0	1	0
1	0	0	1	0	0	0	1
1	0	0	0	1	0	0	1
1	1	0	0	0	0	0	1
1	1	0	0	0	0	0	1

346
355
363
388
384
366
371
375
412
429
396
404

Matriz $(X^t X)$ y g-inversa $((X^t X)^-)$

	m	e2	e3	e4	e5	r1	r2	r3
m	12	4	3	2	3	3	5	4
e2	4	4	0	0	0	1	1	2
e3	3	0	3	0	0	1	2	0
e4	2	0	0	2	0	1	0	1
e5	3	0	0	0	3	0	2	1
r1	3	1	1	1	0	3	0	0
r2	5	1	2	0	2	0	5	0
r3	4	2	0	1	1	0	0	4

0.604	-0.454	-0.269	-0.507	0	-0.194	-0.405	0
-0.454	0.670	0.348	0.476	0	-0.044	0.181	0
-0.269	0.348	0.740	0.379	0	-0.220	-0.097	0
-0.507	0.476	0.379	1.075	0	-0.137	0.260	0
0.000	0.000	0.000	0.000	0	0.000	0.000	0
-0.194	-0.044	-0.220	-0.137	0	0.661	0.291	0
-0.405	0.181	-0.097	0.260	0	0.291	0.608	0
0.000	0.000	0.000	0.000	0	0.000	0.000	0

Estimador ($\hat{\beta}$) y pronostico ($X\hat{\beta}$)

425.22909

-24.49338

-15.46697

-10.92952

0.00000

-53.59912

-37.34359

0.00000

347.1366

356.1630

360.7004

387.8855

387.8855

363.3921

372.4185

372.4185

414.2996

425.2291

400.7357

400.7357

Todas las soluciones

$$\hat{\beta} = (X^t X)^{-1} X^t Y + [I - (X^t X)^{-1} X^t X]z,$$

Con z generado al azar

```
I=diag(nrow(beta1))
z=as.matrix(rnorm(n = nrow(beta1)))
beta_s = beta1 + (I - IGXTX1%*%XTX)%*%z
X%*%beta_s
```

```
##           [,1]
## [1,] 347.1366
## [2,] 356.1630
## [3,] 360.7004
## [4,] 387.8855
## [5,] 387.8855
## [6,] 363.3921
## [7,] 372.4185
## [8,] 372.4185
## [9,] 414.2996
## [10,] 425.2291
## [11,] 400.7357
## [12,] 400.7357
```

Uso del R: Captura datos Becerros

```
becerros2 <- read.csv("becerros2.csv")  
becerros2
```

##		ID	Edad	Raza	Peso
##	1	16K	2	AN	346
##	2	18K	3	AN	355
##	3	22K	4	AN	363
##	4	101L	5+	HE	388
##	5	121L	5+	HE	384
##	6	98L	2	HE	366
##	7	115L	3	HE	371
##	8	117L	3	HE	375
##	9	52J	4	SM	412
##	10	49J	5+	SM	429
##	11	63J	2	SM	396
##	12	70J	2	SM	404

Uso del R: Obtención de la matriz diseño X

```
##install.packages("sasLM")
library(sasLM)
X1=ModelMatrix(Peso~Edad+Raza,beceros, KeepOrder=FALSE)
X=as.matrix(X1$X)
X
```

##	(Intercept)	Edad2	Edad3	Edad4	Edad5+	RazaAN	RazaHE	RazaSM
## 1	1	1	0	0	0	1	0	0
## 2	1	0	1	0	0	1	0	0
## 3	1	0	0	1	0	1	0	0
## 4	1	0	0	0	1	0	1	0
## 5	1	0	0	0	1	0	1	0
## 6	1	1	0	0	0	0	1	0
## 7	1	0	1	0	0	0	1	0
## 8	1	0	1	0	0	0	1	0
## 9	1	0	0	1	0	0	0	1
## 10	1	0	0	0	1	0	0	1
## 11	1	1	0	0	0	0	0	1
## 12	1	1	0	0	0	0	0	1

```
R(X)
```

```
## [1] 6
```

Uso del R: Obtención de $\tilde{\beta}$

$$\tilde{\beta} = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{y}$$

```
##install.packages("sasLM")  
library(sasLM)  
mm=GLM(Peso~Edad+Raza,becerros)  
mm$Parameter
```

```
## NULL
```

Estimación de σ^2

La suma de cuadrados del error (SCE) es:

$$SCE = \epsilon^T \epsilon$$

$$SCE = (\mathbf{y} - \mathbf{X}\hat{\beta})^t (\mathbf{y} - \mathbf{X}\hat{\beta})$$

Un estimador insesgado de σ^2 es

$$\hat{\sigma}^2 = \frac{SCE}{n - \text{rango}(X)}$$

también se denomina grados de libertad del error

Estimación de σ^2

Ejemplo datos becerros

```
SCE=t(Y-X%%beta_s)%*(Y-X%%beta_s)
SCE
```

```
##           [,1]
## [1,] 91.11013
```

```
gle=nrow(X)-R(X)
gle
```

```
## [1] 6
```

```
CME=SCE/gle
## Estimador de sigma^2 (cuadrado medio del error)
knitr::kable(CME)
```

15.18502

Estimación de σ^2

Ejemplo datos becerros

```
library(sasLM)
mm=GLM(Peso~Edad+Raza,becerros)
mm$ANOVA
```

```
## Response : Peso
##              Df Sum Sq Mean Sq F value    Pr(>F)
## MODEL              5 6547.8  1309.56    86.24 1.67e-05 ***
## RESIDUALS           6   91.1    15.19
## CORRECTED TOTAL  11 6638.9
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

$$\hat{\sigma}^2 = \text{CME} = 15.19$$

Varianza de $\hat{\beta}$

Caso X Rango completo

$$\begin{aligned}\text{var}(\hat{\beta}) &= \text{var}((\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{Y}) \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^t \sigma^2 \mathbf{I} ((\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t)^t \\ &= \sigma^2 (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{X} (\mathbf{X}^t \mathbf{X})^{-1} \\ &= \sigma^2 (\mathbf{X}^t \mathbf{X})^{-1}\end{aligned}$$

Caso X Rango Incompleto

$$\begin{aligned}\text{var}(\hat{\beta}) &= \text{var}((\mathbf{X}^t \mathbf{X})^- \mathbf{X}^\top \mathbf{Y}) \\ &= (\mathbf{X}^t \mathbf{X})^- \mathbf{X}^t \sigma^2 \mathbf{I} ((\mathbf{X}^t \mathbf{X})^- \mathbf{X}^\top)^t \\ &= \sigma^2 (\mathbf{X}^t \mathbf{X})^- \mathbf{X}^t \mathbf{X} (\mathbf{X}^t \mathbf{X})^- \\ &= \sigma^2 (\mathbf{X}^t \mathbf{X})^-\end{aligned}$$

ANOVA de una vía.

Considere un experimento que se realiza para comparar $a \geq 2$ tratamientos. Para el i – *ésimo* nivel del tratamiento, suponga que n_i unidades experimentales son seleccionados al azar y asignados al i – *ésimo* tratamiento. Considere el modelo

$$Y_{ij} = \mu + \alpha_i + \epsilon_{ij};$$

para $i = 1, 2, \dots, a$ y $j = 1, 2, \dots, n_i$, donde los errores aleatorios ϵ_{ij} son independientes con media cero y varianza común $\sigma^2 > 0$. Si los efectos del un tratamiento $\alpha_1, \alpha_2, \dots, \alpha_a$ se consideran como constantes fijas, entonces este modelo es un caso especial del Modelo $Y = X\beta + \epsilon$. Para ver esto, observe que con $n = \sum_{i=1}^a n_i$,

$$y = X\beta + \epsilon$$

$$\begin{pmatrix} Y_{11} \\ Y_{12} \\ \vdots \\ Y_{an_a} \end{pmatrix} = \begin{pmatrix} 1_{n_1} & 1_{n_1} & 0_{n_1} & \cdots & 0_{n_1} \\ 1_{n_2} & 1_{n_2} & 0_{n_2} & \cdots & 0_{n_2} \\ \vdots & \vdots & \cdots & \vdots & \vdots \\ 1_{n_a} & 1_{n_a} & 0_{n_a} & \cdots & 0_{n_a} \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \cdots \\ \alpha_a \end{pmatrix} + \begin{pmatrix} \epsilon_{11} \\ \epsilon_{12} \\ \vdots \\ \epsilon_{an_a} \end{pmatrix}$$

donde 1_{n_i} es un vector de unos de $n_i \times 1$ y 0_{n_i} es un vector de ceros de $n_i \times 1$

ANOVA de una vía.

El modelo:

$$Y_{ij} = \mu + \alpha_i + \epsilon_{ij};$$

X No es de rango completo ya que, en este caso, la matriz X es $[1_n : \bigotimes_{i=1}^a 1_{n_i}]$ que es de orden $n \times (a + 1)$ y $\text{rango}(X) = a$.

Definición: Si A es una matriz de $m \times n$ y B es una matriz $p \times q$, entonces el **producto de Kronecker** $A \otimes B$ es la matriz de bloques $mp \times nq$

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} a_{11}B & \cdots & a_{1n}B \\ \vdots & \ddots & \vdots \\ a_{m1}B & \cdots & a_{mn}B \end{bmatrix}.$$

Producto de Kronecker

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} a_{11}b_{11} & a_{11}b_{12} & \cdots & a_{11}b_{1q} & \cdots & \cdots & a_{1n}b_{11} & a_{1n}b_{12} & \cdots & a_{1n}b_{1q} \\ a_{11}b_{21} & a_{11}b_{22} & \cdots & a_{11}b_{2q} & \cdots & \cdots & a_{1n}b_{21} & a_{1n}b_{22} & \cdots & a_{1n}b_{2q} \\ \vdots & \vdots & \ddots & \vdots & & & \vdots & \vdots & \ddots & \vdots \\ a_{11}b_{p1} & a_{11}b_{p2} & \cdots & a_{11}b_{pq} & \cdots & \cdots & a_{1n}b_{p1} & a_{1n}b_{p2} & \cdots & a_{1n}b_{pq} \\ \vdots & \vdots & & \vdots & \ddots & & \vdots & \vdots & & \vdots \\ \vdots & \vdots & & \vdots & & \ddots & \vdots & \vdots & & \vdots \\ a_{m1}b_{11} & a_{m1}b_{12} & \cdots & a_{m1}b_{1q} & \cdots & \cdots & a_{mn}b_{11} & a_{mn}b_{12} & \cdots & a_{mn}b_{1q} \\ a_{m1}b_{21} & a_{m1}b_{22} & \cdots & a_{m1}b_{2q} & \cdots & \cdots & a_{mn}b_{21} & a_{mn}b_{22} & \cdots & a_{mn}b_{2q} \\ \vdots & \vdots & \ddots & \vdots & & & \vdots & \vdots & \ddots & \vdots \\ a_{m1}b_{p1} & a_{m1}b_{p2} & \cdots & a_{m1}b_{pq} & \cdots & \cdots & a_{mn}b_{p1} & a_{mn}b_{p2} & \cdots & a_{mn}b_{pq} \end{bmatrix}.$$

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \otimes \begin{bmatrix} 0 & 5 \\ 6 & 7 \end{bmatrix} = \begin{bmatrix} 1 \cdot 0 & 1 \cdot 5 & 2 \cdot 0 & 2 \cdot 5 \\ 1 \cdot 6 & 1 \cdot 7 & 2 \cdot 6 & 2 \cdot 7 \\ 3 \cdot 0 & 3 \cdot 5 & 4 \cdot 0 & 4 \cdot 5 \\ 3 \cdot 6 & 3 \cdot 7 & 4 \cdot 6 & 4 \cdot 7 \end{bmatrix} = \begin{bmatrix} 0 & 5 & 0 & 10 \\ 6 & 7 & 12 & 14 \\ 0 & 15 & 0 & 20 \\ 18 & 21 & 24 & 28 \end{bmatrix}$$

Producto de Kronecker en R

```
A <- matrix(c(1, 2, 3,4), 2, 2, byrow=TRUE)
A
```

```
##      [,1] [,2]
## [1,]    1    2
## [2,]    3    4
```

```
B <- matrix(c(0, 5, 6,7), 2, 2, byrow=TRUE)
B
```

```
##      [,1] [,2]
## [1,]    0    5
## [2,]    6    7
```

```
kron(A, B)
```

```
##      [,1] [,2] [,3] [,4]
## [1,]    0    5    0   10
## [2,]    6    7   12   14
## [3,]    0   15    0   20
## [4,]   18   21   24   28
```