

Notas del curso de modelo lineal

Formas de solución de las EN en rango Incompleto

Humberto Vaquera Huerta
2024

Modelos de rango incompleto

Definición: Modelos en los que la variable de respuesta Y es *cuantitativa*, pero todas las variables predictoras son *cualitativas* se denominan modelos de análisis de varianza (ANOVA o Anova), modelos de diseño experimental o modelos de diseño de experimentos (DOE).

Los modelos de rango no completo se utilizan a menudo en modelos de diseño experimental. Mucho de la teoría del modelo de rango no completo es similar a la del modelo de rango completo, Pero hay algunas diferencias.

- El inverso generalizado $(X^t X)^-$ no es único.
- $\hat{\beta}$ es una solución a las ecuaciones normales, pero depende de la inversa generalizada y no es única.

Algunas propiedades de los estimadores de mínimos cuadrados:

- Sea $P = P_X$ la matriz de proyección en $C(X)$ (las matrices de proyección son simétricas e idempotentes pero singulares a menos que $P = I$).
- También recuerde que $P_X X = X$, entonces $X^t P = X^t$.

Modelos de rango incompleto

Definición: Sea un modelo lineal $Y = X\beta + \epsilon$; donde $E(\epsilon) = 0$ y $var(\epsilon) = \sigma^2 I$, con X de *rango incompleto*, es decir, $rango(X) = k < p \leq n$ y $X^t X$ es singular. En este modelo, los p parámetros en β no son únicos.

Modelos de rango incompleto

Teorema. Sea $Y = X\beta + \epsilon$; donde $E(\epsilon) = 0$ y $Cov(\epsilon) = \sigma^2 I$, donde X tiene rango $r < p \leq n$.

- i) $P = X(X^t X)^- X^t$ es la matriz de proyección única en $C(X)$ y no depende de la inversa generalizada $(X^t X)^-$.
- ii) $\hat{\beta} = (X^t X)^- X^t Y$ sí depende de $(X^t X)^-$ y no es único.
- iii) $\hat{Y} = X\hat{\beta} = PY$, $r = Y - \hat{Y} = Y - X\hat{\beta} = (I - P)Y$ y $SCE = r^t r$ son únicos y, por lo tanto, no dependen de $(X^t X)^-$.
- iv) $\hat{\beta}$ es una solución de las ecuaciones normales: $X^t X\beta = X^t Y$.
- v) $Rango(P) = r$ y $rango(I - P) = n - r$.
- vi) $CME = \frac{SCE}{n-r} = \frac{r^t r}{n-r}$ es un estimador insesgado de σ^2 .
- vii) Sea X_1 una base para $C(X)$. Entonces $P = X_1(X_1^t X_1)^- X_1^t$.

Modelos de rango incompleto

Usando el método mínimos cuadrados, obtenemos las **ecuaciones normales (EN)**

$$X^t X \beta = X^t y$$

Como $X^t X$ es una matriz singular, esta ecuación no tiene solución única para $\hat{\beta}$. Donde

$$\hat{\beta} = (X^t X)^- X^t y,$$

donde $(X^t X)^-$ es un inverso generalizado de $X^t X$. Por lo tanto, para un y dado. Note que se tienen infinitas soluciones dependiendo de la elección de $(X^t X)^-$.

Formas de resolver el sistema de ecuaciones normales en caso X Rango Incompleto

Solución de las EN (rango incompleto)

- Usando inversa generalizada
- Imponiendo restricciones a las soluciones
- Reparametrizando el modelo

Ejemplo: ANOVA de una via de clasificacion

Considere un experimento completamente al azar con tres métodos de tratamiento para aguas residuales donde mide la eliminación de materiales quimicos de compuestos de carbono de las aguas residuales de arenas de playas contaminadas con petróleo. Se usaron tres replicas.

Tratamientos:

- la flotación de aire (AF),
- separación de espuma (FS), y
- la coagulación de cloruro férrico (FCC).

Un estudio se lleva a cabo y las cantidades de carbono eliminado son los siguientes:

AF	FCC	FS
34.6	26.7	38.8
35.1	26.7	39
35.3	27	40.1

Modelo ANOVA de una via de clasificacion

El modelo:

$$y_{ij} = \mu + \tau_i + \epsilon_{ij};$$

donde:

- y_{ij} representa la j – *ésima* observación ($j = 1, 2, \dots, n_i$) en el i – *ésimo* tratamiento ($i = 1, 2, \dots, k$ niveles).
- μ representa el efecto de la media general
- τ_i representa el i – *ésimo* efecto del tratamiento.
- ϵ_{ij} representa el error aleatorio presente en la j – *ésima* observación en el i – *ésimo* tratamiento.

Modelo en forma matricial datos carbono

$$y = X\beta + \epsilon$$

$$\begin{bmatrix} 34.6 \\ 35.1 \\ 35.3 \\ 38.8 \\ 39.0 \\ 40.1 \\ 26.7 \\ 26.7 \\ 27.0 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \tau_3 \end{bmatrix} + \begin{bmatrix} \epsilon_{11} \\ \epsilon_{12} \\ \epsilon_{13} \\ \epsilon_{21} \\ \epsilon_{22} \\ \epsilon_{23} \\ \epsilon_{31} \\ \epsilon_{32} \\ \epsilon_{33} \end{bmatrix}$$

Rango (X)=3

Ecuaciones normales datos carbono

$$X^t X \beta = X^t y$$

$$\begin{bmatrix} 9 & 3 & 3 & 3 \\ 3 & 3 & 0 & 0 \\ 3 & 0 & 3 & 0 \\ 3 & 0 & 0 & 3 \end{bmatrix} \begin{bmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \tau_3 \end{bmatrix} = \begin{bmatrix} 303.3 \\ 105 \\ 117.9 \\ 80.4 \end{bmatrix}$$

Inversa generalizada $(X^t X)^-$

$$(X^t X)^- = \begin{pmatrix} 1/3 & -1/3 & -1/3 & 0 \\ -1/3 & 2/3 & 1/3 & 0 \\ -1/3 & 1/3 & 2/3 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

Solución a las EN Usando Inversa generalizada

Uso de inversa generalizada

$$X^t X \beta = X^t y$$

El sistema de ecuaciones normales es consistente, y la forma general para resolver el sistema es

En el caso rango incompleto una inversa generalizada de $(\mathbf{X}'\mathbf{X})$ es: $\mathbf{G} = (\mathbf{X}'\mathbf{X})^-$

Una solución es:

$$\tilde{\beta} = (\mathbf{X}^t \mathbf{X})^- \mathbf{X}^t \mathbf{y}$$

es una solución

- Numero Infinito de inversas generalizadas
- Otros vectores de soluciones

$$\hat{\beta} = (X^t X)^- X^t Y + [I - (X^t X)^- X^t X]z = \tilde{\beta} + [I - (X^t X)^- X^t X]z,$$

Solucion usando inversa generalizada carbono

$$\hat{\beta} = (X^t X)^{-} X^t y,$$

$$\hat{\beta} = \begin{pmatrix} 39.3 \\ -4.3 \\ -12.5 \\ 0.0 \end{pmatrix}$$

Solución ML rango incompleto imponiendo restricciones

Usando Restricción en el modelo

El Modelo $Y = X\beta + \varepsilon$ sujeto a: $P^t\beta = \delta$

- Usando multiplicadores de Lagrange:

$$Q(y) = (y - X\beta)^t(y - X\beta)$$

Sujeto a las restricciones $P^t\beta = \delta$.

$$L(\beta, \theta) = (y - X\beta)^t(y - X\beta) + 2\theta^t(P^t\beta - \delta).$$
$$(P^t\beta = \delta) \equiv (P^t\beta - \delta = 0).$$

Derivando

$$\frac{\partial L(\beta, \theta)}{\partial \beta} = -2X^t(y - X\beta) + 2P\theta$$
$$\frac{\partial L(\beta, \theta)}{\partial \theta} = 2(P^t\beta - \delta = 0)$$

Las Ecuaciones Normales Restringidas

$$\begin{pmatrix} X^t X & P \\ P^t & 0 \end{pmatrix} \begin{pmatrix} \beta \\ \theta \end{pmatrix} = \begin{pmatrix} X^t y \\ \delta \end{pmatrix}$$

sujetas a:

$$P^t \beta = \delta$$

donde es $P\beta$ no es estimable: $P^t(X^t X)^- X^t X \neq P^t$

Note que:

$$\begin{pmatrix} X^t X & P \\ P^t & 0 \end{pmatrix}$$

Es de **rango completo** y por lo tanto su inversa existe y es única.

Ejemplo del carbono

Usando la restricción

$$\tau_1 + \tau_2 + \tau_3 = 0$$

Esta restricción se puede escribir como:

$$P^t \beta = \delta$$
$$(0 \quad 1 \quad 1 \quad 1) \begin{pmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \tau_3 \end{pmatrix} = 0$$

Con $P^t(X^tX)^-X^tX \neq P^t$

Ecuaciones Normales restringidas carbono

$$\begin{pmatrix} X^t X & P \\ P^t & 0 \end{pmatrix} \begin{pmatrix} \beta \\ \theta \end{pmatrix} = \begin{pmatrix} X^t y \\ \delta \end{pmatrix}$$

$$\begin{bmatrix} 9 & 3 & 3 & 3 & 0 \\ 3 & 3 & 0 & 0 & 1 \\ 3 & 0 & 3 & 0 & 1 \\ 3 & 0 & 0 & 3 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \tau_3 \\ \theta \end{bmatrix} = \begin{bmatrix} 303.3 \\ 105 \\ 117.9 \\ 80.4 \\ 0 \end{bmatrix}$$

Solución de las ecuaciones Normales Restringidas

$$\begin{pmatrix} \hat{\beta} \\ \hat{\theta} \end{pmatrix} = \begin{pmatrix} X^t X & P \\ P^t & 0 \end{pmatrix}^{-1} \begin{pmatrix} X^t y \\ \delta \end{pmatrix}$$

$$\begin{bmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \tau_3 \\ \theta \end{bmatrix} = \begin{bmatrix} \frac{1}{9} & 0 & 0 & 0 & -\frac{1}{3} \\ 0 & \frac{2}{9} & -\frac{1}{9} & -\frac{1}{9} & \frac{1}{3} \\ 0 & -\frac{1}{9} & \frac{2}{9} & -\frac{1}{9} & \frac{1}{3} \\ 0 & -\frac{1}{9} & -\frac{1}{9} & \frac{2}{9} & \frac{1}{3} \\ -\frac{1}{3} & \frac{1}{3} & \frac{1}{3} & \frac{1}{3} & 0 \end{bmatrix} * \begin{bmatrix} 303.3 \\ 105 \\ 117.9 \\ 80.4 \\ 0 \end{bmatrix} = \begin{pmatrix} 33.7 \\ 1.3 \\ 5.6 \\ -6.9 \\ 0 \end{pmatrix}$$

Otra solución para β

Otra restricción $\tau_1 - 2\tau_2 + \tau_3 = 0$. puede darnos solución...practica de clase

Reparametrización de un modelo lineal

Razones para reparametrizar un modelo

- Reducir el numero de parámetros
- Obtener un modelo de rango completo
- Evitar el uso de inversas generalizadas
- Hacer fáciles los cálculos
- La interpretación de parámetros con mas sentido

Reparamerización

Definición: Suponga el modelo $y = X\beta + \epsilon$, con X de dimensión $n \times p$ con rango $k < p < n$, La idea de la reparameterization es transformar del vector β de parámetros no estimables a un vector de funciones estimables de β linealmente independientes.

$$\begin{pmatrix} \lambda_1^t \beta \\ \lambda_2^t \beta \\ \vdots \\ \lambda_k^t \beta \end{pmatrix} = L\beta = \theta$$

L es una matriz de dimensión $k \times p$ matriz con renglones $\lambda_1^t, \lambda_2^t, \dots, \lambda_k^t$ tal que los elementos de $L\beta = \theta$ son un conjunto completo de funciones linealmente independientes de β .

Reparametrización

Definición: **Modelo Reparametrizado** El nuevo modelo reparametrizado de rango completo es:

$y = W\theta + \epsilon$ donde W es de $n \times k$ de rango completo, y $W\theta = X\beta$ (la media bajo el modelo de rango no completo es la misma que bajo el modelo de rango completo, acabamos de cambiar la parametrización; es decir, cambiado de β a θ .)

Definición de reparametrización

Definición: Considere dos modelos lineales

- $E(Y) = X\beta, \quad V(Y) = \sigma^2 I$
- $E(Y) = W\theta, \quad V(Y) = \sigma^2 I$

Donde X es una matriz diseño de $n \times p$ y W otra matriz diseño de $n \times k$. Decimos que un modelo es una reparameterización del otro si hay Una matriz F de $p \times k$ y una matriz de G de $k \times p$ tal que $W = XF$ y $X = WG$:

Reparametrización

Definición: **Modelo Reparametrizado** El nuevo modelo de rango completo es: $y = W\theta + \epsilon$ donde W es de $n \times k$ de rango completo, y $W\theta = X\beta$ (la media bajo el modelo de rango no completo es la misma que bajo el modelo de rango completo, acabamos de cambiar la parametrización; es decir, cambiado de β a θ .)

Para encontrar el modelo nuevo (de rango incompleto) W , note que $W\theta = X\beta$ y $\theta = L\beta$ para todo β . Note que $W\theta = WL\beta$ y si L es de rango completo ($\theta = L\beta$) note que podemos obtener W como:

$$W = XL^t(LL^t)^{-1}$$

Ejemplo ilustrativo

Considere un modelo $y = X\beta + \epsilon$

$$\begin{pmatrix} y_{11} \\ y_{12} \\ y_{21} \\ y_{22} \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \beta_1 \\ \beta_2 \end{pmatrix} + \begin{pmatrix} \epsilon_{11} \\ \epsilon_{12} \\ \epsilon_{21} \\ \epsilon_{22} \end{pmatrix}$$

Con $R(X) = 3$ de rango incompleto.

Suponga tenemos la reparametrización

$$\theta_1 = \mu + \alpha_1 + \beta_1$$

$$\theta_2 = \beta_2 - \beta_1$$

$$\theta_3 = \alpha_2 - \alpha_1$$

Matricialmente

$$\theta = L^t \beta$$

Ejemplo ilustrativo

$$\theta = L^t \beta$$

$$\begin{pmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 1 & 0 \\ 0 & 0 & 0 & -1 & 1 \\ 0 & -1 & 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \beta_1 \\ \beta_2 \end{pmatrix}$$

Note que los renglones de L son linealmente independientes y el rango de L es 3 y ademas son estimables.

$$W = XL^t(LL^t)^{-1}$$

$$\begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & -1 \\ 0 & 0 & 1 \\ 1 & -1 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} \frac{1}{2} & \frac{1}{4} & \frac{1}{4} \\ \frac{1}{4} & \frac{5}{8} & \frac{1}{8} \\ \frac{1}{4} & \frac{1}{8} & \frac{5}{8} \end{pmatrix}$$

Ejemplo ilustrativo

Modelo reparametrizado

Para el ejemplo el modelo reparametrizado es: $y = W\beta + \epsilon$

$$\begin{pmatrix} y_{11} \\ y_{12} \\ y_{21} \\ y_{22} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \end{pmatrix} + \begin{pmatrix} \epsilon_{11} \\ \epsilon_{12} \\ \epsilon_{21} \\ \epsilon_{22} \end{pmatrix}$$

con:

$$\theta_1 = \mu + \alpha_1 + \beta_1$$

$$\theta_2 = \beta_2 - \beta_1$$

$$\theta_3 = \alpha_2 - \alpha_1$$

Como reparametrizar un ML con rango incompleto

Como encontrar W

- Uso de variables dummy o indicadoras
- Uso de modelo de celdas medias de Hoking
- Uso de restricciones
- Matriz escalonada y Rango.

Ejemplo:

Considere los siguientes datos de un modelo dos vías de clasificación no balanceado en el que las ratas fueron alimentadas con dietas que diferían en el factor A, **nivel de proteína** (alto y bajo), y factor B, **tipo de alimento** (carne de res, cereal, cerdo). La respuesta es el **incremento en peso** (y)

High Protein			Low Protein		
Beef	Cereal	Pork	Beef	Cereal	Pork
73	98	94	90	107	49
102	74	79	76	95	82
	56		90		

Modelo:

$$y_{ijk} = \mu + \tau_i + \beta_j + \epsilon_{ijk}$$

,

Donde:

Y_{ijk} es el peso, μ es el efecto de la media general, τ_i es el efecto de la i – *esimo* nivel de proteína, β_j es el efecto debido a la j – *esimo* tipo de alimento. ϵ_{ij} es el termino de error aleatorio.

Ejemplo: Datos de ratones

Datos de ratones

Prot	Tipo	Peso
H	B	73
H	B	102
H	C	98
H	C	74
H	C	56
H	P	94
H	P	79
L	B	90
L	B	76
L	B	90
L	C	107
L	C	95
L	P	49
L	P	82

Matrix Diseño (X)

(Intercept)	ProtH	ProtL	TipoB	TipoC	TipoP
1	1	0	1	0	0
1	1	0	1	0	0
1	1	0	0	1	0
1	1	0	0	1	0
1	1	0	0	1	0
1	1	0	0	0	1
1	1	0	0	0	1
1	1	0	0	0	1
1	0	1	1	0	0
1	0	1	1	0	0
1	0	1	0	1	0
1	0	1	0	1	0
1	0	1	0	0	1
1	0	1	0	0	1

Rango (X)

[1] 4

Ejemplo: Datos de ratones

Datos de ratones

Prot	Tipo	Peso
H	B	73
H	B	102
H	C	98
H	C	74
H	C	56
H	P	94
H	P	79
L	B	90
L	B	76
L	B	90
L	C	107
L	C	95
L	P	49
L	P	82

El numero de variables dummy de cada factor es Numero de niveles – 1

Variables Dummy Proteina

Niveles Prot	Dummy DP
H	0
L	1

variables Dummy Fuente

Fuente	DF1	DF2
B	0	0
C	1	0
P	0	1

Tabla con variables dummy

<i>Resp</i>	<i>Prot</i>	<i>Tipo</i>	<i>DP</i>	<i>DF1</i>	<i>DF2</i>
73	<i>H</i>	<i>B</i>	0	0	0
102	<i>H</i>	<i>B</i>	0	0	0
98	<i>H</i>	<i>C</i>	0	1	0
74	<i>H</i>	<i>C</i>	0	1	0
56	<i>H</i>	<i>C</i>	0	1	0
94	<i>H</i>	<i>P</i>	0	0	1
79	<i>H</i>	<i>P</i>	0	0	1
90	<i>L</i>	<i>B</i>	1	0	0
76	<i>L</i>	<i>B</i>	1	0	0
90	<i>L</i>	<i>B</i>	1	0	0
107	<i>L</i>	<i>C</i>	1	1	0
95	<i>L</i>	<i>C</i>	1	1	0
49	<i>L</i>	<i>P</i>	1	0	1
82	<i>L</i>	<i>P</i>	1	0	1

Ejemplo: Datos de ratones

Modelo reparametrizado:

$$y_i = \theta_0 + \theta_1 DP_i + \theta_2 FP1_i + \theta_3 FP2_i + \epsilon_i$$

$$y = W\theta + \epsilon$$
$$\begin{pmatrix} 73 \\ 102 \\ 98 \\ 74 \\ 56 \\ 94 \\ 79 \\ 90 \\ 76 \\ 90 \\ 107 \\ 95 \\ 49 \\ 82 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \\ \epsilon_4 \\ \epsilon_5 \\ \epsilon_6 \\ \epsilon_7 \\ \epsilon_8 \\ \epsilon_9 \\ \epsilon_{10} \\ \epsilon_{11} \\ \epsilon_{12} \\ \epsilon_{13} \\ \epsilon_{14} \end{pmatrix}$$

Reparametrización Dummy en R

```
ratones <- read.csv("ratones.csv")
modelo_anova=lm(Peso~Prot+Tipo, ratones)
M_X2=as.matrix(model.matrix(modelo_anova));M_X2
```

Obtenida antes usando Dummy

(Intercept)	ProtL	TipoC	TipoP
1	0	0	0
1	0	0	0
1	0	1	0
1	0	1	0
1	0	1	0
1	0	0	1
1	0	0	1
1	1	0	0
1	1	0	0
1	1	1	0
1	1	1	0
1	1	0	1
1	1	0	1

1	0	0	0
1	0	0	0
1	0	1	0
1	0	1	0
1	0	1	0
1	0	0	1
1	0	0	1
1	1	0	0
1	1	0	0
1	1	0	0
1	1	1	0
1	1	1	0
1	1	0	1
1	1	0	1

Reparametrizacion Dummy en R

```
ratones <- read.csv("ratones.csv")
modelo_anova=lm(Peso~Prot+Tipo, ratones)
summary(modelo_anova)
```

```
##
## Call:
## lm(formula = Peso ~ Prot + Tipo, data = ratones)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -29.247 -11.174   3.494  11.532  19.871
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   85.0706    10.1269   8.400 7.66e-06 ***
## ProtL         1.8824     9.9303   0.190  0.853
## TipoC         0.1765    11.7497   0.015  0.988
## TipoP        -10.0118    12.3231  -0.812  0.435
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 18.31 on 10 degrees of freedom
## Multiple R-squared:  0.08303,    Adjusted R-squared:  -0.1921
## F-statistic: 0.3018 on 3 and 10 DF,  p-value: 0.8235
```


Solucion de EN en el modelo $y = W\theta + \epsilon$

```
ratones <- read.csv("ratones.csv")
modelo_anova=lm(Peso~Prot+Tipo, ratones)
W=as.matrix(model.matrix(modelo_anova))
library(matlib)
Y=as.matrix(ratones$Peso)
theta=Inverse(t(W)%*%W)%*%t(W)%*%Y
theta
```

```
##           [,1]
## [1,]  85.0705824
## [2,]   1.8823514
## [3,]   0.1764691
## [4,] -10.0117690
```

Los parametros θ en terminos del modelo original

Note que si

$$W\theta = X\beta$$

$$(W^t W)^{-1} W^t W \theta = (W^t W)^{-1} W^t X \beta$$

$$\theta = (W^t W)^{-1} W^t X \beta$$

$$\begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 1 & 0 & 0 \\ 0 & -1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & -1 & 1 & 0 \\ 0 & 0 & 0 & -1 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} = \begin{pmatrix} \mu + \tau_1 + \beta_1 \\ \tau_2 - \tau_1 \\ \beta_2 - \beta_1 \\ \beta_3 - \beta_1 \end{pmatrix}$$

Los parametros θ en terminos del modelo original

```
ratones <- read.csv("ratones.csv")
modelo_anova=lm(Peso~Prot+Tipo,ratones)
W=as.matrix(model.matrix(modelo_anova))
library(sasLM)
X1=ModelMatrix(Peso~Prot+Tipo,ratones, KeepOrder=TRUE)
X1=as.matrix(X1$X); library(matlib)
as.matrix(round(Inverse(t(W)%*%W)%*%t(W)%*%X1))
```

```
##      (Intercept) ProtH ProtL TipoB TipoC TipoP
## [1,]           1      1      0      1      0      0
## [2,]           0     -1      1      0      0      0
## [3,]           0      0      0     -1      1      0
## [4,]           0      0      0     -1      0      1
```

$$\begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 1 & 0 & 0 \\ 0 & -1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & -1 & 1 & 0 \\ 0 & 0 & 0 & -1 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} = \begin{pmatrix} \mu + \tau_1 + \beta_1 \\ \tau_2 - \tau_1 \\ \beta_2 - \beta_1 \\ \beta_3 - \beta_1 \end{pmatrix} = \begin{pmatrix} 85.07 \\ 1.88 \\ 0.17 \\ -10.01 \end{pmatrix}$$

Ejemplo 2

<i>obs</i>	<i>Factor A</i>	<i>dummyA₁</i>	<i>dummyA₂</i>
2	<i>G1</i>	0	0
3	<i>G1</i>	0	0
4	<i>G1</i>	0	0
6	<i>G2</i>	1	0
7	<i>G2</i>	1	0
8	<i>G2</i>	1	0
10	<i>G3</i>	0	1
11	<i>G3</i>	0	1
12	<i>G3</i>	0	1

Ejercicio Clase

Regression of Income on Education and Racial–Ethnic Group For a sample of adult Americans aged over 25, Table 13.1 shows y = annual income (thousands of dollars), x = number of years of education (where 12 = high school graduate, 16 = college graduate), and z = racial–ethnic group (black, Hispanic, white). The data exhibit patterns of a much larger sample taken by the U.S. Bureau of the Census. The sample contains $n_1 = 16$ blacks, $n_2 = 14$ Hispanics, and $n_3 = 50$ whites, for a total sample size of $N = 80$. (*Alan Agresti, 2018, Statistical Methods For The Social Sciences Edition: 5th, Pearson Education pag 402*)

TABLE 13.1: Observations on y = Annual Income (in Thousands of Dollars) and x = Number of Years of Education, for Three Racial–Ethnic Groups									
Black		Hispanic		White		White		White	
y	x	y	x	y	x	y	x	y	x
16	10	32	16	30	14	62	16	50	16
18	7	16	11	48	14	24	10	50	14
26	9	20	10	40	7	50	13	22	11
16	11	58	16	84	18	32	10	26	12
34	14	30	12	50	10	34	16	46	16
22	12	26	10	38	12	52	18	22	9
42	16	20	8	30	12	24	12	24	9
42	16	40	12	76	16	22	14	64	14
16	9	32	10	48	16	20	13	28	12
20	10	22	11	36	11	30	14	32	12
66	16	20	10	40	11	24	13	38	14
26	12	56	14	44	12	120	18	44	12
20	10	32	12	30	10	22	10	22	12
30	15	30	11	60	15	82	16	18	10
20	10			24	9	18	12	24	12
30	19			88	17	26	12	56	20
				46	16	104	14		

Usando modelos de celdas medias

Considere el modelo:

$$Y_{ij} = \mu_i + \epsilon_{ij}$$

donde:

- $\mu_i; i = 1, 2, \dots, T$, son las medias de los niveles de los factores. Note que en este modelo, no se ajusta la media general.
- ϵ_{ij} Son los errores aleatorios.

El modelo de medias de celda no se ajusta la media general, sino que se ajusta a una media individual para cada uno de los niveles de tratamiento.

Ejemplo: Datos de invernadero

un Agronomo estudia si la *altura de la planta* puede verse afectada por la aplicación de diferentes *fertilizantes*. Las plantas se ponen en condiciones controladas de invernadero bajo diferentes tipos de Fertilizante. Al final del experimento, se midió la altura de cada planta.

<i>Fert</i>	<i>Height</i>
Control	21
Control	19.5
Control	22.5
Control	21.5
Control	20.5
Control	21
F1	32
F1	30.5
F1	25
F1	27.5
F1	28
F1	28.6
F2	22.5
F2	26
F2	28
F2	27
F2	26.5
F2	25.2
F3	28
F3	27.5
F3	31
F3	29.5
F3	30
F3	29.2

$$Y_{ij} = \mu_i + \epsilon_{ij}$$

- Y_{ij} es la altura de la planta bajo i-esimo trat en la replica j.
- $\mu_i; i = 1, 2, \dots, 4$, son las medias de los de cada tipo de fertilizante.
- ϵ_{ij} Son los errores aleatorios.

Modelo celdas medias forma matricial

$$Y = W\theta + \epsilon$$

$$\begin{pmatrix} y_{11} \\ y_{12} \\ y_{13} \\ y_{14} \\ y_{15} \\ y_{16} \\ y_{21} \\ y_{22} \\ y_{23} \\ y_{24} \\ y_{25} \\ y_{26} \\ y_{31} \\ y_{32} \\ y_{33} \\ y_{34} \\ y_{35} \\ y_{36} \\ y_{41} \\ y_{42} \\ y_{43} \\ y_{44} \\ y_{45} \\ y_{46} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \mu_4 \end{pmatrix} + \begin{pmatrix} \epsilon_{11} \\ \epsilon_{12} \\ \epsilon_{13} \\ \epsilon_{14} \\ \epsilon_{15} \\ \epsilon_{16} \\ \epsilon_{21} \\ \epsilon_{22} \\ \epsilon_{23} \\ \epsilon_{24} \\ \epsilon_{25} \\ \epsilon_{26} \\ \epsilon_{31} \\ \epsilon_{32} \\ \epsilon_{33} \\ \epsilon_{34} \\ \epsilon_{35} \\ \epsilon_{36} \\ \epsilon_{41} \\ \epsilon_{42} \\ \epsilon_{43} \\ \epsilon_{44} \\ \epsilon_{45} \\ \epsilon_{46} \end{pmatrix}$$

$$R(W) = 4$$

Celdas medias en R

```
fert <- read.csv("fert.csv")
modelo_anovaf=lm(Height~0+Fert,fert)
Wf=as.matrix(model.matrix(modelo_anovaf))
Wf
```

	##	FertControl	FertF1	FertF2	FertF3
	## 1	1	0	0	0
	## 2	1	0	0	0
	## 3	1	0	0	0
	## 4	1	0	0	0
	## 5	1	0	0	0
	## 6	1	0	0	0
	## 7	0	1	0	0
	## 8	0	1	0	0
	## 9	0	1	0	0
	## 10	0	1	0	0
	## 11	0	1	0	0
	## 12	0	1	0	0
	## 13	0	0	1	0
	## 14	0	0	1	0
	## 15	0	0	1	0
	## 16	0	0	1	0
	## 17	0	0	1	0
	## 18	0	0	1	0
	## 19	0	0	0	1
	## 20	0	0	0	1
	## 21	0	0	0	1
	## 22	0	0	0	1
	## 23	0	0	0	1
	## 24	0	0	0	1

Celdas medias en R

```
fert <- read.csv("fert.csv")
modelo_anovaf=lm(Height~0+Fert,fert)
summary(modelo_anovaf)
```

```
##
## Call:
## lm(formula = Height ~ 0 + Fert, data = fert)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.6000 -0.7750  0.0000  0.8833  3.4000
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## FertControl    21.0000     0.7132   29.45  <2e-16 ***
## FertF1         28.6000     0.7132   40.10  <2e-16 ***
## FertF2         25.8667     0.7132   36.27  <2e-16 ***
## FertF3         29.2000     0.7132   40.94  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.747 on 20 degrees of freedom
## Multiple R-squared:  0.9964,    Adjusted R-squared:  0.9956
## F-statistic: 1367 on 4 and 20 DF,  p-value: < 2.2e-16
```

Ejemplo: Datos de Farmacos

Los investigadores estaban interesados en estudiar los efectos de 2 **dietas** (bajo en fibra, alto en fibra) y 3 **fármacos** (D1, D2, D3) sobre el peso de cerdos Yorkshire. Un total de 12 cerdos fueron asignados a los 6 Combinaciones de dieta × medicamentos usando diseño experimental completamente aleatorizado. Los cerdos se alojaron en corrales individuales, se inyectaron con sus medicamentos asignados una vez por semana, y alimentados con sus dietas asignadas por un período de 6 semanas. la ganancia en peso durante el período de 6 semanas se registró para cada cerdo.

##	diet	drug	weightgain
## 1	1	1	41.3
## 2	1	1	43.7
## 3	1	2	40.9
## 4	1	2	39.2
## 5	1	3	37.4
## 6	1	3	37.9
## 7	2	1	36.8
## 8	2	1	34.6
## 9	2	2	33.6
## 10	2	2	34.3
## 11	2	3	35.8
## 12	2	3	35.1

Modelo de celdas medias (factorial)

$$Y_{ijk} = \mu_{ij} + \epsilon_{ijk}$$

- Y_{ijk} es la ganancia en peso bajo i-esima dieta en la j-esima droga y en la replica j.
- $\mu_i; i = 1, 2, \dots, 4$, son las medias bajo i-esima dieta en la j-esima droga.
- ϵ_{ijk} Son los errores aleatorios.

Matriz W datos cerdos

```
drogas <- read.csv("drogas.csv")
drogas$diet=factor(drogas$diet)
drogas$drug=factor(drogas$drug)
anova_cerdos=lm(weightgain~0+drug:diet,data=dro
# X matrix:
as.matrix(model.matrix(anova_cerdos))
```

```
##      drug1:diet1 drug2:diet1 drug3:diet1 drug1:diet2 drug2:diet2 drug3:diet2
## 1           1           0           0           0           0           0
## 2           1           0           0           0           0           0
## 3           0           1           0           0           0           0
## 4           0           1           0           0           0           0
## 5           0           0           1           0           0           0
## 6           0           0           1           0           0           0
## 7           0           0           0           1           0           0
## 8           0           0           0           1           0           0
## 9           0           0           0           0           1           0
## 10          0           0           0           0           1           0
## 11          0           0           0           0           0           1
## 12          0           0           0           0           0           1
## attr(,"assign")
## [1] 1 1 1 1 1 1
## attr(,"contrasts")
```

Matriz W datos cerdos

```
drogas <- read.csv("drogas.csv")
drogas$diet=factor(drogas$diet)
drogas$drug=factor(drogas$drug)
anova_cerdos=lm(weightgain~0+drug:diet,data=drogas)
library(sjPlot)
library(sjmisc)
library(sjlabelled)

tab_model(anova_cerdos)
```

weightgain			
Predictors	Estimates	CI	p
drug [1] × diet1	42.50	40.58 – 44.42	<0.001
drug [2] × diet1	40.05	38.13 – 41.97	<0.001
drug [3] × diet1	37.65	35.73 – 39.57	<0.001
drug [1] × diet2	35.70	33.78 – 37.62	<0.001
drug [2] × diet2	33.95	32.03 – 35.87	<0.001
drug [3] × diet2	35.45	33.53 – 37.37	<0.001
Observations	12		
R ² / R ²	1.000 / 0.999		

Encontrar W usando restricciones

Considere datos de ratones

High Protein			Low Protein		
Beef	Cereal	Pork	Beef	Cereal	Pork
73	98	94	90	107	49
102	74	79	76	95	82
	56		90		

Modelo:

$$y_{ijk} = \mu + \tau_i + \beta_j + \epsilon_{ijk}$$

,

Donde: Y_{ijk} es el peso , μ es el efecto de la media general, τ_i es el efecto de la i – *esimo* nivel de proteina, β_j es el efecto debido a la j – *esimo* tipo de alimento. ϵ_{ij} es el termino de error aleatorio.

Suponga que agregamos restricciones:

$$\sum_i \tau_i = 0$$

$$\sum_j \beta_j = 0$$

Encontrar W usando restricciones

Si agregamos las restricciones para que usemos el modelo de rango completo

$$\beta^t = (\mu, \tau_1, \tau_2, \beta_1, \beta_2, \beta_3)$$

$$\tau_1 = -\tau_2$$

$$\beta_3 = -\beta_1 - \beta_2$$

$$\beta_e^t = (\mu, \tau_1, -\tau_1, \beta_1, \beta_2, -\beta_1 - \beta_2)$$

$$\begin{pmatrix} \mu \\ \tau_1 \\ -\tau_1 \\ \beta_1 \\ \beta_2 \\ -\beta_1 - \beta_2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & -1 & -1 \end{pmatrix} \begin{pmatrix} \mu \\ \tau_1 \\ \beta_1 \\ \beta_2 \end{pmatrix}$$

$$\beta_e^t = F\theta$$

Encontrar W usando restricciones

$$XF = W$$

$$\begin{pmatrix} 1 & 1 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & -1 & -1 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & -1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & 1 & 0 \\ 1 & -1 & 1 & 0 \\ 1 & -1 & 1 & 0 \\ 1 & -1 & 0 & 1 \\ 1 & -1 & 0 & 1 \\ 1 & -1 & -1 & -1 \\ 1 & -1 & -1 & -1 \end{pmatrix}$$

Encontrar W usando Rango

- Elimine calcule $R(X)$
- Elimine columnas de X hasta que el rango no baje de $R(X)$
- La matriz resultante es W