

Notas del curso de modelo lineal

Estimabilidad en el modelo lineal

Humberto Vaquera Huerta
2024

Estimabilidad: Rango Incompleto

Identificabilidad y Estimabilidad

Un tema fundamental en la teoría de modelos lineales es descubrir qué parámetros pueden estimarse y cuales no.

- Lo que se puede estimar son funciones de los parámetros que son **identificables**. Las funciones lineales de los parámetros que son identificables son llamadas **estimables** y tienen estimadores lineales insesgados.

La **identificabilidad** es una propiedad de los parámetros en los modelos estadísticos. Es importante saber qué parámetros que podemos estimar a partir de los datos y qué parámetros no se pueden estimar a partir de los datos.

Identificabilidad

La idea es estudiar el mapeo entre parámetros y modelos estadísticos.

Queremos saber si el mapeo es uno a uno.

- Para entender por qué, supongamos que θ es un parámetro y $P(x; \theta)$ es un modelo estadístico (una distribución de probabilidad). Claramente si $\theta_1 = \theta_2$, entonces $P(x; \theta_1) = P(x; \theta_2)$ para todo x .

Sin embargo, si existe algún $\theta_1 \neq \theta_2$ pero $P(x; \theta_1) = P(x; \theta_2)$, entonces los datos distribuidos según $P(\cdot; \theta_1)$ tendrán la misma distribución que los datos distribuidos según $P(\cdot; \theta_2)$. Por lo tanto, es imposible detectar, a partir de los datos, si el parámetro de la distribución subyacente es θ_1 o θ_2 . Entonces, en tales modelos no siempre es posible estimar el parámetro θ .

Identificabilidad en el modelo lineal

Los modelos lineales son particularmente simples: para que β sea **identificable** basta que el parámetro de la media $\mu(\beta) = E(Y) = X\beta$ es una función uno a uno de β . Esto es cierto siempre que $Cov(\epsilon) = \Sigma$ para matrix alguna simétrica positiva semidefinida Σ (¡que no depende de β !).

- El concepto **identificabilidad** evalúa la capacidad de distinguir si dos vectores de parámetros, digamos β_1 y β_2 . Dado el experimento con matriz de diseño X , no podemos distinguir β_1 y β_2 si $X\beta_1 = X\beta_2$, ya que los dos vectores de parámetros dan la misma media para el vector de respuesta y .

En el modelo ANOVA unidireccional, observe que

$$E(y_{ij}) = \mu + \alpha_i = (\mu + c) + (\alpha_i - c),$$

para todo c , por lo que diferentes valores de parámetros darán la misma distribución para y . En este caso, ni μ ni α_i son identificables, aunque la suma $\mu + \alpha_i$ es **identificable**.

- La **estimabilidad de una función de los parámetros** corresponde a la existencia de un estimador lineal insesgado para él. En este libro, nos centraremos principalmente en el concepto de estimabilidad.

Identificabilidad

Definición: Identificabilidad de β en el modelo lineal: El parámetro β es **identificable** si $\forall \beta_1, \beta_2$ tal que $\mu(\beta_1) = \mu(\beta_2)$ debe ser cierto que $\beta_1 = \beta_2$.

- Si X es de rango completo, β es identificable. Si β_1 y β_2 satisfacen $X\beta_1 = X\beta_2$, entonces $X(\beta_1 - \beta_2) = 0$. Por lo tanto $\beta_1 - \beta_2 \in K(X)$. Pero X rango completo significa $K(X) = \{0\}$. Por lo tanto, $\beta_1 - \beta_2 = 0$, es decir, $\beta_1 = \beta_2$.
- Si X no es de rango completo, β no es identificable. Si X no tiene rango completo entonces existe $k \in K(X)$ con $k \neq 0$. Elija un parámetro β_1 . Con $\beta_2 = \beta_1 + k$. Entonces: $X\beta_2 = X(\beta_1 + k) = X\beta_1 + Xk = X\beta_1$
: Pero $\beta_1 \neq \beta_2$.

Funciones identificables de β

Si bien β en sí puede no ser identificable, hay funciones de β que son identificables (es decir, determinadas por el parámetro de la media $X\beta$, en correspondencia uno a uno con $X\beta$, etc.). $\forall \beta$

Definición (funciones identificables de β): Decimos que $g(\beta)$ es una función identificable de β si $\forall \beta_1, \beta_2$, son tales que $\mu(\beta_1) = \mu(\beta_2)$, debemos tener $g(\beta_1) = g(\beta_2)$.

Teorema (caracterización de funciones identificables de β): $g(\beta)$ es una función identificable de β si y sólo si g depende de β sólo a través de $\mu(\beta)$, es decir, existe una función g_* tal que:

$$g(\beta) = g_*(\mu(\beta)) = g_*(X\beta) :$$

Funciones identificables de β

El parámetro β es identificable si para cualquier β_1 y β_2 , $f(\beta_1) = f(\beta_2)$ implica $\beta_1 = \beta_2$. Si β es identificable, decimos que la parametrización $f(\beta)$ es. Además, una función de valor vectorial $g(\beta)$ es identificable si $f(\beta_1) = f(\beta_2)$ implica $g(\beta_1) = g(\beta_2)$. Si la parametrización no es identificable pero existen funciones identificables no triviales, entonces se dice que la parametrización es parcialmente identificable.

En modelos de regresión, i.e., modelos de *rango completo* $r(X) = p$, Los parámetros **son identificables**.

En este caso, $(X^t X)$ es no singular, por lo que $X\beta_1 = X\beta_2$, entonces $\beta_1 = (X^t X)^{-1} X^t X \beta_1 = (X^t X)^{-1} X^t X \beta_2 = \beta_2$

Para los modelos de *rango incompleto* en los que $r(X) = r < p$, existen $\beta_1 \neq \beta_2$ pero $X\beta_1 = X\beta_2$, entonces

Los parámetros **no son identificables**. Para modelos lineales, las únicas funciones de los parámetros que son identificables son funciones de $X\beta$. Esto se deduce del siguiente resultado.

Teorema: Una función $g(\beta)$ es identificable si solo si $g(\beta)$ es una función de $f(\beta)$

Conexión entre identificabilidad y estimación de mínimos cuadrados.

- Si X es de rango completo, $X^t X$ es invertible y $\beta_{mco} = (X^t X)^{-1} (X^t Y)$ es la estimación única de mínimos cuadrados del parámetro identificable β ; $g(\beta_{mco})$ es el único estimador de mínimo de cuadrados de $g(\beta)$ para cualquier función g .
- Si X no tiene el rango completo, no existe una estimación única de mínimos cuadrados: ¿cuál deberíamos usar para estimar? ¿beta? Además, el parámetro β no es identificable, por lo que ni siquiera está claro qué parámetro es al menos ¡La solución de mínimos cuadrados $g(\beta_{mco})$ que estaría estimando! Sin embargo, si β_1 y β_2 son dos estimaciones de mínimos cuadrados, entonces $X\beta_1, X\beta_2$. Por lo tanto, las funciones identificables de β tienen soluciones únicas de mínimos cuadrados únicas. De hecho, si $g(\beta) = g_*(X\beta)$, entonces, para cualquier estimación de mínimos cuadrados, β_{mco} , $g(\beta_{mco}) = g_*(X\beta_{mco})$ es la estimación única de mínimos cuadrados de $g(\beta)$.

Conexión entre identificabilidad y estimación de mínimos cuadrados.

- Existe un proceso inverso para funciones lineales de β , es decir, $g(\beta) = \lambda^t \beta$ para un conjunto de pesos λ . Si β_1 y β_2 LS son dos estimaciones de mínimos cuadrados que satisfacen $\lambda^t \beta_1, \lambda^t \beta_2$, entonces $\lambda = X^T \rho$ para algún conjunto de pesos ρ . Es decir, $g(\beta) = \lambda^t \beta = \rho^t X \beta = g_*(X\beta)$, por lo que g es una función lineal identificable de β

Estimabilidad y Estimacion por Mínimos Cuadrados

El objetivo principal es determinar si ciertas funciones de los parámetros son estimables, y construir estimadores insesgados para ellos.

Definición: Un estimador $t(y)$ es un estimador insesgado para el escalar $\lambda^t \beta$ si solo si $E(t(y)) = \lambda^t \beta$ para todo β .

Definición: Un estimador $t(y)$ es un estimador lineal en y si solo si $t(y) = c + a^t y$ para constantes $c, a_1, \dots, a_N$.

Definición: Una función $\lambda^t \beta$ es linealmente estimable si solo si existe un estimador insesgado para este. Si tal estimador no existe, entonces se dice que no es estimable.

Resultado: Bajo el modelo de media lineal, $\lambda^t \beta$ es linealmente estimable si solo si existe un vector tal que $E(t(y)) = \lambda^t \beta$ para todo β , o $\lambda^t = a^t X$ o $\lambda = X^t a$

Estimabilidad y Estimación por Mínimos Cuadrados

Es razonable **estimar** cualquier función **identificable**. Por lo tanto, en un modelo lineal es razonable estimar cualquier función de $X\beta$. No es razonable estimar funciones no identificables, porque simplemente no se sabe lo que se está estimando. La idea tradicional de estimabilidad en modelos lineales. Las funciones estimadas son funciones lineales de β que son identificables.

Definición. Una función lineal vectorial β , digamos, $\lambda^t\beta$, es estimable si $(\lambda^t\beta = P^tX\beta)$ para alguna matriz P).

Si las funciones no estimables son lineales, la no estimación y la no identificabilidad se vuelve equivalente. Esto cambia en el caso de funciones no lineales.

Definición. Se dice que una función lineal de los parámetros $\lambda^t\beta$ es estimable si existe una combinación lineal de las observaciones con un valor esperado igual a $\lambda^t\beta$, es decir, $\lambda^t\beta$ es estimable si existe un vector a tal que $E(a^ty) = \lambda^t\beta$.

Papers a revisar para repaso y demostraciones alternas

- R. K. Elswick Jr. , Chris Gennings , Vernon M. Chinchilli & Kathryn S. Dawson (1991) **A Simple Approach for Finding Estimable Functions in Linear Models**, The American Statistician, 45:1, 51-53, DOI: 10.1080/00031305.1991.10475766
- Stratis Kounias, Miltiadis Chalikias, **Estimability of parameters in a linear model and related characterizations**, Statistics & Probability Letters, Volume 78, Issue 15, 2008, Pages 2437-2439, ISSN 0167-7152, <https://doi.org/10.1016/j.spl.2008.02.019>.

Estimabilidad

Ejemplo: Anova Considere el modelo

$$y_{ij} = \mu + \alpha_i + \epsilon_{ij}$$

, con $i = 1, \dots, 3, j = 1, \dots, n_i, (n_1, n_2, n_3) = (3, 1, 2)$, donde los ϵ_{ij} son independientes $N(0, \sigma^2)$.

En forma matricial

$$\begin{array}{c} \begin{bmatrix} y_{11} \\ y_{12} \\ y_{13} \\ y_{21} \\ y_{31} \\ y_{32} \end{bmatrix} \\ Y \end{array} = \begin{array}{c} \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \end{bmatrix} \\ X \end{array} \begin{array}{c} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} \\ \beta \end{array} + \begin{array}{c} \begin{bmatrix} e_{11} \\ e_{12} \\ e_{13} \\ e_{21} \\ e_{31} \\ e_{32} \end{bmatrix} \\ e. \end{array}$$

Note que:

$$\begin{pmatrix} \mu + \alpha_1 \\ \mu + \alpha_1 \\ \mu + \alpha_1 \\ \mu + \alpha_2 \\ \mu + \alpha_3 \\ \mu + \alpha_3 \end{pmatrix}$$

Ejemplo

Usando la definición $\lambda^t \beta$ es estimable si existe un vector a tal que $E(a^t y) = \lambda^t \beta$.

Queremos investigar si la función $\lambda^t \beta = \alpha_1 - \alpha_2$ es estimable !

note que con $a^t = (1, 0, 0, -1, 0, 0)$

$$E(a^t y) = a^t E(y) = a^t X \beta$$

$$E(a^t y) = (1, 0, 0, -1, 0, 0) \begin{pmatrix} \mu + \alpha_1 \\ \mu + \alpha_1 \\ \mu + \alpha_1 \\ \mu + \alpha_2 \\ \mu + \alpha_3 \\ \mu + \alpha_3 \end{pmatrix} = \mu + \alpha_1 - \mu - \alpha_2 = \alpha_1 - \alpha_2$$

Estimabilidad

Ejemplo 1:

Podemos estimar la función de parámetros $\lambda_1^t \beta = \mu + \alpha_1$?.

Si elegimos un vector $P_1^t = (1, 0, 0, 0, 0, 0)$

note que

$$\lambda_1^t \beta = P_1^t X \beta$$

si es estimable $\mu + \alpha_1$:

$$(1, 0, 0, 0, 0, 0) \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} = \mu + \alpha_1,$$

Estimabilidad

Ejemplo 2:

Podemos estimar la función de parámetros $\lambda_2^t \beta = \alpha_1 - \alpha_3$?.

Si elegimos un vector $P_2^t = (1, 0, 0, 0, -1, 0)$ note que $\lambda_2^t \beta = P_2^t X \beta$

Si es estimable $\lambda_2^t \beta = \alpha_1 - \alpha_3$:

$$(1, 0, 0, 0, -1, 0) \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} = \alpha_1 - \alpha_3,$$

Estimabilidad

Ejemplo 3:

Podemos estimar la función de parámetros $\lambda_3^t \beta = \alpha_1 + \alpha_2 - 2\alpha_3$?. Si elegimos un vector

$P_3 = (1, 0, 0, 1, -2, 0)$ note que $\lambda_3^t \beta = P_3^t X \beta$

Si es estimable $\lambda_2^t \beta = \alpha_1 + \alpha_2 - 2\alpha_3$:

$$(1, 0, 0, 1, -2, 0) \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} = \alpha_1 + \alpha_2 - 2\alpha_3.$$

Estimabilidad en el Modelo Lineal

- Caso Rango Completo

Si X es de rango completo entonces β *es estimable* y **todas** las funciones $\lambda^t \beta$ son estimables

- Caso Rango Incompleto

Si X es de rango incompleto entonces β *no es estimable* y **no todas** las funciones $\lambda^t \beta$ son estimables

Formas de investigar que funciones $\lambda^t \beta$ son estimables

- **Método 1.** Las combinaciones lineales de los valores esperados de las observaciones son estimables si podemos expresar $\lambda^t \beta$ como una combinación lineal de $E(y_i)$, entonces $\lambda^t \beta$ es estimable.
- **Método 2.** Si $\lambda \in \mathcal{C}(X^t)$ entonces $\lambda^t \beta$ es estimable. Entonces construya un conjunto de vectores base para $\mathcal{C}(X^t)$, digamos $(v^{(1)}, v^{(2)}, \dots, v^{(r)})$, y encuentre las constantes d_j de modo que $\lambda = \sum_j d_j v^{(j)}$.
- **Método 3.** Tenga en cuenta que $\lambda \in \mathcal{C}(X^t)$ si y solo si $\lambda \perp \mathcal{N}(X^t)$. Así que se encuentra una base para $\mathcal{N}(X^t)$ digamos $(c^{(1)}, c^{(2)}, \dots, c^{(p-r)})$. Entonces si $\lambda \perp c^{(j)}$ para todo $j = 1, \dots, p - r$, entonces $\lambda \in \mathcal{C}(X^t)$ y $\lambda^t \beta$ es estimable.

Usando el Metodo 3

Suponga tenemos la Matrix diseño X y el vector de parametros β

$$X = \begin{pmatrix} 1 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \end{pmatrix}, \quad \beta = \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \beta_1 \\ \beta_2 \end{pmatrix}.$$

```
X <- matrix(c(1, 1, 0,1,0,
              1, 1, 0,0,1,
              1, 0, 1,1,0,
              1, 0, 1,0,1), 4, 5, byrow=TRUE)
```

```
library(pracma)
## NullSpace
X_n <- nullspace(X)
lambdat=c(0,1,-1,0,0)
round(lambdat*%X_n)
```

```
##      [,1] [,2]
## [1,]    0    0
```

Si es estimable $\lambda^t \beta = \alpha_1 - \alpha_2$ ya que $\lambda^t = (0, 1, -1, 0, 0) \perp \mathcal{N}(X)$

problema del Metodo 3..hav que calcular espacios nulos de matrices...

Formas practicas de estudiar que funciones $\lambda^t\beta$ son estimables

- Si tenemos que X es de rango incompleto y tenemos una inversa generalizada de (X^tX) es decir $(X^tX)^-$ podemos usar el siguiente resultado:

Teorema 1

Sea $Y = X\beta + \epsilon$ un modelo lineal donde ϵ tiene media 0 y varianza σ^2I . Entonces $\lambda^t\beta$ es estimable si solo si hay una solución del sistema lineal $\lambda^t(X^tX)^-X^tX = \lambda^t$ para cualquier inversa generalizada $(X^tX)^-$.

Formas practicas de estudiar que funciones $\lambda^t\beta$ son estimables

- Si tenemos que X es de rango incompleto y tenemos el rango de X .

Teorema 2

Sea $Y = X\beta + \epsilon$ un modelo lineal donde ϵ tiene media 0 y varianza $\sigma^2 I$. Entonces $\lambda^t\beta$ es estimable si solo si λ^t pertenece al espacio de renglones de X o (X^tX) .

Ejemplo: Verificar si $\lambda^t \beta = \alpha_3 - \alpha_1$ es estimable

Ejemplo: Anova Considere el modelo

$$y_{ij} = \mu + \alpha_i + \epsilon_{ij}$$

$$\begin{bmatrix} y_{11} \\ y_{12} \\ y_{13} \\ y_{21} \\ y_{31} \\ y_{32} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} + \begin{bmatrix} e_{11} \\ e_{12} \\ e_{13} \\ e_{21} \\ e_{31} \\ e_{32} \end{bmatrix}$$

$Y = X \beta + e.$

- Usando Inversa generalizada $(X^t X)^-$ **Queremos investigar si la función $\lambda^t \beta = \alpha_3 - \alpha_1$ es estimable**

debemos probar que $\lambda^t (X^t X)^- X^t X = \lambda^t$ para datos de ejemplo previo.

Ejemplo: Verificar si $\lambda^t \beta = \alpha_3 - \alpha_1$ es estimable

Teorema 1

Sea $Y = X\beta + \epsilon$ un modelo lineal donde ϵ tiene media 0 y varianza $\sigma^2 I$. Entonces $\lambda^t \beta$ es estimable si solo si hay una solución del sistema lineal $\lambda^t (X^t X)^- X^t X = \lambda^t$ para cualquier inversa generalizada $(X^t X)^-$.

Ejemplo de aplicación del **Teorema**, Es estimable

$$\alpha_3 - \alpha_1$$

? para datos de ejemplo previo.

$$X^t X = \begin{pmatrix} 6 & 3 & 1 & 2 \\ 3 & 3 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 2 & 0 & 0 & 2 \end{pmatrix}$$

$$\text{rango}(X) = 3$$

Ejemplo: Verificar si $\lambda^t \beta = \alpha_3 - \alpha_1$ es estimable

Es estimable $\alpha_3 - \alpha_1$? $(X^t X)^- =$

$$\begin{pmatrix} 1/2 & -1/2 & -1/2 & 0 \\ -1/2 & 5/6 & 1/2 & 0 \\ -1/2 & 1/2 & 3/2 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

Note que: $\lambda_1^t = (0, -1, 0, 1)$, $\beta = (\mu, \alpha_1, \alpha_2, \alpha_3)$, es decir $\lambda_1^t \beta = \alpha_3 - \alpha_1$

$$\lambda_1^t (X^t X)^- X^t X =$$

$$(0 \quad -1 \quad 0 \quad 1) \begin{pmatrix} 1/2 & -1/2 & -1/2 & 0 \\ -1/2 & 5/6 & 1/2 & 0 \\ -1/2 & 1/2 & 3/2 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 6 & 3 & 1 & 2 \\ 3 & 3 & 0 & 0 \\ 1 & 0 & 1 & 0 \end{pmatrix}$$

Ejemplo estimabilidad usando Rango

Teorema 2

Sea $Y = X\beta + \epsilon$ un modelo lineal donde ϵ tiene media 0 y varianza $\sigma^2 I$. Entonces $\lambda^t \beta$ es estimable si solo si λ^t pertenece al espacio de renglones de X o $(X^t X)$.

Si $R(X) = R(X^t X)$ es igual al rango de $R\begin{pmatrix} X \\ \lambda^t \end{pmatrix}$ entonces $\lambda^t \beta$ es estimable.

Ejemplo: $\lambda_1^t = (0, -1, 0, 1)$, $\beta = (\mu, \alpha_1, \alpha_2, \alpha_3)$ $\lambda_1^t \beta = \alpha_3 - \alpha_1$

$$R\begin{pmatrix} X \\ \lambda^t \end{pmatrix} = R \begin{pmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \end{pmatrix} = 3 = R(X)$$

Ejemplo 2

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \beta_1 \\ \beta_2 \end{pmatrix}.$$

Suponga tenemos la Matrix diseño X y el vector de parametros β

- $\lambda^t \beta = \alpha_1 - \alpha_2$ es estimable ?

Verificar si $\lambda^t \beta = \alpha_1 - \alpha_2$ es estimable en R

```
library(matlib)
X <- matrix(c(1, 1, 0, 1, 0,
              1, 1, 0, 0, 1,
              1, 0, 1, 1, 0,
              1, 0, 1, 0, 1), 4, 5, byrow=TRUE)
lambdat=c(0, 1, -1, 0, 0)
Ginv(t(X)%*%X)
```

```
##      [,1] [,2] [,3] [,4] [,5]
## [1,]  0.75 -0.5  0  -0.5  0
## [2,] -0.50  1.0  0   0.0  0
## [3,]  0.00  0.0  0   0.0  0
## [4,] -0.50  0.0  0   1.0  0
## [5,]  0.00  0.0  0   0.0  0
```

```
lambdat%*%Ginv(t(X)%*%X)%*%t(X)%*%X
```

```
##      [,1] [,2] [,3] [,4] [,5]
## [1,]    0    1  -1    0    0
```

Note que se prueba que $\lambda^t \beta = \alpha_1 - \alpha_2$ es estimable !

Verificar si $\lambda^t \beta = \alpha_1 - \alpha_2$ es estimable en R

```
library(matlib)
X <- matrix(c(1, 1, 0,1,0,
              1, 1, 0,0,1,
              1, 0, 1,1,0,
              1, 0, 1,0,1), 4, 5, byrow=TRUE)
R(X); lambdat=c(0,1,-1,0,0); X_aumentada=rbind(X,lambdat)
```

```
## [1] 3
```

X_aumentada

```
##      [,1] [,2] [,3] [,4] [,5]
##      1    1    0    1    0
##      1    1    0    0    1
##      1    0    1    1    0
##      1    0    1    0    1
## lambdat 0    1   -1    0    0
```

R(X_aumentada)

```
## [1] 3
```

Formas practicas de estudiar que funciones $\lambda^t \beta$

son estimables

Teorema 3

Sea $Y = X\beta + \epsilon$ un modelo lineal donde ϵ tiene media 0 y varianza $\sigma^2 I$. Entonces $\lambda^t \beta$ es estimable si solo si

$$\lambda^t [I - (X^t X)^- X^t X] = 0$$

Usando libreria *estimability* de R

```
library(estimability)
A <- matrix(c(1, 1, 0, 1, 0,
              1, 1, 0, 0, 1,
              1, 0, 1, 1, 0,
              1, 0, 1, 0, 1), 4, 5, byrow=TRUE)
N=nonest.basis(A)
round(N)
```

```
##      [,1] [,2]
## [1,]    0  -1
## [2,]   -1    0
## [3,]   -1    0
## [4,]    0    1
## [5,]    0    1
```

```
funciones=rbind(c(0, 1, -1, 0, 0))
is.estble(funciones, N)
```

```
## [1] TRUE
```

Como obtener conjuntos de funciones estimables linealmente independientes

- El numero de funciones estimables linealmente independientes es igual al $\text{rango}(X)$
- Existe un numero infinitos de conjuntos de funciones estimables linealmente independientes

Procedimientos simples

- Uso de matriz Echelon de X
- Uso de reparametrizacion con variables Dummy

Ejemplo: Matriz Echelon

```
library(matlib)
A <- matrix(c(1, 1, 0,1,0,
              1, 1, 0,0,1,
              1, 0, 1,1,0,
              1, 0, 1,0,1), 4, 5, byrow=TRUE)
echelon(A, verbose=F, fractions=TRUE)
```

```
##      [,1] [,2] [,3] [,4] [,5]
## [1,]  1   0   1   0   1
## [2,]  0   1  -1   0   0
## [3,]  0   0   0   1  -1
## [4,]  0   0   0   0   0
```

tenemos $R(X) = 3$, Usando Echelon obtenemos tres funciones lineales estimables independientes

$$\lambda^t \beta_1 = \mu + \alpha_2 + \beta_2 \lambda^t \beta_2 = \alpha_1 - \alpha_2 \lambda^t \beta_3 = \beta_1 - \beta_2$$

Ejercicio1 clase:

		<u>movie</u>		
		1	2	3
<u>customer</u>	1	4	1	?
	2	?	3	5
	3	?	?	3
	4	3	1	?

y_{ij} = customer i 's rating
of movie j

$$y_{ij} = \mu + c_i + m_j + \epsilon_{ij}$$

¿ Es estimable $m_2 - m_3$?

$$\begin{bmatrix} 4 \\ 1 \\ 3 \\ 5 \\ 3 \\ 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} \mu \\ c_1 \\ c_2 \\ c_3 \\ c_4 \\ m_1 \\ m_2 \\ m_3 \end{bmatrix} + \begin{bmatrix} \epsilon_{11} \\ \epsilon_{12} \\ \epsilon_{22} \\ \epsilon_{23} \\ \epsilon_{33} \\ \epsilon_{41} \\ \epsilon_{42} \end{bmatrix}$$

$$\mathbf{y} = \mathbf{X} \boldsymbol{\beta} + \boldsymbol{\epsilon}$$

Ejercicio 2 clase:

Del articulo:

- S. O. Adeyemo, F. N. Nwobi, A Note on Estimability in Linear Models, International Journal of Statistics and Applications, Vol. 4 No. 4, 2014, pp. 212-216. doi: 10.5923/j.statistics.20140404.06.

En el experimento, nueve variedades diferentes de Se probaron cultivos de yuca, seis a la vez en un máximo de cinco años de tal manera que estas variedades no fueron replicadas igualmente.

- <http://article.sapub.org/10.5923.j.statistics.20140404.06.html>

Rendimiento	Genotipos	Rendimiento	Genotipos	Rendimiento	Genotipos
36.6	1	28.33	3	12.7	6
37.9	1	31.6	4	6.22	6
21.49	1	15.1	4	4.41	6
23.8	2	15.13	4	2.99	6
8	2	33.7	5	13.42	7
0.29	2	9.4	5	9.84	7
41.9	3	7.07	5	19.85	8

Ejercicio 2 clase:

$$Y = X\beta + \epsilon$$

36.6

37.9

1 1 0 0 0 0 0 0 0 0

1 1 0 0 0 0 0 0 0 0

ϵ_{11}

ϵ_{12}

ϵ_{13}

Datos

(Intercept)	Genotipos1	Genotipos2	Genotipos3	Genotipos4	Genotipos5	Genotipos6	Genotipos7	Genotipos8	Genotipos9
1	1	0	0	0	0	0	0	0	0
1	1	0	0	0	0	0	0	0	0
1	1	0	0	0	0	0	0	0	0
1	0	1	0	0	0	0	0	0	0
1	0	1	0	0	0	0	0	0	0
1	0	0	1	0	0	0	0	0	0
1	0	0	1	0	0	0	0	0	0
1	0	0	1	0	0	0	0	0	0
1	0	0	1	0	0	0	0	0	0
1	0	0	0	1	0	0	0	0	0
1	0	0	0	1	0	0	0	0	0
1	0	0	0	1	0	0	0	0	0
1	0	0	0	0	1	0	0	0	0
1	0	0	0	0	1	0	0	0	0
1	0	0	0	0	0	1	0	0	0
1	0	0	0	0	0	1	0	0	0
1	0	0	0	0	0	1	0	0	0
1	0	0	0	0	0	0	1	0	0
1	0	0	0	0	0	0	1	0	0
1	0	0	0	0	0	0	0	1	0
1	0	0	0	0	0	0	0	1	0
1	0	0	0	0	0	0	0	0	1
1	0	0	0	0	0	0	0	0	1

Ejercicio 2 clase:

```
yuca <- read.csv("yuca.csv")
yuca$Genotipos=as.factor(yuca$Genotipos)
library(sasLM)
M_X=ModelMatrix(Rendimiento~Genotipos,yuca)
X=as.matrix(M_X$X)
X
```

Matrix diseño X

(Intercept)	Genotipos1	Genotipos2	Genotipos3	Genotipos4	Genotipos5	Genotipos6	Genotipos7	Genotipos8	Genotipos9
1	1	0	0	0	0	0	0	0	0
1	1	0	0	0	0	0	0	0	0
1	1	0	0	0	0	0	0	0	0
1	0	1	0	0	0	0	0	0	0
1	0	1	0	0	0	0	0	0	0
1	0	0	1	0	0	0	0	0	0
1	0	0	1	0	0	0	0	0	0
1	0	0	1	0	0	0	0	0	0
1	0	0	0	1	0	0	0	0	0
1	0	0	0	1	0	0	0	0	0
1	0	0	0	0	1	0	0	0	0
1	0	0	0	0	1	0	0	0	0
1	0	0	0	0	0	1	0	0	0
1	0	0	0	0	0	1	0	0	0
1	0	0	0	0	0	0	1	0	0
1	0	0	0	0	0	0	1	0	0
1	0	0	0	0	0	0	0	1	0
1	0	0	0	0	0	0	0	0	1
1	0	0	0	0	0	0	0	0	1