

Notas del curso de modelo lineal

Teorema de Gauss Markov y Estimabilidad

Humberto Vaquera Huerta
2024

Teorema de Gauss Markov y Estimabilidad

Otro criterio para la estimación de $\lambda^t \beta$ es elegir la mejor estimación lineal insesgada (MELI) de $\lambda^t \beta$. Probamos con el teorema de Gauss-Markov que dice que el estimador de los mínimos cuadrados son las mejores estimaciones lineales insesgadas.

Definición MELI :

$a^t y$ es el **mejor estimador lineal insesgado** de $\lambda^t \beta$ si $a^t y$ es insesgado y si para cualquier otro estimador lineal insesgado $b^t y$, $Var(a^t y) \leq Var(b^t y)$.

El teorema de Gauss-Markov establece que en la clase de estimadores lineales insesgados el estimador de MCO es eficiente. Es decir tiene la mínima varianza de su clase

mejor estimador lineal insesgado (MELI) Best Linear Unbiased Estimator (BLUE)

Teorema de Gauss Markov

Informalmente, el teorema de **Gauss-Markov** establece que, bajo ciertas condiciones, el estimador de **mínimos cuadrados ordinarios (MCO)** es el mejor que podemos utilizar en el modelo lineal. Esta es una afirmación poderosa. Formalmente, el teorema establece lo siguiente:

Teorema de Gauss–Markov:

Considere el modelo lineal $Y = X\beta + \epsilon$, $E(\epsilon) = 0$, $Cov(\epsilon) = \sigma^2 I$. Si $\lambda^t \beta$ es estimable, entonces el estimador de cuadrados mínimos $\lambda^t \hat{\beta}$ de $\lambda^t \beta$ es el mejor estimador lineal insesgado (MELI) de $\lambda^t \beta$.
Donde $\hat{\beta}$ es una solución de las ecuaciones normales $X^t X \beta = X^t y$.

Teorema de Gauss Markov .. Demostración::

Buscamos un estimador

$$\lambda^t \beta^* = c + d^t y$$

que es un estimador lineal insesgado de $\lambda^t \beta$.

Entonces con $c = 0$ y sea $d^t X = \lambda^t$.

Ya que $E(c + d^t y) = c + d^t X \beta = \lambda^t \beta$ para todo β .

$$\begin{aligned} \text{Var}(c + d^t y) &= \text{Var}(d^t y) = \text{Var}(\lambda^t \hat{\beta} + d^t y - \lambda^t \hat{\beta}) \\ &= \text{Var}(\lambda^t \hat{\beta}) + \text{Var}(d^t y - \lambda^t \hat{\beta}) + 2\text{Cov}(\lambda^t \hat{\beta}, d^t y - \lambda^t \hat{\beta}) \\ &= \text{Var}(\lambda^t \hat{\beta}) + \text{Var}(d^t y - \lambda^t \hat{\beta}) + 2\text{Cov}(\lambda^t \hat{\beta}, d^t y - \lambda^t \hat{\beta}) \end{aligned}$$

Recordar

$$\text{Cov}(a^t y, c^t y) = a^t \text{Cov}(y) c, \text{ para } a, c. \text{ constantes}$$

Teorema de Gauss Markov .. Demostración: cont...

note que

$$Cov(\lambda^t \hat{\beta}, d^t y - \lambda^t \hat{\beta}) = cov(\lambda^t (X^t X)^{-} X^t y, d^t y - \lambda^t (X^t X)^{-} X^t y)$$

$$a^t = \lambda^t (X^t X)^{-} X^t \text{ y } c^t = d^t - \lambda^t (X^t X)^{-} X^t$$

podemos obtener

$$Cov(\lambda^t \hat{\beta}, d^t y - \lambda^t \hat{\beta}) = \lambda^t (X^t X)^{-} X^t Cov(y)(d - X((X^t X)^{-})^t \lambda$$

$$Var(\lambda^t \hat{\beta}) + Var(d^t y - \lambda^t \hat{\beta}) + 2Cov(\lambda^t \hat{\beta}, d^t y - \lambda^t \hat{\beta}) =$$

$$Var(\lambda^t \hat{\beta}) + Var(d^t y - \lambda^t \hat{\beta}) + 2\lambda^t (X^t X)^{-} X^t Cov(y)(d - X((X^t X)^{-})^t \lambda$$

$$Var(\lambda^t \hat{\beta}) + Var(d^t y - \lambda^t \hat{\beta}) + 2\lambda^t (X^t X)^{-} X^t (X^t X)^{-} \sigma^2 (d - X((X^t X)^{-})^t \lambda$$

Teorema de Gauss Markov .. Demostración: cont...

$$\begin{aligned} &= \text{Var}(\lambda^t \hat{\beta}) + \text{Var}(d^t y - \lambda^t \hat{\beta}) + 2\sigma^2 \lambda^t (X^t X)^- (X^t d - X^t X ((X^t X)^-)^t \lambda \\ &= \text{Var}(\lambda^t \hat{\beta}) + \text{Var}(d^t y - \lambda^t \hat{\beta}) + 2\sigma^2 \lambda^t (X^t X)^- (\lambda - \lambda) \\ &= \text{Var}(\lambda^t \hat{\beta}) + \text{Var}(d^t y - \lambda^t \hat{\beta}) \end{aligned}$$

ya que $\lambda^t \beta$ es estimable, tenemos que $\lambda \in C(X^t)$ note que $\lambda^t (X^t X)^- X^t X = \lambda^t$. Entonces $\text{Var}(d^t y) \geq \text{Var}(\lambda^t \hat{\beta})$, Con igualda si solo si

$$\text{Var}(d^t y - \lambda^t \hat{\beta}) = \text{Var}((d - X(X^t X)^- \lambda)^t y) = \sigma^2 \|d - X((X^t X)^-)^t \lambda\|^2 = 0$$

Entonces la igualdad ocurre i (y un estimador con igual varianza) si y sólo si $d = X((X^t X)^-)^t \lambda$ o $d^t y = \lambda^t \hat{\beta}$. En otras palabras, el mejor estimador lineal insesgado es único.

Estimación de la varianza σ^2

Obtención de un Estimador de la Varianza del vector de errores

Teorema

Sea $r(X) = r$ el rango de X y $Cov(\epsilon) = \sigma^2 I$, Entonces $\frac{y^t(I-M)y}{(n-r)}$ es un estimador insesgado de σ^2 .
Donde $M = X(X^t X)^{-1} X^t$.

Es decir

$$\hat{\sigma}^2 = \frac{Y^t(I-M)Y}{(n-r)} = \frac{(Y - X\hat{\beta})^t(Y - X\hat{\beta})}{(n-r)}$$

o en la practica $\hat{\sigma}^2 = CME$, el cuadrado medio del error estima a $\hat{\sigma}^2$.

Teorema de Rao

Teorema

Sea $Y = X\beta + \epsilon$ un modelo lineal donde ϵ se distribuye normal con media 0 y varianza $\sigma^2 I$. entonces el estimador de máxima verosimilitud es el mejor (varianza mínima) en la clase de estimadores insesgados.

Este resultado es mas poderoso que el teorema de Gauss Markov ya que incluye estimadores no lineales pero se requiere normalidad en los errores.

Distribución de las combinaciones lineales estimables $\lambda^t \beta$

Teorema

Suponga que $Y = X\beta + \epsilon$, donde $E(\epsilon)$ se distribuye $N(0, \sigma^2 I)$, y que $\lambda^t \beta$ es estimable. Entonces,

- $\lambda^t \hat{\beta}$ se distribuye normal con media $\lambda^t \beta$ y varianza $\lambda^t (X^t X)^{-} \lambda \sigma^2$, donde $\hat{\beta}$ es obtenido como $\hat{\beta} = (X^t X)^{-} X^t y$.
- $\lambda^t \hat{\beta}$ y CME son independientemente distribuidos, donde CME es el cuadrado medio del error.
 $\hat{\sigma}^2 = CME = \frac{y^t (I - X(X^t X)^{-} X^t) y}{(n-r)}$
- $\lambda^t \hat{\beta}$ y el CME son estimadores insesgados uniformemente de varianza mínima de $\lambda^t \beta$ y de σ^2 .

Ahora recuerde que: $\lambda^t \hat{\beta}$ se distribuye normal con media $\lambda^t \beta$ y varianza $\lambda^t (X^t X)^{-} \lambda \sigma^2$, donde $\hat{\beta}$ es obtenido como $\hat{\beta} = (X^t X)^{-} X^t Y$.

Pruebas de hipótesis en combinaciones lineales estimables

En el modelo lineal es fundamental el derivar pruebas y intervalos de confianza relativos a funciones lineales estimables $A\beta$.

Definición: Hipótesis comprobables

Se dice que la hipótesis $H_0 : A\beta = m$ es comprobable si los elementos de $A\beta$ son estimables, donde A es una matriz de orden $s \times p$ y rango $s \leq r$, el rango de X , y m es un vector constante.

posteriormente derivaremos el estadístico

$$F_c = \frac{(A\hat{\beta} - m)^t (A(X^t X)^{-1} A^t) (A\hat{\beta} - m)}{s \times CME}$$

donde s =rango de A y r =rango de X .

El cual se distribuye como F con s y $(n - r)$ grados de libertad y rechazamos cuando F_c es grande en relación a F tablas.

Pruebas de hipótesis en combinaciones lineales estimables

- En el caso especial cuando $A = \lambda^t$, un estadístico de prueba para probar

$H_0 : \lambda^t \beta = m$ versus $H_a : \lambda^t \beta \neq m$ es:

$$T_c = \frac{(\lambda \hat{\beta} - m)}{[(\lambda^t (X^t X)^{-1} \lambda) \times CME]^{\frac{1}{2}}}$$

la cual, bajo H_0 , se distribuye t con $(n - r)$ grados de libertad. Rechazamos cuando $|T_c|$ es grande.

- Un **intervalo de confianza** del $(1 - \alpha)100\%$ para $\lambda^t \beta$ es:

$$\lambda \hat{\beta} \pm \sqrt{[(\lambda^t (X^t X)^{-1} \lambda) \times CME]} \times t_{\frac{\alpha}{2}, (n-r)}$$

donde $t_{\frac{\alpha}{2}, (n-r)}$ se obtiene de las tablas de t de student.

Ejemplo: Fertilizantes

El rendimiento de un determinado cultivo de grano depende de la dosis de un fertilizante particular. Cuatro niveles igualmente espaciados del factor fertilizante fueron utilizados en un experimento bajo un diseño completamente al azar. Los datos de rendimiento (en bushels/acre) se dan en la siguiente tabla:

Tabla de rendimientos

<i>Dosis del Fertilizante (lb/parcela)</i>			
15	25	35	45
18	39	41	41
12	28	37	42
25	40	30	38
27	33	41	48
26	30	45	45

Considere el modelo:

$$Y_{ij} = \mu + \tau_i + \epsilon_{ij}$$

con $i = 1, \dots, 4$ y $j = 1, \dots, 5$

Ejemplo: Fertilizantes

Suponga que tenemos interés en probar las siguientes combinaciones lineales:

$$\lambda_1^t \beta = -3\tau_1 - \tau_2 + \tau_3 + 3\tau_4$$

$$\lambda_2^t \beta = \tau_1 - \tau_2 - \tau_3 + \tau_4$$


$$\lambda_3^t \beta = -\tau_1 + 3\tau_2 - 3\tau_3 + \tau_4$$

Son contrastes que prueban el efecto *lineal*, *cuadrático* y *cúbico* del fertilizante sobre el cultivo.

Ejemplo: Fertilizantes

##	Dosis	Rend
## 1	15	18
## 2	15	12
## 3	15	25
## 4	15	27
## 5	15	26
## 6	25	39
## 7	25	28
## 8	25	40
## 9	25	33
## 10	25	30
## 11	35	41
## 12	35	37
## 13	35	30
## 14	35	41
## 15	35	45
## 16	45	41
## 17	45	42
## 18	45	38
## 19	45	48
## 20	45	45

Ejemplo: Fertilizantes



Preguntas de investigación..

- Existe efecto de dosis de fertilizante sobre el rendimiento?
- Como es el efecto de dosis? Lineal, cuadrático o cúbico?

Ejemplo: Fertilizantes

Modelo lineal en forma matricial

$$y = X\beta + \varepsilon$$

$$\begin{pmatrix} 18 \\ 12 \\ 25 \\ 27 \\ 26 \\ 39 \\ 28 \\ 40 \\ 33 \\ 30 \\ 41 \\ 37 \\ 30 \\ 41 \\ 45 \\ 41 \\ 42 \\ 38 \\ 48 \\ 45 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \tau_3 \\ \tau_4 \end{pmatrix} + \begin{pmatrix} \varepsilon_{11} \\ \varepsilon_{12} \\ \varepsilon_{13} \\ \varepsilon_{14} \\ \varepsilon_{15} \\ \varepsilon_{21} \\ \varepsilon_{22} \\ \varepsilon_{23} \\ \varepsilon_{24} \\ \varepsilon_{25} \\ \varepsilon_{31} \\ \varepsilon_{32} \\ \varepsilon_{33} \\ \varepsilon_{34} \\ \varepsilon_{35} \\ \varepsilon_{41} \\ \varepsilon_{42} \\ \varepsilon_{43} \\ \varepsilon_{44} \\ \varepsilon_{45} \end{pmatrix}$$

Ejemplo: Fertilizantes

Son estimables las siguientes combinaciones lineales?:

$$\lambda_1^t \beta = -3\tau_1 - \tau_2 + \tau_3 + 3\tau_4$$

$$\lambda_2^t \beta = \tau_1 - \tau_2 - \tau_3 + \tau_4$$

$$\lambda_3^t \beta = -\tau_1 + 3\tau_2 - 3\tau_3 + \tau_4$$

Usando criterio del rango se prueba que son estimables;iiii

$$X^t X = \begin{pmatrix} 20 & 5 & 5 & 5 & 5 \\ 5 & 5 & 0 & 0 & 0 \\ 5 & 0 & 5 & 0 & 0 \\ 5 & 0 & 0 & 5 & 0 \\ 5 & 0 & 0 & 0 & 5 \end{pmatrix}$$

Son estimables las siguientes combinaciones lineales?:

$$\lambda_1^t \beta = -3\tau_1 - \tau_2 + \tau_3 + 3\tau_4$$

$$(X^t X)^- = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & \frac{1}{5} & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{5} & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{5} & 0 \\ 0 & 0 & 0 & 0 & \frac{1}{5} \end{bmatrix}$$

Ejemplo: Fertilizantes

$$\lambda_1^t \beta = -3\tau_1 - \tau_2 + \tau_3 + 3\tau_4$$

$$\lambda_1^t = [0 \quad -3 \quad -1 \quad 1 \quad 3]$$

$$\lambda_1^t (X^t X)^{-1} X^t X =$$

$$(0 \quad -3 \quad -1 \quad 1 \quad 3) \begin{pmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & \frac{1}{5} & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{5} & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{5} & 0 \\ 0 & 0 & 0 & 0 & \frac{1}{5} \end{pmatrix} \begin{pmatrix} 20 & 5 & 5 & 5 & 5 \\ 5 & 5 & 0 & 0 & 0 \\ 5 & 0 & 5 & 0 & 0 \\ 5 & 0 & 0 & 5 & 0 \\ 5 & 0 & 0 & 0 & 5 \end{pmatrix} =$$
$$(0 \quad -3 \quad -1 \quad 1 \quad 3)$$

Es estimable;

Ejemplo: Fertilizantes

Aplicando el Teorema de Gauss Markov. Si $\lambda_1^t \beta = -3\tau_1 - \tau_2 + \tau_3 + 3\tau_4$ es estimable el Mejor estimador lineal insesgado de este contraste es:

$\lambda_1 \hat{\beta}$ donde $\hat{\beta} = (X^t X)^{-1} X^t Y$

$$\hat{\beta} = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & \frac{1}{5} & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{5} & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{5} & 0 \\ 0 & 0 & 0 & 0 & \frac{1}{5} \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 18 \\ 12 \\ 25 \\ 27 \\ 26 \\ 39 \\ 28 \\ 40 \\ 33 \\ 30 \\ 41 \\ 37 \\ 30 \\ 41 \\ 45 \\ 41 \\ 42 \\ 38 \\ 48 \\ 45 \end{bmatrix} = \begin{bmatrix} 0 \\ \frac{108}{5} \\ 34 \\ \frac{194}{5} \\ \frac{214}{5} \end{bmatrix}$$

Una solución de β

Ejemplo: Fertilizantes

Aplicando el Teorema de Gauss Markov. Si $\lambda_1^t \beta = -3\tau_1 - \tau_2 + \tau_3 + 3\tau_4$ es estimable el Mejor estimador lineal insesgado de este contraste es:

$$\lambda_1^t \hat{\beta} \text{ donde } \hat{\beta} = (X^t X)^{-1} X^t Y$$

$$\lambda_1^t \hat{\beta} = -3\hat{\tau}_1 - \hat{\tau}_2 + \hat{\tau}_3 + 3\hat{\tau}_4$$

$$\begin{bmatrix} 0 & -3 & -1 & 1 & 3 \end{bmatrix} \begin{bmatrix} \hat{\mu} \\ \hat{\tau}_1 \\ \hat{\tau}_2 \\ \hat{\tau}_3 \\ \hat{\tau}_4 \end{bmatrix} = \begin{bmatrix} 0 & -3 & -1 & 1 & 3 \end{bmatrix} \begin{bmatrix} 0 \\ \frac{108}{5} \\ 34 \\ \frac{194}{5} \\ \frac{214}{5} \end{bmatrix} = \frac{342}{5}$$

Es el MELI

Ejemplo: Fertilizantes

De manera similar se puede probar que :

$$\lambda_2^t \beta = \tau_1 - \tau_2 - \tau_3 + \tau_4$$

$$\lambda_3^t \beta = -\tau_1 + 3\tau_2 - 3\tau_3 + \tau_4$$

son estimables y usando teorema de Gauss Markov el MELI es:

$$\lambda_2^t \hat{\beta} = \hat{\tau}_1 - \hat{\tau}_2 - \hat{\tau}_3 + \hat{\tau}_4 = \frac{108}{5} - 34 - \frac{195}{5} + \frac{215}{5} = \frac{42}{5}$$

$$\lambda_3^t \hat{\beta} = -\hat{\tau}_1 + 3\hat{\tau}_2 - 3\hat{\tau}_3 + \hat{\tau}_4 = -\frac{108}{5} + 3 \times 34 - 3\frac{195}{5} + \frac{215}{5} = \frac{34}{5}$$

$\lambda^t \hat{\beta}$ se distribuye normal con media $\lambda^t \beta$ y varianza $\lambda^t (X^t X)^{-} \lambda \sigma^2$, donde $\hat{\beta}$ es obtenido como $\hat{\beta} = (X^t X)^{-} X^t Y$.

Ejemplo: Fertilizantes

Distribución de combinaciones lineales estimadas

- $\lambda^t \hat{\beta}$ se distribuye normal con media $\lambda^t \beta$ y varianza $\lambda^t (X^t X)^{-1} \lambda \sigma^2$, donde $\hat{\beta}$ es obtenido como $\hat{\beta} = (X^t X)^{-1} X^t Y$. y $\hat{\sigma}^2$ se estima usando el CME.

Por lo que

$$\lambda^t \hat{\beta} \sim N(\lambda^t \beta, \lambda^t (X^t X)^{-1} \lambda \sigma^2)$$

Un intervalo de confianza del $(1 - \alpha)100\%$ para $\lambda^t \beta$ es:

$$\lambda^t \hat{\beta} \pm \sqrt{[(\lambda^t (X^t X)^{-1} \lambda) \times CME]} \times t_{\frac{\alpha}{2}, (n-r)}$$

donde $t_{\frac{\alpha}{2}, (n-r)}$ se obtiene de las tablas de la distribución *t de student*.

Ejemplo: Fertilizantes

Obtenga un IC del 95\% para :

$$\lambda_1^t \beta = -3\tau_1 - \tau_2 + \tau_3 + 3\tau_4$$

$$\lambda_2^t \beta = \tau_1 - \tau_2 - \tau_3 + \tau_4$$

$$\lambda_2^t \beta = -\tau_1 + 3\tau_2 - 3\tau_3 + \tau_4$$

$\lambda^t \hat{\beta}$ se distribuye normal con media $\lambda^t \beta$ y varianza $\lambda^t (X^t X)^{-1} \lambda \sigma^2$, donde $\hat{\beta}$ es obtenido como $\hat{\beta} = (X^t X)^{-1} X^t Y$. y $\hat{\sigma}^2$ se estima usando el CME.

Por lo que

Obtenga un IC del 95% para :

$$\lambda_1^t \beta = -3\tau_1 - \tau_2 + \tau_3 + 3\tau_4$$

$$\lambda_2^t \beta = \tau_1 - \tau_2 - \tau_3 + \tau_4$$

$$\lambda_3^t \beta = -\tau_1 + 3\tau_2 - 3\tau_3 + \tau_4$$

$$\hat{\sigma}^2 = CME = \frac{1167}{40}$$

$$\lambda \hat{\beta} \pm \sqrt{[(\lambda^t (X^t X)^{-1} \lambda) \times CME]} \times t_{\frac{\alpha}{2}, (n-r)}$$

Obtenga un IC del 95% para :

$$\lambda_1^t \beta = -3\tau_1 - \tau_2 + \tau_3 + 3\tau_4$$

$$\hat{\sigma}^2 = CME = \frac{1167}{40}, t_{\frac{0.05}{2}, (20-4)} = 2.119905$$

$$\lambda \hat{\beta} \pm \sqrt{[(\lambda^t (X^t X)^{-1} \lambda) \times CME]} \times t_{\frac{\alpha}{2}, (n-r)}$$

$$\lambda^t (X^t X)^{-1} \lambda = \begin{bmatrix} 0 & -3 & -1 & 1 & 3 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & \frac{1}{5} & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{5} & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{5} & 0 \\ 0 & 0 & 0 & 0 & \frac{1}{5} \end{bmatrix} \begin{bmatrix} 0 \\ -3 \\ -1 \\ 1 \\ 3 \end{bmatrix} = 4$$

$$\lambda \hat{\beta} \pm \sqrt{[(\lambda^t (X^t X)^{-1} \lambda) \times CME]} \times t_{\frac{\alpha}{2}, (n-r)} = \frac{342}{5} \pm \sqrt{4 \times \frac{1167}{40}} \times 2.119905$$

Por lo que el Intervalo es (45.49, 91.30) hay un efecto lineal

Ejemplo Fertilizante en R

```
fert=read.csv("fert_dosis.csv");fert$Dosis=as.factor(fert$Dosis)
library(emmeans)
anova_fert=aov(Rend~Dosis,fert); anova(anova_fert)
```

```
## Analysis of Variance Table
##
## Response: Rend
##           Df Sum Sq Mean Sq F value    Pr(>F)
## Dosis      3 1269.4   423.13   14.503 7.951e-05 ***
## Residuals 16  466.8    29.17
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
medias=emmeans(anova_fert, "Dosis")
Contrastes <- contrast(medias, "poly")
confint(Contrastes)
```

```
## contrast estimate      SE df lower.CL upper.CL
## linear      68.4 10.80 16      45.5     91.30
## quadratic   -8.4  4.83 16     -18.6      1.84
## cubic        6.8 10.80 16     -16.1     29.70
##
## Confidence level used: 0.95
```

Ejemplo Fertilizante en R

```
library(emmeans)
contrast_lineal=contrast(medias, method = list(c(-3,-1, 1, 3)))
contrast_lineal
```

```
## contrast      estimate    SE df t.ratio p.value
## c(-3, -1, 1, 3)      68.4 10.8 16   6.332  <.0001
```

```
confint(contrast_lineal)
```

```
## contrast      estimate    SE df lower.CL upper.CL
## c(-3, -1, 1, 3)      68.4 10.8 16    45.5    91.3
##
## Confidence level used: 0.95
```


Ejemplo Fertilizante en R

```
library(multcomp)
contraste_l <- glht(anova_fert,
  linfct = mcp(Dosis = c(-3,-1, 1, 3)))
#summary(contraste_l)
confint(contraste_l)
```

```
##
##      Simultaneous Confidence Intervals
##
## Multiple Comparisons of Means: User-defined Contrasts
##
##
## Fit: aov(formula = Rend ~ Dosis, data = fert)
##
## Quantile = 2.1199
## 95% family-wise confidence level
##
##
## Linear Hypotheses:
##      Estimate lwr      upr
## 1 == 0 68.4000  45.4991 91.3009
```

Ejemplo Fertilizante en R

```
library(multcomp)
contraste_l <- glht(anova_fert,
  linfct = mcp(Dosis = c(-3,-1, 1, 3)))
plot(medias,hORIZ=F)
```



Prueba de Hipotesis sobre combinaciones lineales

Ejemplo

- Probar

$H_0 : \lambda_1^t \beta = -3\tau_1 - \tau_2 + \tau_3 + 3\tau_4 = 0$ versus $H_a : \lambda_1^t \beta = -3\tau_1 - \tau_2 + \tau_3 + 3\tau_4 \neq 0$ es:

$$T_c = \frac{(\lambda \hat{\beta} - m)}{[(\lambda^t (X^t X)^{-1} \lambda) \times CME]^{\frac{1}{2}}} = \frac{\frac{342}{5} - 0}{(4 \times \frac{1167}{40})^{1/2}} = 6.332$$

- $\lambda_1^t \hat{\beta} = -3\hat{\tau}_1 - \hat{\tau}_2 + \hat{\tau}_3 + 3\hat{\tau}_4 = \frac{342}{5}$
- $m = 0$
- $\lambda^t (X^t X)^{-1} \lambda = 4$
- $\hat{\sigma}^2 = CME = \frac{1167}{40}$
- Valor de tablas $t_{\frac{0.05}{2}, (20-4)} = 2.119905$ bajo H_0 , se distribuye t con $(n - r)$ grados de libertad. En este caso Rechazamos H_0 ya que $|T_c = 6,332|$ es valor de tablas (2,11).

Caso Rango X Completo

Modelo de Regresión Lineal

$$y_i = \beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki} + \epsilon_i, \quad i = 1, \dots, N$$

El modelo de regresión múltiple se especifica en la siguiente forma matricial:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$$

Si X es de rango completo $(X^t X)^{-1}$ existe y es única por lo que la solución de las Ecuaciones Normales es única:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{Y}$$

El teorema de Gauss-Markov para la regresión múltiple establece que si $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$ con $\mathbb{E}(\boldsymbol{\epsilon}) = \mathbf{0}$, $\mathbf{Var}(\boldsymbol{\epsilon}) = \sigma^2 \mathbf{I}$ y $\text{Rango}(\mathbf{X}) = k + 1$ (rango completo) se cumplen, los estimadores MCO $\hat{\boldsymbol{\beta}}$ son los mejores estimadores lineales insesgados y son consistentes (MELI) de $\boldsymbol{\beta}$ del modelo de regresión múltiple.

Caso Rango X Completo

Regresión

Matriz de varianzas y covarianzas de $\hat{\beta}$

$$\text{Var}(\hat{\beta}) = \begin{bmatrix} \text{Var}(\hat{\beta}_0) & \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) & \dots & \text{Cov}(\hat{\beta}_0, \hat{\beta}_k) \\ \text{Cov}(\hat{\beta}_1, \hat{\beta}_0) & \text{Var}(\hat{\beta}_1) & \dots & \text{Cov}(\hat{\beta}_1, \hat{\beta}_k) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(\hat{\beta}_k, \hat{\beta}_0) & \text{Cov}(\hat{\beta}_k, \hat{\beta}_1) & \dots & \text{Var}(\hat{\beta}_k) \end{bmatrix} = \sigma^2 (\mathbf{X}^t \mathbf{X})^{-1}$$

Caso Rango $\mathbf{X}$ Completo

Regresión

Estimación del parámetro de varianza del error

Defina el vector de **residuales** como la diferencia entre los valores reales y predichos:

$$\hat{\boldsymbol{\varepsilon}} = [\hat{\varepsilon}_1, \dots, \hat{\varepsilon}_N]^t = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}$$

Es estimador de σ^2 es:

$$\hat{\sigma}^2 = \frac{1}{N - (k + 1)} \sum_{i=1}^N \hat{\varepsilon}_i^2 = \frac{\hat{\boldsymbol{\varepsilon}}^t \hat{\boldsymbol{\varepsilon}}}{N - (k + 1)}$$

donde: $K + 1$ es el numero de parámetros de regresion $\hat{\boldsymbol{\beta}} = [\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k]^t$ y N es el numero de observaciones. Si se cumple el supuesto de normalidad ($\boldsymbol{\varepsilon} \sim N(0, \sigma^2 \mathbf{I})$) Entonces:

$$\hat{\boldsymbol{\beta}} \sim \mathcal{N} \left(\boldsymbol{\beta}, \sigma^2 (\mathbf{X}^t \mathbf{X})^{-1} \right)$$

Estimabilidad de funciones lineales en Regresion

En modelos de regresión , i.e., modelos de *rango completo* $\text{rango}(X) = k + 1$.

- Todas las funciones lineales de los parámetros $\lambda^t \beta$ son estimables y el MELI es:

$$\sum_{j=0}^k \lambda_j \hat{\beta}_j = \lambda_0 \hat{\beta}_0 + \dots + \lambda_k \hat{\beta}_k = \hat{r}$$

$$\lambda^t \hat{\beta} \sim N(\lambda^t \beta, \lambda^t (X^t X)^{-1} \lambda \sigma^2)$$

- β es estimable y por el teorema de Gauss Markov $\hat{\beta} = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{y}$ es el MELI.

Ejemplo Boston dataset

The Boston Housing data set which contains 506 observations on housing values in suburbs of Boston.

```
# Load packages
library(MASS)
# Select data
data(Boston)
head(Boston, 3)
```

```
##      crim zn  indus chas   nox   rm  age   dis rad tax ptratio  black  lstat
## 1 0.00632 18   2.31    0 0.538 6.575 65.2 4.0900    1 296    15.3 396.90   4.98
## 2 0.02731  0   7.07    0 0.469 6.421 78.9 4.9671    2 242    17.8 396.90   9.14
## 3 0.02729  0   7.07    0 0.469 7.185 61.1 4.9671    2 242    17.8 392.83   4.03
##      medv
## 1 24.0
## 2 21.6
## 3 34.7
```

Deseamos ajustar el modelo

$$medv_i = \beta_0 + \beta_1 lstat_i + \beta_2 age_i + \beta_3 crim_i + u_i.$$

Ejemplo Boston dataset

Estimador MCO

```
regres_aj=lm(medv~lstat + age + crim, Boston)
coef(regres_aj)
```

```
## (Intercept)      lstat      age      crim
## 32.82804470 -0.99409094  0.03764664 -0.08262222
```

$$\hat{medv}_i = \underset{(0.75)}{32.828} - \underset{(0.05)}{0.994} \times lstat_i - \underset{(0.04)}{0.083} \times crim_i + \underset{(0.01)}{0.038} \times age_i.$$

Suponga deseamos estimar

$$\lambda^t \beta = \beta_2 - \beta_3$$

el MELI es

$$\lambda^t \hat{\beta} = \hat{\beta}_2 - \hat{\beta}_3 = (-.083) - (0.038) = -0.121$$

Intervalo de confianza para $\beta_2 - \beta_3$

```
library(car)
regres_aj=lm(medv~lstat + age + crim, Boston)
#linearHypothesis(regres_aj,"1*crim - 1*age = 0")
library(foreign)
library(multcomp)
confint(glht(regres_aj, linfct = c("crim-age = 0")))
```

```
##
##      Simultaneous Confidence Intervals
##
## Fit: lm(formula = medv ~ lstat + age + crim, data = Boston)
##
## Quantile = 1.9647
## 95% family-wise confidence level
##
##
## Linear Hypotheses:
##              Estimate lwr      upr
## crim - age == 0 -0.12027 -0.19734 -0.04319
```