

Notas del curso de modelo lineal

Enfoque geometrico del modelo lineal

Humberto Vaquera Huerta
2024

Modelos lineales y geometría

La comprensión de la geometría puede proporcionar información sobre gran parte del análisis asociado con el análisis de un modelo lineal. La idea es escribir el modelo lineal como una ecuación vectorial y explorar las implicaciones de esta ecuación utilizando una comprensión básica de los espacios vectoriales.

Existe geometría asociada con el modelo lineal la cual puede proporcionar información sobre gran parte del análisis asociado con el análisis estadístico.

- La idea es escribir el modelo lineal como una ecuación vectorial y explorar las implicaciones de esta ecuación utilizando una comprensión básica de los espacios vectoriales.
- Es necesario revisar los aspectos de los vectores y los espacios vectoriales.

Fisher (1915) trato geoméricamente problemas de la estadística, definitivamente pensaba geoméricamente de vez en cuando. La claridad con la que Fisher veía los conceptos no era fácilmente transferible a los lectores de sus artículos.

Los fundamentos de vectores


Para nuestros propósitos, un vector es una lista de números reales

$$\mathbf{V} = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix}$$

Pensaremos en un vector como las coordenadas de un punto en espacio n-dimensional a menudo usaremos una línea dirigida segmento que se extiende desde el origen hasta estas coordenadas para ayudarnos a visualizar conceptos ejemplo:

$$\mathbf{V} = \begin{bmatrix} 2 \\ 3 \end{bmatrix}; \quad \mathbf{W} = \begin{bmatrix} -4 \\ 1 \end{bmatrix}$$

Geometria



$$\mathbf{v} = \begin{bmatrix} 2 \\ 3 \end{bmatrix} \quad \mathbf{w} = \begin{bmatrix} -4 \\ 1 \end{bmatrix}$$

Vectores en el plano

Los fundamentos de vectores

Suma de vectores

La suma de dos vectores se obtiene sumando sus entradas correspondientes:




$$\begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} + \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix} = \begin{bmatrix} v_1 + w_1 \\ v_2 + w_2 \\ \vdots \\ v_n + w_n \end{bmatrix}$$

$$\mathbf{v} + \mathbf{w} = \begin{bmatrix} 2 \\ 3 \end{bmatrix} + \begin{bmatrix} -4 \\ 1 \end{bmatrix} = \begin{bmatrix} -2 \\ 4 \end{bmatrix}$$

Los fundamentos de vectores

Visualización de la suma de vectores

Visualmente, traducimos el punto de partida de uno de los vectores a el punto final del otro.



Los fundamentos de vectores

Multiplicación escalar de vectores



Para multiplicar un vector por una constante, simplemente multiplique cada entrada por esa constante:

$$k \times \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} k \times v_1 \\ k \times v_2 \\ \vdots \\ k \times v_n \end{bmatrix}$$

Los fundamentos de vectores

Visualización de la multiplicación escalar

Si multiplicamos un vector por una constante, el vector resultante tiene la misma dirección (o la dirección opuesta si la constante es negativo) como el vector original, pero su longitud ha sido multiplicado por la constante.



Espacios vectoriales

Un **espacio vectorial** V es un cuadruplete $(V, K, +, \cdot)$ que posee:

un conjunto de elementos llamados **vectores**, campo de **escalares**, una **operación de adición**, y una **operación de producto por un escalar**.

que satisfacen las siguientes propiedades:

- $\mathbf{x} + \mathbf{y} \in V$; (adición cerrada),
- $\mathbf{x} + \mathbf{y} = \mathbf{y} + \mathbf{x}$; (adición conmutativa),
- $\mathbf{x} + (\mathbf{y} + \mathbf{z}) = (\mathbf{x} + \mathbf{y}) + \mathbf{z}$; (adición asociativa),
- $\mathbf{x} + 0 = \mathbf{x}$; ($\exists$ del elemento neutro respecto a la adición),
- $\alpha \mathbf{x} \in S$; (producto por escalar cerrado),
- $\alpha(\beta \mathbf{x}) = (\alpha\beta) \mathbf{x}$; (producto por escalar asociativo),
- $\alpha(\mathbf{x} + \mathbf{y}) = \alpha \mathbf{x} + \alpha \mathbf{y}$; (producto escalar distributivo),
- $1 \mathbf{x} = \mathbf{x}$; ($\exists$ del elemento neutro respecto al producto).

Para todo vector que corresponde a V , y $\forall \alpha, \beta \in K$.

Los fundamentos de vectores

Algebra básica de vectores

Para los vectores U, V y W y los escalares k_1 y k_2 :

$$1. V + W = W + V$$

$$2. U + (V + W) = (U + W) + V$$

$$3. k_1(V + W) = K_1 * V + K_1 * W$$

$$4. (k_1 + k_2)V = K_1 * V + k_2 * V$$

Prácticamente cualquier propiedad algebraica que se aplique a la la suma y multiplicación de números reales se aplicará a vectores también

Espacios vectoriales

Para nuestros propósitos, solo necesitamos considerar los vectores que contienen **números reales** y las definiciones usuales de *adición de vectores* y *multiplicación escalar*. En este caso, un espacio de vectores es cualquier colección de vectores que se cierra bajo suma y multiplicación escalar.

Esto significa que si tomamos dos vectores u y v del espacio de un vector, entonces cualquier combinación lineal $k_1 * u + k_2 * v$ también debe estar en ese espacio vectorial. Como resultado, el vector cero debe estar en todos los espacios vectoriales

Definición de $\mathbb{R}^n$

Sea $\mathbb{R}^n$ el conjunto de todos los vectores de n componentes donde cada componente es un número real.

- $\mathbb{R}^n$ es un espacio vectorial bajo las definiciones usuales de adición de vectores y multiplicación escalar. Los números reales son cerrados bajo suma y multiplicación.

La base de un espacio vectorial

La forma usual de definir un subespacio es identificando un conjunto de vectores que forman una base.

- Supongamos que tomamos cualquier colección finita de vectores de R^n y considere el conjunto de vectores producido al tomar todos posibles combinaciones lineales de estos vectores. nuestro método de generar este subconjunto garantiza que se cerradura bajo la suma y la multiplicación escalar y por lo tanto ser un subespacio de R^n .
- Además, suponga que ninguno de los vectores en la colección original se puede generar como una combinación lineal de la otros vectores { es decir, ninguno de estos es redundante. Luego esto colección de vectores se llama base para el espacio vectorial que ellos generan)

Dado un espacio vectorial X , se dice que el conjunto de vectores X_0 constituyen una *base* de X si X_0 es *linealmente independiente*, y genera a X .

Se llama **dimensión** D de un espacio vectorial X al **número** de vectores que tiene una base de dicho espacio.

La base de un espacio vectorial

Sea V un espacio vectorial. Un conjunto mínimo de vectores en V que genera V se llama **base de V**

Como resultado, para verificar si un conjunto de vectores forma la base de un espacio vectorial, es necesario verificar que sea linealmente independiente y que abarque el espacio vectorial. Si al menos una de estas condiciones no se cumple, entonces no es una base.

En $\mathbb{R}^3$, todo vector tiene la forma $\begin{bmatrix} a \\ b \\ c \end{bmatrix}$ donde a, b, c son números reales. Tenga en cuenta que $\mathbb{R}^3$ está expandido por el conjunto $\left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right\}$ es una base, dimensión 3.

El conjunto:

$$\left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \right\}$$

No es una base ya que expande $\mathbb{R}^3$ pero no son linealmente independientes

Subespacios de $\mathbb{R}^n$


Necesitaremos considerar los diferentes subespacios de $\mathbb{R}^n$. Cualquier subconjunto de vectores en $\mathbb{R}^n$ que sea en sí mismo un espacio vectorial se denomina subespacio de $\mathbb{R}^n$. Dado que usamos las mismas definiciones para la suma y la multiplicación escalar que antes, todo lo que realmente necesitamos verificar es que el subconjunto de vectores sea cerrado bajo la suma y la multiplicación por un escalar.

Espacio en $\mathbb{R}^3$

$\mathbb{R}^3$ es un ejemplo que podemos interpretar.

Considere el espacio vectorial generado por un solo vector V_1 en $\mathbb{R}^3$: el subespacio consta de V_1 y todos los múltiplos escalares de V_1 .

- Este subespacio se puede considerar como una línea infinita en $\mathbb{R}^3$




Subespacios de $\mathbb{R}^n$

Los subespacios de $\mathbb{R}^3$ se pueden clasificar de la siguiente manera:

1. El origen mismo .
2. Cualquier línea que pase por el origen.
3. Cualquier plano que pase por el origen.
4. $\mathbb{R}^3$ en sí.

Los elementos 3 y 4 de esta lista son técnicamente subespacios de $\mathbb{R}^3$ pero no tienen mucho interés práctico: se denominan "subespacios inadecuados".



Una base de un subespacio

Supongamos que para un subespacio S tenemos vectores $V_1, \dots, V_k$ tal que cada vector en S se puede expresar como una combinación lineal de $V_1, \dots, V_k$. Entonces $V_1, \dots, V_k$ se dice que expanden S . Los vectores $V_1, \dots, V_k$ se dice que son linealmente independientes si no es posible expresar ninguno de ellos como una combinación lineal de los demás. Un conjunto de vectores $V_1, \dots, V_k$ es una base para un subespacio S si

1. $V_1, \dots, V_k$ expanden S .
2. $V_1, \dots, V_k$ son linealmente independientes.

La dimensión de un subespacio

Para cualquier subespacio S , hay un número infinito de bases. Sin embargo, cada uno de estos consistirá exactamente en el mismo número de vectores. El número de vectores en una base para S es llamada la dimensión de S .

- Por ejemplo para una línea en $\mathbb{R}^3$, una base consistirá en un vector que cae en esa línea { las líneas son unidimensionales}.
- Para cualquier plano en $\mathbb{R}^3$, cualquier conjunto de 2 vectores linealmente independientes(no colineales) que caen en ese plano son una base {Los planos son bidimensionales}.
- Cualquier conjunto de 3 vectores linealmente independientes en $\mathbb{R}^3$ será un base para el propio $\mathbb{R}^3$.

Espacios Euclídeos: producto escalar, normas, distancia y ángulos

Producto interno o producto escalar

Dado dos vectores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^N$, se define su *producto interno* $\langle \mathbf{x}, \mathbf{y} \rangle \in \mathbb{R}$ como:

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x} \cdot \mathbf{y} = x_1 y_1^* + x_2 y_2^* + \dots + x_n y_n^* = \sum_{i=1}^n x_i y_i^*$$

dónde el $*$ representa el **conjugado** en caso de tratarse de valores complejos. El producto interno de un vector consigo mismo es igual al cuadrado de su norma 2.

En $\mathbb{R}^2$ tenemos definido el producto escalar usual

$$(a_1, a_2) \cdot (b_1, b_2) = a_1 b_1 + a_2 b_2$$

Es una operación entre dos vectores, cuyo resultado es un escalar (de ahí el nombre “producto escalar”).

El producto escalar permite reconocer a los vectores ortogonales (“ángulo recto”): dos vectores son ortogonales si su producto escalar es cero.

Producto escalar

Propiedades del producto escalar usual.

1. Conmutativa. $u \cdot v = v \cdot u$
2. Distributiva. $u \cdot (v + w) = u \cdot v + u \cdot w$
3. Reubicación del escalar . $\alpha(u \cdot v) = (\alpha u) \cdot v = u \cdot (\alpha v)$
4. Definida positiva: $v \cdot v \geq 0$, y se da la igualdad $v \cdot v = 0$ solamente para el vector $v = 0$

Ejemplos de productos vectoriales

- Suponga dos vectores en $\mathbb{R}^3$

$$u = (-3, 5, 8) \quad , \quad v = (1, 1, 1)$$

$$\langle u, v \rangle = u \cdot v = (-3) \cdot 1 + 5 \cdot 1 + 8 \cdot 1 = 10$$

- En $\mathbb{R}^n$, el producto escalar usual considere dos vectores x y y

$$\langle x, y \rangle = x_1y_1 + x_2y_2 + \dots + x_ny_n = \sum_{i=1}^n x_iy_i$$

Producto internos o escalares

El espacio euclídeo es un tipo de espacio geométrico donde se satisfacen los axiomas de Euclides de la geometría. La recta real, el plano euclídeo y el espacio tridimensional de la geometría euclidiana son casos especiales de espacios euclídeos de dimensiones 1, 2 y 3 respectivamente.

Definición 1 . Producto escalar en cualquier espacio. **Espacio euclídeo.**

Cualquier operación en un espacio vectorial que cumpla las propiedades del producto vectorial, diremos que es un producto escalar (aunque no se trate del producto escalar usual).

Llamaremos espacio euclídeo a un espacio vectorial dotado de un producto escalar. El producto escalar se denotará por $u \cdot v$. También se puede utilizar la notación $\langle u, v \rangle$.

Espacios Euclídeos: Norma

Los conceptos geométricos de longitud, distancia y perpendicularidad, que son bien conocidos para $\mathbb{R}^2$ y $\mathbb{R}^3$, se definen para $\mathbb{R}^n$ y en general para cualquier espacio vectorial euclídeo V . Estos conceptos dan herramientas geométricas potentes para resolver problemas de mínimos cuadrados.

También definimos la **norma de un vector** x en un espacio con producto interior (euclideo) V es decir $x \in V$.

$$\|x\| = \sqrt{\langle x, x \rangle} \in \mathbb{R}^+$$

. Es la Norma euclídea. Ejemplo: $v = (0, 3, -3)$

$$\|v\| = \sqrt{\langle v, v \rangle} = \sqrt{0^2 + 3^2 + (-3)^2} = \sqrt{18} = 3\sqrt{2}$$

Espacios Euclídeos: Norma

Note que $\text{dist}(x, 0) = \|x - 0\| = \|x\|$

Propiedades de la norma

1. $\|x\| \geq 0$
2. $\|x\| = 0$ si solo si $x = 0$
3. $\|\lambda x\| = |\lambda| \|x\|$ con $\lambda \in R$
4. $|\langle x, y \rangle| \leq \|x\| \|y\|$ **Desigualdad de Schwarz**
5. $|\langle x, y \rangle| = \|x\| \|y\|$ si solo si $x = y$
6. $\|x + y\| \leq \|x\| + \|y\|$ **desigualdad triangular**


Espacios Euclídeos: Distancia entre dos vectores.

- La **distancia entre dos vectores** $x, y \in V$ es la norma del vector diferencia entre ambos.

$$\text{dist}(x, y) = \|x - y\|$$

Table 1. Hypothetical Data for Adam and Eve

	Height (cm)	Weight (kg)
Adam	182	85
Eve	164	52



Source: Bring, J., 1996, A Geometric Approach to Compare Variables in a Regression Model, The American Statistician, 50,1, pp. 57-62.


Calcule la distancia entre Adan y Eva...

Espacios Euclídeos: Angulos

Tomado **Desigualdad de Schwarz** , para cualesquier par de vectores x y y no nulos en V . tenemos que $|\langle x, y \rangle| \leq \|x\| \cdot \|y\|$.

$$-1 \leq \frac{\langle x, y \rangle}{\|x\| \cdot \|y\|} \leq 1.$$

Desigualdad de Schwarz y coeficiente de correlacion



$$\cos \Theta = \frac{\mathbf{u}^t \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}$$

Espacios Euclídeos: Angulos.

Definición. Sean los vectores x y y no nulos en V . Definimos al ángulo entre x y y como el único ángulo θ en el intervalo $[0, \pi]$ tal que

$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \cdot \|y\|}.$$

$$\theta = \arccos \left(\frac{\langle x, y \rangle}{\|x\| \cdot \|y\|} \right), \quad 0 \leq \theta \leq \pi$$

Ejemplo: Suponga 2 vectores $x = (1, 1, 3)$, $y = (-1, 0, 4)$;

$$\theta = \arccos \left(\frac{1 \cdot (-1) + 1 \cdot 0 + 3 \cdot 4}{\sqrt{1^2 + 1^2 + 3^2} \cdot \sqrt{(-1)^2 + 0^2 + 4^2}} \right) = \arccos \left(\frac{11}{\sqrt{11} \cdot \sqrt{17}} \right) \cong 36,44^\circ$$

Ortogonalidad de vectores

Definición. Decimos que x y y son ortogonales si $\langle x, y \rangle = 0$.

Ejemplo: Ejemplo. Tomemos $\mathbb{R}^5$ con el producto interior canónico, es decir, el producto punto. Los vectores $x = (1, 0, -4, 0, 5)$ y $y = (0, 3, 0, -2, 0)$

$$\langle u, v \rangle = 1 \cdot 0 + 0 \cdot 3 + (-4) \cdot 0 + 0 \cdot (-2) + 5 \cdot 0 = 0,$$

así que **son ortogonales**.

Sean los vectores x y y no nulos en V si

$$\langle x, y \rangle = x \cdot y = 0 \Leftrightarrow \cos(\theta) = 0 \Leftrightarrow \theta = \frac{\pi}{2}$$

Una condición de perpendicularidad: $x \perp y \Leftrightarrow x \cdot y = 0$

- Un vector v es ortogonal a un subespacio S si es ortogonal a cada vector en S .
- Los subespacios S_1 y S_2 son ortogonales si cada vector en S_1 es ortogonal a cada vector en S_2
- $\cos(\theta) = 0$ implica ortogonalidad


Proyección ortogonal de un vector sobre otro

Proyección de un vector v sobre otro vector u , v se puede descomponer de manera única como $v = v_1 + v_2$ con v_1 en la dirección de u , y v_2 ortogonal a u . La componente v_1 se llama **proyección ortogonal** de v sobre u , y se denota $proy_u(v)$. Notar que $proy_u(v)$ es un múltiplo de u . Se calcula :

$$proy_u(v) = \frac{u \cdot v}{u \cdot u} u = \frac{\langle u, v \rangle}{\|u\|^2} u$$

Una vez hallada la componente v_1 , se puede calcular la otra componente v_2 como $v_2 = v - v_1$


Definición: Sean u y v dos vectores de V_n con $u \neq 0$: La proyección ortogonal de v sobre u , denotada $Proy_u(v)$, es el vector $Proy_u(v) = \frac{u \cdot v}{u \cdot u} u = \frac{\langle u, v \rangle}{\|u\|^2} u$



Proyección ortogonal de un vector sobre otro

Ejemplo

En $\mathbb{R}^2$, proyecta el vector $v = (1, 2)$ sobre el $u = (3, 1)$



$$Proy_u(v) = \frac{\langle u, v \rangle}{\|u\|^2} u = \frac{1 * 3 + 2 * 1}{3^2 + 1^2} * (3, 1) = \frac{5}{10} (3, 1) = \left(\frac{3}{2}, \frac{1}{2}\right)$$

Proyección ortogonal de un vector sobre un subespacio

Dado un vector v y un subespacio S , v se puede descomponer de manera única como $v = v_1 + v_2$, con $v_1 \in S$ y v_2 en la dirección ortogonal a S se llama proyección ortogonal de v sobre S , y se denota

$$Proy_S(v) = \frac{u_1 \cdot v}{u_1 \cdot u_1} u_1 + \dots + \frac{u_n \cdot v}{u_n \cdot u_n} u_n$$

donde $(u_1, \dots, u_n)$ han de formar una base ortogonal de S .

La matriz de proyección

Permite obtener la proyección de un vector cualquiera v sobre un subespacio S de $\mathbb{R}^n$ sin necesidad de hallar una base ortogonal de S .

$Proy_S(v) = P_S(v)$ Se calcula como

$$P_S(v) = A(A^t A)^{-1} A^t v$$

, donde A es la matriz que contiene una base de S en sus columnas (A no tiene porqué ser cuadrada)

Ejemplo: En $\mathbb{R}^3$, proyecta el vector $u = (3, 2, 2)$ sobre el subespacio S generado por los vectores $(2, 0, 1)$ y $(0, 3, 0)$

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \\ 1 & 0 \end{pmatrix}$$

$$P_S = A (A^t A)^{-1} A^t = \begin{pmatrix} 2 & 0 \\ 0 & 3 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 5 & 0 \\ 0 & 9 \end{pmatrix}^{-1} \begin{pmatrix} 2 & 0 & 1 \\ 0 & 3 & 0 \end{pmatrix} = \begin{pmatrix} \frac{4}{5} & 0 & \frac{2}{5} \\ 0 & 1 & 0 \\ \frac{2}{5} & 0 & \frac{1}{5} \end{pmatrix}$$

$$P_S \cdot v = \begin{pmatrix} \frac{4}{5} & 0 & \frac{2}{5} \\ 0 & 1 & 0 \\ \frac{2}{5} & 0 & \frac{1}{5} \end{pmatrix} \begin{pmatrix} 3 \\ 2 \\ 2 \end{pmatrix} = \begin{pmatrix} \frac{16}{5} \\ 2 \\ \frac{8}{5} \end{pmatrix}$$

Espacio columna de una Matriz

Definición Sea A una matriz $m \times n$, el espacio columna de A es el conjunto de aquellos vectores de R^m que se pueden expresar como combinaciones lineales de las n columnas de la matriz A . Así, el espacio columna de A consiste de aquellos vectores de la forma

$$x_1 a_1 + x_2 a_2 + \cdots + x_n a_n$$

Donde $x_1, x_2, \dots, x_n$ son escalares y los vectores $a_1, a_2, \dots, a_n$ son las columnas de la matriz A . Observe que la formula anterior es Ax .

Teorema Para cualquier matriz A de $m \times n$ y vector b en R^m : b esta en el espacio columna de A si y solo si $Ax = b$ es consistente.

Espacio columna de una Matriz

Ejemplo

{

indique si el espacio columna de A incluye al vector $b = (4, -2, -3)$Si pertenece...!!

```
library(matlib)
A <- matrix(c(2, -4, 0, 0, -1, 2, 0, 0, 0, 0, 1, 2), 3, 4, byrow=TRUE)
b <- c(4, -2, -3)
Ab=cbind(A,b) # A aumentada con b
R(A) # Rango de A
```

```
## [1] 2
```

```
R(Ab) # Rango de A aumentada con columna b
```

```
## [1] 2
```

Espacio renglon de una Matriz

Definición El espacio renglon de una matriz A de $m \times n$ es el conjunto de todos los vectores de R^n que son combinaciones lineales de los renglones de A . Así, la forma general del espacio renglon de A es:

$$x_1 a_1 + x_2 a_2 + \cdots + x_m a_m$$

donde $x_1, x_2, \dots, x_m$ son escalares y $a_1, a_2, \dots, a_m$ son los renglones de A .

Notación

1. El símbolo $C(A)$ representará el espacio columna de la matriz A .
2. El símbolo $R(A)$ representará el espacio renglón de A .

Espacio nulo de una Matrix

Definición. Espacio nulo. El espacio nulo de una matriz A de $m \times n$ se define como el espacio vectorial que consiste en la solución del sistema de ecuaciones $Ax = 0$. El espacio nulo de A se denota por $N(A)$ y se puede escribir como

$$N(A) = \{x : Ax = 0\}$$

¿Cuál es la dimensión de los vectores en $N(A)$? ¿Cuántos vectores hay en una base de $N(A)$?

- $\dim(N(A)) = n - \text{rango}(A)$ e la Nulidad de A

Espacio Nulo de una Matriz

Definición: Espacio nulo de una matriz Sea $A \in M_{m \times n}$. El espacio nulo de A se define como:

$$N(A) = \{v \in \mathbb{R}^n \mid Av = 0\}$$

Ejemplo:

$$A = \begin{pmatrix} 1 & -3 & -2 \\ -5 & 9 & 1 \end{pmatrix}$$

El vector $v = (5, 3, -2)$ tiene la propiedad de que $Av = 0$

Teorema: $N(A)$ es un subespacio vectorial de $\mathbb{R}^n$

Geometría del Modelo Lineal Gauss-Markov

El modelo lineal general

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon$$

Donde la matriz diseño X tiene dimensión, con $n \times k$, es fija (no estocástica) con $n > k$. β es un vector de constantes desconocido de dim $k \times 1$ El vector e de errores consiste de n variables independientes e idénticamente i.i.d. tal que

$E(e) = 0$ y $E(ee') = \sigma^2 I$ donde σ^2 es un parámetro desconocido.

-Teniendo un valor real de Y , los objetivos habituales son estimar σ^2 , $X\beta$ o incluso β y descubrir si es posible hacer el modelo más preciso. Usando ejemplos simples revisaremos cómo estos objetivos se pueden lograr fácilmente a través de la interpretación geométrica de la modelo.

Mínimos cuadrados como proyección ortogonal

Estimando $X\beta$: una proyección ortogonal

Sea $\hat{\beta}$ cualquier solución de las ecuaciones normales

$$X^t X = Xy$$

para el modelo $y = X\beta + \varepsilon$.

Con:

- $\hat{y} = X\hat{\beta}$ y residuales $\hat{e} = y - \hat{y} = y - X\hat{\beta}$, para que el vector y de observaciones admita la descomposición

$$y = \hat{y} + \hat{e}$$

- . Claramente $\hat{y} \in C(X)$, y $\hat{e} \in N(X^t)$.
- $\hat{y}$ y $\hat{e}$ son ortogonales.

$$\hat{y}^t \hat{e} = \hat{\beta}^t X^t (y - X\hat{\beta}) = \hat{\beta}^t (X^t y - X^t X \hat{\beta}) = 0.$$

El espacio columna de la Matriz de Diseño

- $X\beta$ es una combinación lineal de las columnas de X
- El conjunto de todas las posibles combinaciones lineales de las columnas de X es llamado el espacio de columnas de X y se denota por

$$C(X) = [Xa \in R^k]$$

Consideraciones geometricas en el Modelo lineal

En el modelo Gauss-Markov lineal, y es un vector aleatorio cuya media $E(y) = X\beta \in C(X)$ es el espacio de columnas de X cuya varianza es $\sigma^2 I$ para algún número real positivo

Consistencia. Recuerde que un sistema lineal $Ax = b$ es consistente si existe una x^* tal que $Ax^* = b$; es decir, si $b \in C(A)$.

Aplicando esta definición a las Ecuaciones Normales

$$X^t X \beta = X^t y,$$

son consistentes si $X^t y \in C(X^t X)$. Claramente, $X^t y \in C(X^t)$. Por lo tanto, vamos a ser capaz de establecer consistencia (geométricamente) si podemos mostrar que $C(X^t X) = C(X^t)$.

$$C(X^t X) = C(X^t) \Rightarrow r(X^t X) = r(X^t) = r(X)$$

$$N(X^t X) = N(X)$$

Consideraciones geometricas en el Modelo lineal

Resultado: $Q(\beta) = (Y - X\beta)^t(Y - X\beta)$ es minimizada en $\hat{\beta}$ si solo si if $\hat{\beta}$ es una solución de las ecuaciones normales ($X^tX\beta = X^ty$).

Invarianza: Se tienen $\hat{\beta}$ y $\tilde{\beta}$ resuelven las ecuaciones normales, entonces $X\hat{\beta} = X\tilde{\beta}$. En otras palabras, $X\hat{\beta}$ es invariante a la elección de $\hat{\beta}$.

Resultado: Un estimador $\hat{\beta}$ es un estimador de mínimos cuadrados si y solo si $X\hat{\beta} = My$, donde M es la matriz de proyección ortogonal sobre $C(X)$.

Consideraciones geometricas en el Modelo lineal

Proyector P_X

Teorema. $P_X = X(X^t X)^{-} X^t$ es una matriz de proyección ortogonal sobre $C(X)$, esto es, P_X es

- idempotente
- proyecta sobre $C(X)$,
- es invariante ante cualquier inversa generalizada,
- simetrica, y unica.

Proyector M_X

Resultado $M_X = (I - P_X)$ es la unica, proyeccion simetrica sobre $N(X^t)$.

Consideraciones geometricas en el Modelo lineal

Resultado. Suponga X es de $n \times p$ con rango $r \leq p$, y sea P_X una matriz de proyección ortogonal sobre $C(X)$. Entonces $r(P_X) = r(X) = r$ y $r(M_X) = r(I - P_X) = n - r$.

- En el Modelo lineal **la predicción de y**

$$P_X y = X\hat{\beta} \equiv \hat{y}$$

Es unica.


Llamamos a $\hat{y}$ el vector de valores ajustados o predichos.

- Geométricamente, $\hat{y}$ es el punto en $C(X)$ que está más cerca de y .
- $M_X = I - P_X$ es la matriz de proyección perpendicular sobre $N(X^t)$. Note que

$$M_X y = (I - P_X)y = y - P_X y = y - \hat{y} \equiv \hat{e}.$$

Llamamos a $\hat{e}$ el **vector de residuales**.

Proyección ortogonal de y sobre $C(x)$



Ejemplo ilustrativo: Estimacion de la media

Suponga un investigador entrevista aleatoriamente dos productores de maiz y les pregunta sobre el rendimiento promedio de maiz por hectárea obtenido en el ciclo de cultivo, las respuesta fueron (6.1, 2.3) ton/ha. Estime el rendimiento promedio (μ) usando enfoque geométrico del modelo lineal.

Modelo Lineal

$$y = X\beta + \epsilon$$

$$\begin{pmatrix} y_1 = 6.1 \\ y_2 = 2.3 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \mu + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \end{pmatrix}$$

$$X = \begin{pmatrix} 1 \\ 1 \end{pmatrix}; \quad X^t X = (1 \quad 1) \begin{pmatrix} 1 \\ 1 \end{pmatrix} = 2; \quad (X^t X)^- = \frac{1}{2}$$


$$P_X = X(X^t X)^- X^t = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \frac{1}{2} (1 \quad 1) = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 1/2 & 1/2 \\ 1/2 & 1/2 \end{pmatrix}$$

$$\hat{\beta} = \hat{\mu} = (X^t X)^- X^t y = \frac{1}{2} (1 \quad 1) \begin{pmatrix} 6.1 \\ 2.3 \end{pmatrix} = \frac{6.1 + 2.3}{2} = 4.2$$

Ejemplo ilustrativo: Estimacion de la media

Proyeccion ortogonal $P_X y = \hat{y}$

$$\hat{y} = P_X y = X(X^t X)^{-1} X^t y = \begin{pmatrix} 1/2 & 1/2 \\ 1/2 & 1/2 \end{pmatrix} \begin{pmatrix} 6.1 \\ 2.3 \end{pmatrix} = \begin{pmatrix} 4.2 \\ 4.2 \end{pmatrix}$$



Residuales $M_X y$

$$\hat{y} - y = M_X y = (I - X(X^t X)^{-1} X^t) y = \left(\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} 1/2 & 1/2 \\ 1/2 & 1/2 \end{pmatrix} \right) \begin{pmatrix} 6.1 \\ 2.3 \end{pmatrix} = \begin{pmatrix} 1.9 \\ -1.9 \end{pmatrix}$$

Ejemplo 2:

$$y = X\beta + \epsilon$$

$$\begin{pmatrix} y_1 = 1 \\ y_2 = 2 \\ y_3 = 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \end{pmatrix}$$


$$P_X = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}; \quad M_X = (I - P_X) = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

Prediccion y residuales


$$\hat{y} = P_X y = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix}; \quad \hat{e} = M_X y = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 2 \end{pmatrix}$$

Ejemplo 2:

Proyección ortogonal



ANOVA Y PITAGORAS



De esta figura se puede observa la estimación MCO, Ajuste y ANOVA.

Coeficiente de ajuste R^2

$$R^2 = (\cos(\theta))^2 = \frac{\|P_X y\|^2}{\|y\|^2} \in [0, 1]$$

Sumas de Cuadrados (de Pitagoras)

- Suma de cuadrados total = $\|y\|^2 = y^t y = \sum_{i=1}^n y_i^2$
- suma de cuadrados del modelo = $\|P_X y\|^2 = y^t P_X y = \hat{y}^t \hat{y}$
- suma de cuadrados del error = $\|M_X y\|^2 = y^t M_X y = \hat{e}^t \hat{e}$

la descomposición de sumas de cuadrados

$$\begin{aligned} y^t y &= y^t I y = y^t (P_X + I - P_X) y \\ &= y^t P_X y + y^t (I - P_X) y \\ &= y^t P_X P_X y + y^t (I - P_X) (I - P_X) y \\ &= \hat{y}^t \hat{y} + \hat{e}^t \hat{e}, \end{aligned}$$

Tabla de ANOVA con Geometria

La descomposición ortogonal de $y^t y$ se presenta en forma de tabla de análisis de varianza (ANOVA).

TABLA DE ANOVA: suponga que y es $n \times 1$, X es $n \times p$ con rango $r \leq p$, β es $p \times 1$ y ε es $n \times 1$.

<i>Fuente</i>	Grados de libertad	Suma de cuadrados	Cuadrados medios	<i>Fc</i>
<i>Modelo</i>	$r = r(P_X)$	$\hat{y}^t \hat{y} = y^t P_X y$	$\frac{y^t P_X y}{r}$	$\frac{\frac{y^t P_X y}{r}}{\frac{y^t (I - P_X) y}{n - r}}$
<i>Residual</i>	$n - r = r(I - P_X)$	$\hat{e}^t \hat{e} = y^t (I - P_X) y$	$\frac{y^t (I - P_X) y}{n - r}$	
<i>Total</i>	n	$y^t y = y^t I y$		

\$Fc\$ de Fisher

$$Fc = \frac{\frac{||P_X y||^2}{r(P_X)}}{\frac{||M_X y||^2}{r(M_X)}}$$

Ejemplo 2:

$$y = X\beta + \epsilon$$
$$\begin{pmatrix} y_1 = 1 \\ y_2 = 2 \\ y_3 = 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \end{pmatrix}$$

Normas al cuadrado del triángulo de pitágoras

- $\|y\|^2 = y^t y = \sum_{i=1}^n y_i^2 = 1^2 + 2^2 + 2^2 = 9$
- $\|P_X y\|^2 = y^t P_X y = \hat{y}^t \hat{y} = 1^2 + 2^2 + 0^2 = 5$
- $\|M_X y\|^2 = y^t M_X y = \hat{e}^t \hat{e} = 0^2 + 0^2 + 2^2 = 4$

$$R^2 = \cos(\theta) = \frac{\|P_X y\|^2}{\|y\|^2} = \frac{5}{9} = 0.555$$

$$r(P_X) = 2, \quad r(M_X) = (3 - 2) = 1; \quad n = 3$$

<i>Fuente</i>	Grados de libertad	Suma de cuadrados	Cuadrados medios	<i>Fc</i>
<i>Modelo</i>	2	5	$5/2 = 2.5$	$\frac{5/2}{4} = 0.625$
<i>Residual</i>	1	4	$4/1$	
<i>Total</i>	3	9		

Ejemplo 2 en R

```
y=c(1,2,2)
x1=c(1,1,0)
x2=c(0,1,0)
regre=lm(y~-1+x1+x2)
summary(regre)
```

```
##
## Call:
## lm(formula = y ~ -1 + x1 + x2)
##
## Residuals:
##  1  2  3
##  0  0  2
##
## Coefficients:
##      Estimate Std. Error t value Pr(>|t|)
## x1      1.000      2.000   0.500   0.705
## x2      1.000      2.828   0.354   0.784
##
## Residual standard error: 2 on 1 degrees of freedom
## Multiple R-squared:  0.5556,    Adjusted R-squared:  -0.3333
## F-statistic: 0.625 on 2 and 1 DF,  p-value: 0.6667
```

Ejemplo

Ejemplo: Longitud del catéter

Ejemplo Para 12 pacientes jóvenes, los catéteres se alimentaron desde una vena principal hasta el corazón. Se midió la longitud del catéter al igual que la altura y el peso de los pacientes. ¿Es posible predecir la longitud necesaria del catéter en función de la altura y el peso?

Reference: S Weisberg, Applied Linear Regression, Wiley, 1980, page 218

Deseamos ajustar el modelo:

$$y_i = \beta_1 x_i + \beta_2 x_i + \epsilon_i \quad \text{for } i = 1, \dots, n$$

Datos

Patient	Height	Weight	Catheter
1	42.8	40	37
2	63.5	93.5	50
3	37.5	35.5	34
4	39.5	30	36
5	45.5	52	43
6	38.5	17	28
7	43	38.5	37
8	22.5	8.5	20
9	37	33	34
10	23.5	9.5	30
11	33	21	38
12	58	79	47

Modelo Lineal

$$Y = X\beta + \varepsilon$$

$$\underbrace{\begin{bmatrix} 37 \\ 50 \\ 34 \\ 36 \\ 43 \\ 28 \\ 37 \\ 20 \\ 34 \\ 30 \\ 38 \\ 47 \end{bmatrix}}_Y = \underbrace{\begin{bmatrix} 42.8 & 40.0 \\ 63.5 & 93.5 \\ 37.5 & 35.5 \\ 39.5 & 30.0 \\ 45.5 & 52.0 \\ 38.5 & 17.0 \\ 43.0 & 38.5 \\ 22.5 & 8.5 \\ 37.0 & 33.0 \\ 23.5 & 9.5 \\ 33.0 & 21.0 \\ 58.0 & 79.0 \end{bmatrix}}_X \underbrace{\begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix}}_{\beta} + \underbrace{\begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \\ \epsilon_4 \\ \epsilon_5 \\ \epsilon_6 \\ \epsilon_7 \\ \epsilon_8 \\ \epsilon_9 \\ \epsilon_{10} \\ \epsilon_{11} \\ \epsilon_{12} \end{bmatrix}}_{\epsilon}$$

Estimador de β

Modelo sin intercepto

```
x1<-c(42.8,63.5,37.5,39.5,45.5,38.5,43.0,22.5,37.0,23.5,33.0,58.0)
x2<-c(40.0,93.5,35.5,30.0,52.0,17.0,38.5, 8.5,33.0, 9.5,21.0,79.0)
X<-cbind(x1,x2)
y<-matrix(c(37,50,34,36,43,28,37,20,34,30,38,47),12,1)
BETA_est<- solve(t(X)%*%X)%*%t(X)%*%y
knitr::kable(BETA_est)
```

x1	1.0262867
x2	-0.1468127

datos cateter: $(X^t X)^{-1}$

para obtener $(X^t X)^{-1}$:

```
XtXinv<-solve(t(X)%*%X)
XtXinv
```

```
##              x1              x2
## x1  0.0004718799 -0.000412036
## x2 -0.0004120360  0.000399924
```

multiplicando $(X^t X)^{-1}$ por $\hat{\sigma}^2$ para obtener la matriz de varianzas y covarianzas de $\hat{\beta}$.

Residuales de datos Catheter

```
P<-X%%solve(t(X)%*%X)%*%t(X)  
res<-(diag(12)-P)%*%y  
knitr::kable(res)
```

-1.0525617

-1.4422172

0.7261005

-0.1339425

3.9382164

-9.0162207

-1.4780381

-1.8435420

0.8722121

7.2769841

7.2156066

Estimacion de $\hat{\sigma}^2$

parab obtener $\hat{\sigma}^2$:

```
sig2hat<-(t(res)%*%res)/(nrow(X)-2-1)
sig2hat
```

```
##           [,1]
## [1,] 23.63962
```

para obtener la matriz de varianzas y covarianzas de $\hat{\beta}$.

```
as.numeric(sig2hat)*XtXinv
```

```
##           x1           x2
## x1  0.011155061 -0.009740374
## x2 -0.009740374  0.009454051
```

Inferencia para $\hat{\beta}$

Dado que ahora tenemos $\hat{\beta}$ y la matriz de covarianza estimada para $\hat{\beta}$, podemos hacer los tipos estándar de inferencia estadística (encontrar intervalos de confianza y realizar pruebas de hipótesis).
como se tuvo que estimar σ^2 , debemos usar un valor de la distribución t t_{n-k-1} Para obtener un $(1 - \alpha)$ intervalo de confianza del 100% para β Para obtener un intervalo de confianza del $(1 - \alpha)100\%$ para β_i :
 $\hat{\beta}_i \pm t_{n-k-1}(1 - \alpha/2) \times se(\hat{\beta}_i)$

Para probar $H_0 : \beta_i = k$, calculamos

$$t_{cal} = (\beta_i - k) / se(\hat{\beta}_i)$$

$$p - value = 2 \times Pr(t_{n-k-1} \geq |t_{cal}|)$$

Ejemplo para $\hat{\beta}_1$

Un IC del 95% para β_1 :

$$\hat{\beta}_1 \pm t_9(.975) \times se(\hat{\beta}_1)$$

$$0.211 \pm 2.26\sqrt{0.119}$$

$$0.211 \pm 0.782$$

O para probar $H_0 : \beta_1 = 0$


$$t_{calc} = (\beta_i)/se(\hat{\beta}_i) = 2.11/\sqrt{0.119} = 0.611$$

$$p - value = 2 \times Pr(t_{n-k-1} \geq |t_{cal}|) = 2 \times Pr(t_9 \geq 0.611) = 0.56$$

Proyección ortogonal de Y

Proyectando y sobre al espacio de columnas de X da nuestro vector medio estimado $\hat{y}$ (es decir, los valores ajustados)

$$\hat{y} = Py = X(X^tX)^{-1}X^ty$$



Proyectores P

$$P = X(X^t X)^{-1} X^t$$

```
P<-round(X%%solve(t(X)%%X)%%t(X),2)
P
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]
## [1,] 0.09 0.08 0.08 0.10 0.08 0.12 0.10 0.07 0.08 0.07 0.09 0.09
## [2,] 0.08 0.51 0.08 0.00 0.19 -0.14 0.06 -0.10 0.05 -0.09 -0.05 0.39
## [3,] 0.08 0.08 0.07 0.08 0.07 0.10 0.08 0.06 0.07 0.06 0.07 0.08
## [4,] 0.10 0.00 0.08 0.12 0.06 0.17 0.11 0.10 0.09 0.11 0.12 0.03
## [5,] 0.08 0.19 0.07 0.06 0.11 0.04 0.08 0.02 0.07 0.02 0.04 0.16
## [6,] 0.12 -0.14 0.10 0.17 0.04 0.28 0.13 0.17 0.11 0.18 0.18 -0.07
## [7,] 0.10 0.06 0.08 0.11 0.08 0.13 0.10 0.08 0.09 0.08 0.10 0.07
## [8,] 0.07 -0.10 0.06 0.10 0.02 0.17 0.08 0.11 0.07 0.11 0.11 -0.05
## [9,] 0.08 0.05 0.07 0.09 0.07 0.11 0.09 0.07 0.08 0.07 0.08 0.06
## [10,] 0.07 -0.09 0.06 0.11 0.02 0.18 0.08 0.11 0.07 0.11 0.11 -0.05
## [11,] 0.09 -0.05 0.07 0.12 0.04 0.18 0.10 0.11 0.08 0.11 0.12 -0.01
## [12,] 0.09 0.39 0.08 0.03 0.16 -0.07 0.07 -0.05 0.06 -0.05 -0.01 0.31
```

Proyección ortogonal de y sobre $C(X)$

podemos proyectar y sobre el espacio de columnas de X y obtener $\hat{y}$

```
P<-X%%solve(t(X)%*%X)%*%t(X)
pred<-(P)%*%y
pred
```

```
##           [,1]
## [1,] 38.05256
## [2,] 51.44222
## [3,] 33.27390
## [4,] 36.13394
## [5,] 39.06178
## [6,] 37.01622
## [7,] 38.47804
## [8,] 21.84354
## [9,] 33.12779
## [10,] 22.72302
## [11,] 30.78439
## [12,] 47.92642
```


Predicciones de datos Catheter

Vector de residuales r

El vector de residuales se define:

$$r = y - \hat{y} = y - Py = My$$

$$r = (I - X(X^tX)^{-1}X^t)y$$



Proyectores M

$$M = I - X(X^t X)^{-1} X^t$$

```
I=diag(nrow(X))  
M<-round(I-X%%solve(t(X)%*%X)%*%t(X),2)  
M
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]  
## [1,]  0.91 -0.08 -0.08 -0.10 -0.08 -0.12 -0.10 -0.07 -0.08 -0.07 -0.09 -0.09  
## [2,] -0.08  0.49 -0.08  0.00 -0.19  0.14 -0.06  0.10 -0.05  0.09  0.05 -0.39  
## [3,] -0.08 -0.08  0.93 -0.08 -0.07 -0.10 -0.08 -0.06 -0.07 -0.06 -0.07 -0.08  
## [4,] -0.10  0.00 -0.08  0.88 -0.06 -0.17 -0.11 -0.10 -0.09 -0.11 -0.12 -0.03  
## [5,] -0.08 -0.19 -0.07 -0.06  0.89 -0.04 -0.08 -0.02 -0.07 -0.02 -0.04 -0.16  
## [6,] -0.12  0.14 -0.10 -0.17 -0.04  0.72 -0.13 -0.17 -0.11 -0.18 -0.18  0.07  
## [7,] -0.10 -0.06 -0.08 -0.11 -0.08 -0.13  0.90 -0.08 -0.09 -0.08 -0.10 -0.07  
## [8,] -0.07  0.10 -0.06 -0.10 -0.02 -0.17 -0.08  0.89 -0.07 -0.11 -0.11  0.05  
## [9,] -0.08 -0.05 -0.07 -0.09 -0.07 -0.11 -0.09 -0.07  0.92 -0.07 -0.08 -0.06  
## [10,] -0.07  0.09 -0.06 -0.11 -0.02 -0.18 -0.08 -0.11 -0.07  0.89 -0.11  0.05  
## [11,] -0.09  0.05 -0.07 -0.12 -0.04 -0.18 -0.10 -0.11 -0.08 -0.11  0.88  0.01  
## [12,] -0.09 -0.39 -0.08 -0.03 -0.16  0.07 -0.07  0.05 -0.06  0.05  0.01  0.69
```

Proyección ortogonal de y sobre $C(X^\perp)$

podemos proyectar y sobre el espacio $C(X^\perp)$ y obtener $\hat{e}$


```
P<-X%%solve(t(X)%*%X)%*%t(X)
res<-(diag(12)-P)%*%y
res
```

```
##           [,1]
## [1,] -1.0525617
## [2,] -1.4422172
## [3,]  0.7261005
## [4,] -0.1339425
## [5,]  3.9382164
## [6,] -9.0162207
## [7,] -1.4780381
## [8,] -1.8435420
## [9,]  0.8722121
## [10,]  7.2769841
## [11,]  7.2156066
## [12,] -0.9264245
```

Residuales de datos Catheter

Ajuste R^2 (coeficiente de determinación)


$$R^2 = (\cos(\theta))^2 = \frac{||Py||^2}{||y||^2}$$



Teorema de Pitagoras y ANOVA de Fisher

$$||y||^2 = ||Py||^2 + ||My||^2$$

$$SCT = SCM + SCE$$



Ejemplo: Normas al cuadrado de vectores

$$||y||^2$$

```
SCT=t(y)%*%y  
SCT
```

```
##           [,1]  
## [1,] 16432
```

$$||Py||^2$$

```
P<-X%*%solve(t(X)%*%X)%*%t(X)  
Py=P%*%y  
SCM=t(Py)%*%Py  
SCM
```

```
##           [,1]  
## [1,] 16219.24
```

Ejemplo: Normas al cuadrado de vectores

$$||My||^2$$

```
M<-I-X%%solve(t(X)%*%X)%*%t(X)
My=M%*%y
SCE=t(My)%*%My
SCE
```

```
##           [,1]
## [1,] 212.7566
```

Ajuste de la regresion

```
modelo=lm(y~-1+x1+x2)
summary(modelo)
```

```
##
## Call:
## lm(formula = y ~ -1 + x1 + x2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -9.0162 -1.4512 -0.5302  1.6387  7.2770
##
## Coefficients:
##      Estimate Std. Error t value Pr(>|t|)
## x1   1.02629     0.10020   10.243 1.28e-06 ***
## x2  -0.14681     0.09224   -1.592   0.143
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.613 on 10 degrees of freedom
## Multiple R-squared:  0.9871,    Adjusted R-squared:  0.9845
## F-statistic: 381.2 on 2 and 10 DF,  p-value: 3.639e-10
```

Ejemplo ANOVA

```
library(sasLM)
x1<-c(42.8,63.5,37.5,39.5,45.5,38.5,43.0,22.5,37.0,23.5,33.0,58.0)
x2<-c(40.0,93.5,35.5,30.0,52.0,17.0,38.5, 8.5,33.0, 9.5,21.0,79.0)
y<-matrix(c(37,50,34,36,43,28,37,20,34,30,38,47),12,1)
dat=data.frame(cbind(y,x1,x2))
aov3(y~-1+x1+x2,dat)
```

```
## Response : y
```

##		Df	Sum Sq	Mean Sq	F value	Pr(>F)	
##	MODEL	2	16219.2	8109.6	381.1691	3.639e-10	***
##	x1	1	2232.1	2232.1	104.9115	1.275e-06	***
##	x2	1	53.9	53.9	2.5332	0.1426	
##	RESIDUALS	10	212.8	21.3			
##	UNCORRECTED TOTAL	12	16432.0				
##	---						
##	Signif. codes:	0	'***'	0.001	'**'	0.01	'*' 0.05 '.' 0.1 ' ' 1

Ejemplo R^2

```
R2=SCM/SCT  
R2
```

```
##           [,1]  
## [1,] 0.9870523
```

Características de probabilidad de las proyecciones ortogonales

Supongamos que el vector aleatorio Y de n componentes sigue la distribución normal $N(0, I_n)$ y que lo proyectamos ortogonalmente en dos subespacios M y K de dimensiones m y k , que son ortogonales entre sí. Es fácil probar que

- $||Y||^2 \sim \chi_m^2$
- $\frac{||Y_m||^2}{||Y_k||^2} \sim F_{m,k}$