

Notas del curso de modelo lineal


Prueba de Hipotesis en el Modelo Lineal

Humberto Vaquera Huerta
Primavera 2024

Prueba de Hipotesis de ANOVA

Inferencia en el modelo lineal

Mapa conceptual



Prueba de Hipotesis de ANOVA

Considere el modelo $y = X\beta + \varepsilon$, donde $\beta^t = (\beta_0, \beta_1, \dots, \beta_p)$ con el supuesto que $\varepsilon \sim N_n(0, \sigma^2 I_n)$ Se desea probar el hecho de que ninguna variable independiente (exogena) explica la variable respuesta:

- $H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$
- vs H_A : al menos un β_i

Prueba de Hipotesis de ANOVA

Tabla de ANOVA para probar $H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$

Considere la partición (corregida) de la suma de cuadrados dada por

$$\mathbf{y}^t(I - \frac{1}{n}J)\mathbf{y} = \mathbf{y}^t(P_X - \frac{1}{n}J)\mathbf{y} + \mathbf{y}^t(I - P_X)\mathbf{y}$$

$$SCT_c = SCM_c + SCE$$

Se construye


Fuentes de Variación	Grados de libertad	Sumas de Cuadrados	Cuadrados medios	F cal	F tablas	Pvalue
Modelo	$r(P_X - \frac{1}{n}J)$	$\mathbf{y}^t(P_X - \frac{1}{n}J)\mathbf{y}$	$CMM = \frac{\mathbf{y}^t(P_X - \frac{1}{n}J)\mathbf{y}}{r(P_X - \frac{1}{n}J)}$	$FC = \frac{CMM}{CME}$		
Error	$r(I - P_X)$	$\mathbf{y}^t(I - P_X)\mathbf{y}$	$CME = \frac{\mathbf{y}^t(I - P_X)\mathbf{y}}{r(I - P_X)}$			
Total	$r(I - \frac{1}{n}J)$	$\mathbf{y}^t(I - \frac{1}{n}J)\mathbf{y}$				

Ejemplo: Superficie de respuesta

La Dureza, y_i , de yeso fue medida para cada una de las 9 combinaciones de contenido de **arena** y contenido de **fibra**. El contenido de arena (S_i) se configuró en uno de los 3 niveles, al igual que el contenido de fibra (f_i). Se probaron todas las combinaciones posibles, cada una en dos lotes de yeso. datos:

<i>Sand</i>	<i>Fibre</i>	<i>Hardness</i>
0	0	61
0	0	63
15	0	67
15	0	69
30	0	65
30	0	74
0	0.25	69
0	0.25	69
15	0.25	69
15	0.25	74
30	0.25	74
30	0.25	72
0	0.5	67
0	0.5	69
15	0.5	69
15	0.5	74
30	0.5	74
30	0.5	74

Ejemplo: Superficie de respuesta



Modelo:

$$y_i = \beta_0 + \beta_1 S_i + \beta_2 S_i^2 + \beta_3 f_i + \beta_4 f_i^2 + \beta_5 S_i f_i + \varepsilon_i$$

Suponga $\varepsilon_i \sim n(0, \sigma^2)$ Deseamos probar $H_0: \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = 0$ vs H_A : al menos un β_i

Ejemplo: Superficie de respuesta

Tabla de ANOVA

$$H_0: \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = 0$$

ANÁLISIS DE VARIANZA Modelo		$Y_i = \beta_0 + \beta_1 s_i + \beta_2 s_i^2 + \beta_3 f_i + \beta_4 f_i^2 + \beta_5 s_i f_i + \epsilon_i$			
Completo					
	Grados de libertad	Suma de cuadrados	Promedio de los cuadrados	F	Valor crítico de F
Regresión	5	195.013889	39.0027778	5.759426	0.00614704
Residuos	12	81.263889	6.77199074		
Total	17	276.277778			

Se rechaza H_0

Prueba de la hipótesis lineal general

Prueba de la hipótesis lineal general

La variedad de hipótesis que podríamos querer probar es bastante extensa, por ejemplo:

- $H_1 : \beta_j = 0$
- $H_2 : \beta_1 = \beta_2 = \beta_3 = 0$
- $H_3 : \beta_1 + \beta_3 = 1, \beta_2 = 3$
- $H_4 : \beta_2 = \beta_3 = \beta_4$
- $H_5 : \beta \in C(B)$

Todos estos ejemplos se pueden escribir como un sistema de ecuaciones lineales:

$$H_0 : C\beta = r \text{ versus } H_1 : C\beta \neq r,$$

donde C es $p \times s$ de rango completo por columna. $C^t \in \mathcal{C}(X)$.

Prueba de la hipótesis lineal general

Definición (Hipótesis comprobable)

La hipótesis lineal general $H_0 : C\beta = r$ es **comprobable** si y sólo si C tiene rango completo por columna y cada componente de $C\beta$ es estimable. Si alguno de los componentes de $C\beta$ no son estimables, entonces la hipótesis se considera no comprobable.

- O de manera equivalente la matrix C debe satisfacer la condición

$$CX(X^tX)^-X^t = C$$

para que la hipótesis H sea comprobable.

Pruebas de hipótesis en ANOVA

Mientras que en un problema de regresión la atención se centra generalmente en la estimación, en el caso de ANOVA generalmente se hace en la prueba de hipótesis.

Considere la prueba de hipótesis sobre la β En el modelo

$$\mathbf{Y} = \mathbf{X}\beta + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim N(0, \sigma^2 I)$$

, donde X es $n \times p$ de rango $k < p \leq n$, y $\mathbf{y} \sim N(\mathbf{X}\beta, \sigma^2 I)$..

Hipótesis comprobables

Existe una estrecha conexión entre las funciones estimables y si se puede o no probar una hipótesis:

Definición

Una hipótesis tal como $H_0 : \beta_1 = \beta_2$ se dice comprobable si existen funciones estimables linealmente independientes $\lambda_1^t \beta, \lambda_2^t \beta, \dots, \lambda_k^t \beta$ tales que H_0 es verdadera si solo si

$$\lambda_1^t \beta = \dots = \lambda_k^t \beta = 0$$

Hipótesis lineal general

Teorema Si $\mathbf{y} \sim N_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I})$, donde $\mathbf{X}$ es de rango $k < p \leq n$, si $\mathbf{C}$ es $m \times p$ de rango $m \leq k$ tal que $\mathbf{C}\boldsymbol{\beta}$ es un conjunto de m funciones estimables linealmente independientes, y si $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y}$ es una solución de las EN, entonces

- $\mathbf{C}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{C}'$ es no singular
- $\mathbf{C}\hat{\boldsymbol{\beta}} \sim N_m[\mathbf{C}\boldsymbol{\beta}, \sigma^2 \mathbf{C}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{C}']$
- $\text{SSH}/\sigma^2 = (\mathbf{C}\hat{\boldsymbol{\beta}})'[\mathbf{C}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{C}']^{-1} \mathbf{C}\hat{\boldsymbol{\beta}}/\sigma^2 \sim \chi^2(m, \lambda)$ donde $\lambda = (\mathbf{C}\boldsymbol{\beta})' \mathbf{C}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{C}' \mathbf{C}\boldsymbol{\beta} / (2\sigma^2)$
- $\text{SSE}/\sigma^2 = \mathbf{y}'[\mathbf{I} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}']\mathbf{y}/\sigma^2 \sim \chi^2(n - k)$
- SSH y SSE son independientes.

Hipótesis lineal general

Teorema

Bajo las condiciones del teorema anterior si $H_0 : C^t \beta = d$ es cierta:


$$F_c = \frac{SSH/m}{SSE/(n-k)} \sim F(m, n-k)$$

o

$$F_c = \frac{\frac{(C\hat{\beta}-d)^t [C(X^t X)^{-1} C^t]^{-1} (C\hat{\beta}-d)}{m}}{\frac{y^t (I - X(X^t X)^{-1} X^t) y}{(n-k)}} \sim F(m, n-k)$$


Hipótesis lineal general

Geometría de la prueba de F



Hipótesis lineal general

Geometría de la prueba de F



Hipótesis lineal general

En el caso especial cuando $C = \lambda^t$, un estadístico de prueba

$$H_0 : \lambda\beta = d \text{ vs } H_a : \lambda\beta \neq d$$

es:

$$F_c = \frac{\frac{(\lambda^t \hat{\beta} - d)^t [\lambda(X^t X)^{-1} \lambda^t]^{-1} (\lambda^t \hat{\beta} - d)}{m}}{\frac{\mathbf{y}^t (I - \mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t) \mathbf{y}}{(n-k)}} \sim F(1, n - k)$$

de manera alterna

$$T_c = \frac{\lambda^t \hat{\beta} - d}{\sqrt{\frac{(\lambda(X^t X)^{-1} \lambda^t) \mathbf{y}^t (I - \mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t) \mathbf{y}}{(n-k)}}} = \frac{\lambda^t \hat{\beta} - d}{\sqrt{(\lambda(X^t X)^{-1} \lambda^t) \times CME}}$$

Bajo H_0 , tiene una distribución t con $n - k$ grados de libertad

Prueba de t

Prueba de t

Deseamos probar

$$H_0 : \lambda^t \beta = d \text{ vs } H_a : \lambda^t \beta \neq d$$

$$T_c = \frac{\lambda^t \hat{\beta} - d}{\sqrt{(\lambda^t (X^t X)^{-1} \lambda^t) \times CME}} \sim t_{(n-k)}$$

donde $r(I - X(X^t X)^{-1} X^t) = n - k$ Donde $CME = \hat{\sigma}^2 = y^t(I - X(X^t X)^{-1} X^t)y/(n - k)$ y donde los grados de libertad del error es $r(I - X(X^t X)^{-1} X^t) = n - k$

- casos particulares $H_0 : \beta_i = 0$
- casos particulares $H_0 : \lambda^t \beta = 0$

Ejemplo:

Supongamos que tenemos el modelo aditivo (sin interacción)

$$y_{ij} = \mu + \alpha_i + \beta_j + \varepsilon_{ij}, \quad i = 1, 2, 3; j = 1, 2,$$

Queremos probar la hipótesis:

$$H_0 : \alpha_1 = \alpha_2 = \alpha_3$$

las observaciones se pueden escribir en la forma $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ como

$$\begin{pmatrix} y_{11} \\ y_{12} \\ y_{13} \\ y_{21} \\ y_{22} \\ y_{23} \\ y_{31} \\ y_{33} \\ y_{33} \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} + \begin{pmatrix} \varepsilon_{11} \\ \varepsilon_{12} \\ \varepsilon_{13} \\ \varepsilon_{21} \\ \varepsilon_{22} \\ \varepsilon_{23} \\ \varepsilon_{31} \\ \varepsilon_{33} \\ \varepsilon_{33} \end{pmatrix}$$

Ejemplo

$H_0 : \alpha_1 = \alpha_2 = \alpha_3$ se puede expresar como $H_0 : \alpha_1 - \alpha_2 = 0$, y $\alpha_1 - \alpha_3 = 0$.

- Paso 1: Verificar que $H_0 : \alpha_1 - \alpha_2 = 0$, y $\alpha_1 - \alpha_3 = 0$ es estimable (es decir H_0 es comprobable)

Note

$$H_0 : C\beta = \begin{pmatrix} 0 & 1 & -1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Ejemplo:

- Ahora $E(y_{11} - y_{21}) = (\mu + \alpha_1 + \beta_1) - (\mu + \alpha_2 + \beta_1) = \alpha_1 - \alpha_2$ por lo tanto es una función estimable.
- También $E(y_{11} - y_{31}) = (\mu + \alpha_1 + \beta_1) - (\mu + \alpha_3 + \beta_1) = \alpha_1 - \alpha_3$ por lo tanto es una función estimable.

$H_0 : \alpha_1 = \alpha_2 = \alpha_3$ es comprobable es equivalente a

$$H_0 : C\beta = \begin{pmatrix} 0 & 1 & -1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

y es **comprobable**

Ejemplo

Codigo en R para verificar $H_0 : \alpha_1 = \alpha_2 = \alpha_3$ es comprobable

```
library(matlib)
X=matrix( c(1 , 1 , 0 , 0 , 1 , 0 , 0 ,
            1 , 1 , 0 , 0 , 0 , 1 , 0 ,
            1 , 1 , 0 , 0 , 0 , 0 , 1 ,
            1 , 0 , 1 , 0 , 1 , 0 , 0 ,
            1 , 0 , 1 , 0 , 0 , 1 , 0 ,
            1 , 0 , 1 , 0 , 0 , 0 , 1 ,
            1 , 0 , 0 , 1 , 1 , 0 , 0 ,
            1 , 0 , 0 , 1 , 0 , 1 , 0 ,
            1 , 0 , 0 , 1 , 0 , 0 , 1 ), nrow=9, byrow=TRUE)

R(X)
```

```
## [1] 5
```

```
R=matrix( c(0 ,1, -1, 0, 0, 0,0,
            0 ,1, 0, -1, 0, 0,0), nrow=2, byrow=TRUE)

X_R=rbind(X,R)
R(X_R)
```

```
## [1] 5
```

Ejemplo 2: CBR decline

La Tabla muestra la disminución de Correspondent Banking Relationships (CBR) en 20 países clasificados según dos criterios: **entorno social**, con categorías *bajo* (menos de 70 años), *medio* (70-79) y *alto* (80+), y **esfuerzo de planificación familiar**, con categorías *débil* (0 –4), *moderado* (5–14) y *fuerte* (15+). En nuestro ejemplo, tanto el ajuste como el esfuerzo son factores con tres niveles. Tenga en cuenta que no hay países con programas sólidos en entornos sociales bajos.

Tabla

Table . CBR Decline by Levels of Social Setting
and Levels of Family Planning Effort

entorno social Setting	Effort esfuerzo de planificación familiar		
	Weak	Moderate	Strong
Low	1,0,7	21,13,4,7	–
Medium	10,6,2	0	25
High	9	11	29,29,40,21,22,29

Ejemplo 2

Modelo propuesto:

$$y_{ijk} = \mu + \alpha_i + \beta_j + \varepsilon_{ijk}$$

- y_{ijk} representa CBR decline,
- μ representa un valor de referencia,
- α_i representa el efecto del i-ésimo nivel del entorno social y
- β_j representa el efecto del j-ésimo nivel del esfuerzo.
- $\varepsilon_{ijk} \sim N(0, \sigma^2)$.

Ejemplo 2

Datos:

<i>Setting</i>	<i>Effort</i>	<i>CBR</i>
1	1	1
1	1	0
1	1	7
1	2	21
1	2	13
1	2	4
1	2	7
2	1	10
2	1	6
2	1	7
2	2	0
2	3	25
3	1	9
3	2	11
3	3	29
3	3	29
3	3	40
3	3	21
3	3	22
3	3	29

Ejemplo 2: CBR decline

Modelo $y = X\beta + \varepsilon$

$$\begin{pmatrix} 1 \\ 0 \\ 7 \\ 21 \\ 13 \\ 4 \\ 7 \\ 10 \\ 6 \\ 7 \\ 0 \\ 25 \\ 9 \\ 11 \\ 29 \\ 29 \\ 40 \\ 21 \\ 22 \\ 29 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} + \begin{pmatrix} \varepsilon_{111} \\ \varepsilon_{112} \\ \varepsilon_{113} \\ \varepsilon_{121} \\ \varepsilon_{122} \\ \varepsilon_{123} \\ \varepsilon_{131} \\ \varepsilon_{211} \\ \varepsilon_{212} \\ \varepsilon_{213} \\ \varepsilon_{221} \\ \varepsilon_{231} \\ \varepsilon_{311} \\ \varepsilon_{321} \\ \varepsilon_{331} \\ \varepsilon_{332} \\ \varepsilon_{333} \\ \varepsilon_{334} \\ \varepsilon_{335} \\ \varepsilon_{336} \end{pmatrix}$$

Ejemplo 2: CBR decline

Deseamos probar el **entorno social** influye en el CBR decline..

es decir;

$$H_0 : \alpha_1 = \alpha_2 = \alpha_3$$

o de forma equivalente:

$$H_0 : C\beta = \begin{pmatrix} 0 & 1 & -1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Utilice un nivel de significancia $\alpha = 0.05$

Ejemplo 2: CBR decline

Pasos:

1. Verificando que H_0 es *comprobable* usando rangos $r(X) =$

[1] 5

Rango $r \left(\begin{matrix} X \\ C \end{matrix} \right) =$

[1] 5

Por lo tanto H_0 es comprobable

Ejemplo 2: CBR decline

1. Obtención del estadístico $F : c$

$$F_c = \frac{\frac{(C\hat{\beta} - d)^t [C(X^t X)^{-1} C^t]^{-1} (C\hat{\beta} - d)}{m}}{\frac{y^t (I - X(X^t X)^{-1} X^t) y}{(n - k)}} \sim F(m, n - k)$$

F_c

```
##           [,1]  
## [1,] 0.3294194
```

F tablas y pvalue

```
## [1] 3.68232
```

```
##           [,1]  
## [1,] 0.7244156
```

Ejemplo 2: CBR decline

codigo en R para calculos de ejemplo

```
cbr=read.csv("cbr.csv")
library(sasLM)
library(matlib)
cbr$Setting=as.factor(cbr$Setting);cbr$Effort=as.factor(cbr$Effort)
y=as.matrix(cbr$CBR)
X=ModelMatrix(CBR~ Setting+ Effort, cbr)$X
C=matrix( c(0 ,1, -1, 0, 0, 0,0,
            0 ,1, 0, -1, 0, 0,0), nrow=2, byrow=TRUE)
beta=Ginv(t(X)%*%X)%*%t(X)%*%y
#C*%beta
SCH=t(C*%beta)%*%solve(C*%Ginv(t(X)%*%X)%*%t(C))%*%(C*%beta)
glh=R(C*%Ginv(t(X)%*%X)%*%t(C))
SCE=t(y)%*%(diag(nrow(X))-X*%Ginv(t(X)%*%X)%*%t(X))%*%y
gle=R(diag(nrow(X)))-R(X*%Ginv(t(X)%*%X)%*%t(X))
FC=(SCH/glh)/(SCE/gle)
FC # F calculada
alfa=0.05
qf((1-alfa), df1=glh, df2=gle) ## valor de tablas F
pf(FC, df1=glh, df2=gle, lower.tail = F) ## Pvalue
```

Ejemplo 2: CBR decline

Codigo en R para calculos de ejemplo usando anova

```
cbr=read.csv("cbr.csv")
library(sasLM)
library(matlib)
cbr$Setting=as.factor(cbr$Setting);cbr$Effort=as.factor(cbr$Effort)
y=as.matrix(cbr$CBR)
library(car)
#Anova(lm(CBR~ Setting+ Effort, cbr),type=3)
GLM(CBR~ Setting+ Effort, cbr)$`Type III`
```

```
##           Df Sum Sq Mean Sq F value    Pr(>F)
## Setting    2   25.31    12.66   0.3294 0.724416
## Effort      2  834.11   417.05  10.8550 0.001216 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

No Rechazo H_0

Pruebas de hipótesis para comparar modelos

Idea de modelo lineal completo y modelo reducido

Considere un modelo lineal $y = X\beta + \varepsilon$ donde la matriz diseño X puede ser particionada en dos matrices X_1 y X_2 es decir:

$$X = [X_1 | X_2]$$

- El modelo **completo** es:

$$y = X\beta + \varepsilon = [X_1 | X_2] \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix} + \varepsilon$$

$$y = X_1\beta_1 + X_2\beta_2 + \varepsilon$$

Y el considere el **modelo reducido**:

$$y = X_1\beta_1 + \varepsilon$$

El termino de diferencia es $X_2\beta_2$ el que es 0 si la hipótesis nula $H_0 : \beta_2 = 0$ es cierta.

Probando hipotesis usando modelo completo y reducido

\scriptsize Deseamos Probar $H_0 : \beta_2 = 0$

- Ajustando modelo completo una solución a las EN ($(X^t X)\beta = X^t y$)

$$\hat{\beta} = (X^t X)^{-1} X^t y$$

Note que $\hat{y}_c = X\hat{\beta}$ y $\hat{\varepsilon}_c = y - \hat{y}_c$ es el pronóstico y residuales bajo el modelo completo

- Ajustando el modelo reducido una solución a las EN ($(X_1^t X_1)\beta = X_1^t y$)

$$\hat{\beta}_1 = (X_1^t X_1)^{-1} X_1^t y$$

Note que $\hat{y}_r = X_1\hat{\beta}_1$ y $\hat{\varepsilon}_r = y - \hat{y}_r$ es el pronóstico y residuales bajo el modelo reducido

- Obtenga la descomposición del vector de datos Y en la suma de tres vectores perpendiculares

$$y = X_1\hat{\beta}_1 + (X\hat{\beta} - X_1\hat{\beta}_1) + \hat{\varepsilon}_c$$

Probando hipotesis usando modelo completo y reducido

- Obtenemos las Normas (formas cuadráticas) por Pitagoras

$$||y|| = ||X_1\hat{\beta}_1||^2 + ||(X\hat{\beta} - X_1\hat{\beta}_1)||^2 + ||\hat{\epsilon}_c||^2$$

$$y^ty = y^t(X_1(X_1^tX_1)^{-}X_1^t)y + y^t(X(X^tX)^{-}X^t - X_1(X_1^tX_1)^{-}X_1^t)y + y^t(I - X(X^tX)^{-}X^t)y$$

$$SCT_c = SC(X_1) + SC(X_2/X_1) + SCE_C$$

resulta la tabla

<i>Fuentes de Variación</i>	<i>Grados de libertad</i>	<i>Suma de Cuadrados</i>	<i>Cuadrados medios</i>	<i>F</i>
X_1	$r(X_1(X_1^tX_1)^{-}X_1^t) = r(X_1)$	$SC(X_1) = y^t(X_1(X_1^tX_1)^{-}X_1^t)y$		
$X_2 X_1$	$r((X(X^tX)^{-}X^t - X_1(X_1^tX_1)^{-}X_1^t)) = r(X) - r(X_1)$	$SC(X_2 X_1) = y^t(X(X^tX)^{-}X^t - X_1(X_1^tX_1)^{-}X_1^t)y$	$CM(X_2 X_1) = SC(X_2 X_1)/(r(X) - r(X_1))$	$F_c = CM(X_2 X_1)/CME_c$
<i>Error(completo)</i>	$r(I - X(X^tX)^{-}X^t) = n - r(X)$	$SCE_c = y^t(I - X(X^tX)^{-}X^t)y$	$CME_c = SCE_c/(n - r(X))$	
<i>Total(nocorregido)</i>	$r(I) = n$	$SCT = y^ty$		


Prueba de F parcial

En esta tabla la notación $X_2|X_1$ significa X_2 ajustada por X_1 o X_2 después de ajustar por X_1 . Esta tabla se usa para probar $H_0 : \beta_2 = 0$ calculando

$$F_c = \frac{CM(X_2|X_1)}{CME_c} = \frac{y^t(X(X^tX)^-X^t - X_1(X_1^tX_1)^-X_1^t)y/(r(X) - r(X_1))}{y^t(I - X(X^tX)^-X^t)y/(n - r(X))} \sim F_{[(r(X)-r(X_1)), (n-r(X))]}$$

Enfoque de modelo completo-reducido

Dados varios predictores de una respuesta, podríamos preguntarnos si todos son necesarios. Considere un modelo grande(**modelo completo**), Ω , y un modelo más pequeño(**Modelo reducido**), ω , que consta de un subconjunto de predictores que están en Ω . Por el principio de la parsimonia, preferimos usar ω si los datos lo respaldan. Entonces tomaremos ω para representar la hipótesis nula y Ω para representar la alternativa. Geometricamente:



Pruebas de hipótesis para comparar modelos

Ahora suponga que la dimensión (número de parámetros) de Ω es q y la dimensión de ω es p . Ahora por Teorema de Cochran, si el modelo nulo (ω) es verdadero entonces

$$\frac{SCE_{\omega} - SCE_{\Omega}}{q - p} \sim \sigma^2 \chi_{q-p}^2, \quad \frac{SCE_{\Omega}}{n - q} \sim \sigma^2 \chi_{n-q}^2$$

Por lo que la F parcial

$$F = \frac{(SCE_{\omega} - SCE_{\Omega}) / (q - p)}{SCE_{\Omega} / (n - q)} \sim F_{n-q}^{q-p}$$

Rechazo $H_0 : \omega$ vs $H_1 : \Omega$ si $F > F_{tablas}$

Ejemplo:

Considere el modelo

$$y_{ij} = \mu + \alpha_i + \beta_j + \epsilon_{ij}$$

con $i = 1, 2, 3; j = 1, 2$. y queremos probar

$$H_0 : \alpha_1 = \alpha_2 = \alpha_3$$

codigo para hacer la matriz diseño X en R

```
make.X=function(I, J) {  
  X=NULL  
  for(i in 1:I) {  
    tmp=matrix(0, J, I)  
    tmp[, i]=1  
    X=rbind(X, cbind(tmp, diag(J)))  
  }  
  X=cbind(1, X)  
  X  
}  
X=make.X(3, 2)  
qr(X)$rank
```

```
## [1] 4
```

matriz diseño X en R

```
X
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6]
## [1,]    1    1    0    0    1    0
## [2,]    1    1    0    0    0    1
## [3,]    1    0    1    0    1    0
## [4,]    1    0    1    0    0    1
## [5,]    1    0    0    1    1    0
## [6,]    1    0    0    1    0    1
```

Queremos probar $H_0 : \alpha_1 = \alpha_2 = \alpha_3$

es equivalente a

$$H_0 : \alpha_1 - \alpha_2 = 0 \text{ y } \alpha_1 - \alpha_3 = 0$$

Entonces H_0 es comprobable si $\alpha_1 - \alpha_2 = 0$ y $\alpha_1 - \alpha_3 = 0$ son estimables

Codigo en R para probar H_0

```
n=nrow(X)
k=qr(X)$rank
beta1=rbind(5, 0, 0, 0, -2, 2)
beta2=rbind(5, -3, -1, 4, -2, 2)
epsilon=rnorm(6, 0, 1)
y1=cbind(round(X%%beta1+epsilon, 3))
y2=cbind(round(X%%beta2+epsilon, 3))
```

```
# Find ydots and betahats
I=3;J=2
ydots1=c(t(X)%%y1)
tmp=ydots1/apply(X, 2, sum)
tmp[-1]=tmp[-1]-tmp[1]
betahat1=tmp
ydots2=c(t(X)%%y2)
tmp=ydots2/apply(X, 2, sum)
tmp[-1]=tmp[-1]-tmp[1]
betahat2=tmp
rbind(round(betahat1, 3), round(betahat2, 3))
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6]
## [1,] 4.973 -0.181 0.277 -0.096 -2.115 2.115
## [2,] 4.973 -3.181 -0.723 3.904 -2.115 2.115
```


Codigo en R para probar H_0

```
sse1=t(y1)%*%y1-rbind(betahat1)%*%t(X)%*%y1
sse2=t(y2)%*%y2-rbind(betahat2)%*%t(X)%*%y2
round(c(sse1, sse2), 5)
```

```
## [1] 0.29023 0.29023
```

```
ssalpha1=sum(ydots1[1+1:I]^2/J)-ydots1[1]^2/(I*J)
ssalpha2=sum(ydots2[1+1:I]^2/J)-ydots2[1]^2/(I*J)
round(c(ssalpha1, ssalpha2), 3)
```

```
## [1] 0.238 51.772
```

```
F1=(ssalpha1/(I-1))/(sse1/(n-k))
F2=(ssalpha2/(I-1))/(sse2/(n-k))
# Find p values
round(c(F1, F2), 1)
```

```
## [1] 0.8 178.4
```

```
c(1-pf(F1, I-1, n-k), 1-pf(F2, I-1, n-k))
```

Ejemplo

Se llevó a cabo un experimento de nutrición animal para estudiar los efectos proteína en la dieta a nivel de leucina en el plasma de los cerdos. Los cerdos fueron asignados al azar a cada uno de los doce tratamientos. Estos tratamientos son las combinaciones de **fuentes de proteína** (harina de pescado, harina de soja y desnatado seco leche) y **concentración de proteínas** en la dieta (9, 12, 15 o 18 por ciento). La variable de respuesta es el **nivel de leucina en plasma** libre en mcg/ml.

- Fuente: Windels, H. F. (1964). **The Influence of Diet and of Duration of Fast upon Plasma Levels of Free Leucine, Isoleucine, and Valine in the Growing Pig**. Ph. D. thesis, University of Minnesota, St. Paul, MN.

Ejemplo

Datos:

Meal	9%	12%	15%	18%
Fish	27.8	31.5	34	30.6
	23.7	28.5	28.7	32.7
		32.8	28.3	33.7
Soy	39.3	39.8	38.5	42.9
	34.8	40	39.2	49
	29.8	39.1	40	44.4
Milk	40.6	42.9	59.5	72.1
	31	50.1	48.9	59.8
	34.6	37.4	41.4	67.6

<i>Fuente</i>	<i>Concentracion</i>	<i>Leucina</i>
<i>Fish</i>	9%	27.8
<i>Fish</i>	9%	23.7
<i>Fish</i>	12%	31.5
<i>Fish</i>	12%	28.5
<i>Fish</i>	12%	32.8
<i>Fish</i>	15%	34
<i>Fish</i>	15%	28.7
<i>Fish</i>	15%	28.3
<i>Fish</i>	18%	30.6
<i>Fish</i>	18%	32.7
<i>Fish</i>	18%	33.7
<i>Soy</i>	9%	39.3
<i>Soy</i>	9%	34.8
<i>Soy</i>	9%	29.8
<i>Soy</i>	12%	39.8
<i>Soy</i>	12%	40
<i>Soy</i>	12%	39.1
<i>Soy</i>	15%	38.5
<i>Soy</i>	15%	39.2
<i>Soy</i>	15%	40
<i>Soy</i>	18%	42.9
<i>Soy</i>	18%	49
<i>Soy</i>	18%	44.4
<i>Milk</i>	9%	40.6
<i>Milk</i>	9%	31
<i>Milk</i>	9%	34.6
<i>Milk</i>	12%	42.9
<i>Milk</i>	12%	50.1
<i>Milk</i>	12%	37.4
<i>Milk</i>	15%	59.5
<i>Milk</i>	15%	48.9
<i>Milk</i>	15%	41.4
<i>Milk</i>	18%	72.1
<i>Milk</i>	18%	59.8
<i>Milk</i>	18%	67.6

datos en R

```
expe_leucina <- read.csv("expe_leucina.csv")
ajuste_lec=lm(Leucina~Fuente+Concentracion+Fuente*Concentracion,data=expe_leucina)
anova(ajuste_lec)
```

```
## Analysis of Variance Table
```

```
##
```

```
## Response: Leucina
```

```
##
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
## Fuente	2	1989.19	994.59	47.523	6.781e-09	***
## Concentracion	3	1196.93	398.98	19.064	1.961e-06	***
## Fuente:Concentracion	6	602.00	100.33	4.794	0.002628	**
## Residuals	23	481.36	20.93			

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Tipos de Sumas de cuadrados I,II, III

Sumas de cuadrados en R

Cuando los datos están desbalanceados, hay diferentes formas de calcular las sumas de cuadrados para ANOVA. Hay al menos 3 enfoques, comúnmente llamados sumas de cuadrados de Tipo I, II y III (esta notación es del paquete SAS).

Tipos:

- Sumas de cuadrados de tipo I, II y III

Ejemplo: modelo con dos factores A y B; por tanto, hay dos efectos principales y una interacción, AB. El modelo completo está representado por $SC(A, B, AB)$. $SC(A, B)$ indica el modelo sin interacción, $SC(B, AB)$ indica el modelo que no tiene en cuenta los efectos del factor A, y así sucesivamente. Para determinar la interacción, se realiza una prueba F de los modelos $SC(A, B, AB)$ y del modelo de no interacción $SC(A, B)$.

Sumas de cuadrados en R

Sumas de cuadrados incrementales.

$$SC(AB|A, B) = SC(A, B, AB) - SC(A, B)$$

$$SC(A|B, AB) = SC(A, B, AB) - SC(B, AB)$$

$$SC(B|A, AB) = SC(A, B, AB) - SC(A, AB)$$

$$SC(A|B) = SC(A, B) - SC(B)$$

$$SC(B|A) = SC(A, B) - SC(A)$$

Tipo I: Sumas de cuadrados “secuencial”

- $SC(A)$ para el factor A.
- $SC(B|A)$ para el factor B.
- $SC(AB|B, A)$ para la interacción AB.

Esto prueba el efecto principal del factor A, seguido del efecto principal del factor B después del efecto principal de A, seguido del efecto de interacción AB después de los efectos principales. Debido a la naturaleza secuencial y al hecho de que los dos factores principales se prueban en un orden particular, este tipo de sumas de cuadrados dará resultados diferentes para datos no balanceados dependiendo de qué efecto principal se considere primero. Para datos no balanceados, este enfoque prueba una diferencia en las medias marginales ponderadas.

Sumas de cuadrados del Tipo II

- $SC(A|B)$ para el factor A.
- $SC(B|A)$ para el factor B.

Este tipo prueba cada efecto principal después del otro efecto principal.

Tenga en cuenta que no se asume una interacción significativa (en otras palabras, primero debe probar la interacción ($SC(AB | A, B)$) y solo si AB no es significativo, continuar con el análisis de los efectos principales). Si de hecho no hay interacción, entonces el tipo II es más poderoso que el tipo III.

Sumas de cuadrados del Tipo III:

- $SS(A|B, AB)$ para el factor A.
- $SC(B|A, AB)$ para el factor B.

Este tipo prueba la presencia de un efecto principal después del otro efecto principal e interacción. Por tanto, este enfoque es válido en presencia de interacciones significativas. Sin embargo, a menudo no es interesante interpretar un efecto principal si hay interacciones (en términos generales, si hay una interacción significativa, los efectos principales no deben analizarse más a fondo).

Las funciones *anova* y *aov* en R

Las funciones *anova* y *aov* en R implementan una suma secuencial de cuadrados (tipo I). Como se indicó anteriormente, para datos no balanceados, esto rara vez prueba una hipótesis de interés, ya que esencialmente el efecto de un factor se calcula en base a los niveles variables del otro factor. En un sentido práctico, esto significa que los resultados son interpretables solo en relación con los niveles particulares de observaciones que ocurren en el conjunto de datos (desbalanceado). Es relativamente sencillo obtener SC tipo II en R. Tipo II SC en R

Dado que la SS de tipo II prueba cada efecto principal después de los otros efectos principales, y asume que no hay interacciones, se puede obtener la SC correcta usando *anova()* y variando el orden de los factores.

Para obtener SS tipo I:

Ejemplo:

```
anova(lm(Leucina~Fuente*Concentracion,data=expe_leucina))
```

```
## Analysis of Variance Table
```

```
##
```

```
## Response: Leucina
```

```
##
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
## Fuente	2	1989.19	994.59	47.523	6.781e-09	***
## Concentracion	3	1196.93	398.98	19.064	1.961e-06	***
## Fuente:Concentracion	6	602.00	100.33	4.794	0.002628	**
## Residuals	23	481.36	20.93			

```
## ---  
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Si los datos están desbalanceados, obtendrá resultados ligeramente diferentes si en su lugar utiliza:

```
anova(lm(Leucina~Concentracion*Fuente,data=expe_leucina))
```

```
## Analysis of Variance Table
##
## Response: Leucina
##
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
## Concentracion	3	1050.33	350.11	16.729	5.513e-06	***
## Fuente	2	2135.79	1067.90	51.025	3.495e-09	***
## Concentracion:Fuente	6	602.00	100.33	4.794	0.002628	**
## Residuals	23	481.36	20.93			

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

El SC tipo II se obtiene utilizando la segunda línea de salida de cada uno de los comandos anteriores (ya que en SS tipo I, el segundo componente será el segundo factor, después del primer factor). Es decir, obtiene los resultados de SC de tipo II para el tema del primer comando y los resultados de sys del segundo.

SC Tipo III en R

```
options(contrasts=c("contr.sum","contr.poly"))
model <-lm( Leucina~Fuente*Concentracion,data=expe_leucina)
drop1(model, .~., test="F")
```

```
## Single term deletions
```

```
##
```

```
## Model:
```

```
## Leucina ~ Fuente * Concentracion
```

```
##              Df Sum of Sq      RSS      AIC F value    Pr(>F)
## <none>                481.36 115.75
## Fuente                2    2036.1 2517.46 169.65   48.643 5.462e-09 ***
## Concentracion         3    1125.1 1606.49 151.93   17.920 3.216e-06 ***
## Fuente:Concentracion   6     602.0 1083.37 132.14    4.794 0.002628 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

SC tipo III SS, y p-values de F-test.

SC Tipo II y III SS usando car Package

```
library(car)
Anova(lm(Leucina~Fuente*Concentracion,data=expe_leucina),type="II")
```

```
## Anova Table (Type II tests)
##
## Response: Leucina
##
```

	Sum Sq	Df	F value	Pr(>F)	
Fuente	2135.79	2	51.025	3.495e-09	***
Concentracion	1196.93	3	19.064	1.961e-06	***
Fuente:Concentracion	602.00	6	4.794	0.002628	**
Residuals	481.36	23			

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

utiliza:

```
library(car)  
Anova(lm(Leucina~Fuente*Concentracion,data=expe_leucina),type="III")
```

```
## Anova Table (Type III tests)  
##  
## Response: Leucina  
##  
##           Sum Sq Df  F value    Pr(>F)  
## (Intercept)    53827  1 2571.920 < 2.2e-16 ***  
## Fuente         2036  2   48.643 5.462e-09 ***  
## Concentracion  1125  3   17.920 3.216e-06 ***  
## Fuente:Concentracion    602  6    4.794 0.002628 **  
## Residuals        481 23  
## ---  
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Usando libreria sasLM de R

```
expe_leucina <- read.csv("expe_leucina.csv")
library(sasLM)
ajuste_2=GLM(Leucina~Fuente+Concentracion+Fuente*Concentracion,expe_leucina)
ajuste_2
```

```
## $ANOVA
## Response : Leucina
##           Df Sum Sq Mean Sq F value    Pr(>F)
## MODEL           11 3788.1   344.37   16.454 2.244e-08 ***
## RESIDUALS        23  481.4    20.93
## CORRECTED TOTAL 34 4269.5
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## $Fitness
## Root MSE Leucina Mean Coef Var  R-square  Adj R-sq
## 4.574813      39.85714 11.47803 0.8872546 0.8333328
##
## $`Type I`
##           Df Sum Sq Mean Sq F value    Pr(>F)
## Fuente           2 1989.2   994.59   47.523 6.781e-09 ***
## Concentracion     3 1196.9   398.98   19.064 1.961e-06 ***
## Fuente:Concentracion 6  602.0   100.33    4.794 0.002628 **
## ---
```

Usando libreria sasLM de R

```
expe_leucina <- read.csv("expe_leucina.csv")
library(sasLM)
ajuste_2=GLM(Leucina~Fuente+Concentracion+Fuente*Concentracion,expe_leucina)
ajuste_2$`Type III`
```

```
##              Df Sum Sq Mean Sq F value    Pr(>F)
## Fuente              2 2036.1  1018.05   48.643 5.462e-09 ***
## Concentracion        3 1125.1   375.04   17.920 3.216e-06 ***
## Fuente:Concentracion  6   602.0   100.33    4.794 0.002628 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

La prueba de razón de verosimilitud (*LRT*)

Prueba de Razón de Verosimilitud Generalizada

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población con función de densidad de probabilidad multiparamétrica dada por $f_x(x; \theta)$ con $\theta = (\theta_1, \dots, \theta_m)$. Si $\theta \in \Theta_0$ en que Θ_0 es el correspondiente espacio paramétrico bajo H_0 es decir deseamos probar:

$$\begin{cases} H_0 : & \theta \in \Theta_0 \\ H_1 : & \theta \notin \Theta_0 \end{cases}$$

Entonces, el estadístico $T(X) = -2\log(\lambda)$ tiene distribución asintótica $\chi^2_{(m-r)}$, donde r es el número de parámetros de θ que ha sido completamente especificado en la hipótesis nula y λ tiene la siguiente expresión:

$$\lambda = \left(\frac{\max_{\theta \in \Theta_0} \mathcal{L}(\theta)}{\max_{\theta \in \Theta} \mathcal{L}(\theta)} \right) = \left(\frac{\mathcal{L}(\hat{\theta}_0)}{\mathcal{L}(\hat{\theta})} \right)$$

Donde $\mathcal{L}(\theta) = \prod_{i=1}^n f_{X_i}(x_i; \theta) = f_{X_1}(x_1; \theta) \cdots f_{X_n}(x_n; \theta)$ es la función de verosimilitud.

- Se rechaza H_0 si $T(X) = -2\log(\lambda) > \chi^2_{(m-r), \alpha}$

Prueba LRT en modelos lineales

Definición: Considere el modelo lineal $y = X\beta + \varepsilon$ y deseamos probar la hipótesis $H_0 : C\beta = m$, el estadístico de prueba de razón de verosimilitud, λ , para probar está dado por:

$$\lambda = \frac{\max_{H_0} \mathcal{L}(\beta, \sigma^2, y)}{\max_{\beta, \sigma^2} \mathcal{L}(\beta, \sigma^2, y)}$$

Donde :

- $\max_{\beta, \sigma^2} \mathcal{L}(\beta, \sigma^2, y) = \frac{1}{(2\pi\tilde{\sigma}^2)^{\frac{n}{2}}} e^{\frac{-n}{2}}$
- $\max_{H_0} \mathcal{L}(\beta, \sigma^2, y) = \frac{2\pi}{n} [(y - X\hat{\beta}_r)^t (y - X\hat{\beta}_r)]^{-n/2} e^{\frac{-n}{2}}$ con
 $\hat{\beta}_r = \hat{\beta} - (X^t X)^{-1} C^t (C(X^t X)^{-1} C^t)^{-1} (C\hat{\beta} - m)$ y $\tilde{\sigma}^2 = (y - X\hat{\beta})^t (y - X\hat{\beta}) / n$

Prueba LRT en modelos lineales

note que:

$$\lambda = \frac{\frac{2\pi}{n}[(y - X\hat{\beta}_r)^t(y - X\hat{\beta}_r)]^{-n/2}e^{\frac{-n}{2}}}{\frac{1}{(2\pi(y - X\hat{\beta})^t((y - X\hat{\beta})/n)^{\frac{n}{2}})}e^{\frac{-n}{2}}} = \left(\frac{(y - X\hat{\beta})^t(y - X\hat{\beta})}{(y - X\hat{\beta}_r)^t(y - X\hat{\beta}_r)} \right)^{n/2}$$

$$\lambda = \left(\frac{(y - X\hat{\beta})^t(y - X\hat{\beta})}{(y - X\hat{\beta})^t(y - X\hat{\beta}) + (C\hat{\beta} - m)^t(C(X^tX)^{-1}C^t)^{-1}(C\hat{\beta} - m)} \right)^{n/2}$$

Rechazo $H_0 : C\beta = m$, si $-2\log(\lambda)$ es mayor que un valor de tablas $\chi^2_{r(C),\alpha}$

Ejemplo LRT: con datos CBR decline

Deseamos probar el **entorno social** influye en el CBR decline..

$$H_0 : C\beta - m = \begin{pmatrix} 0 & 1 & -1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} - \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Utilice una prueba de razon de verosimilitudes con nivel de significancia $\alpha = 0.05$

- Obtención de:

$$\lambda = \left(\frac{(y - X\hat{\beta})^t (y - X\hat{\beta})}{(y - X\hat{\beta})^t (y - X\hat{\beta}) + (C\hat{\beta} - m)^t (C(X^t X)^{-1} C^t)^{-1} (C\hat{\beta} - m)} \right)^{n/2} = \left(\frac{SCE}{SCE + SCH} \right)^{n/2}$$

Ejemplo LRT: con datos CBR decline

codigo en R para cálculos de ejemplo

```
cbr=read.csv("cbr.csv")
library(sasLM)
library(matlib)
cbr$Setting=as.factor(cbr$Setting);cbr$Effort=as.factor(cbr$Effort)
y=as.matrix(cbr$CBR)
X=ModelMatrix(CBR~ Setting+ Effort, cbr)$X
C=matrix( c(0 ,1, -1, 0, 0, 0,0,
            0 ,1, 0, -1, 0, 0,0), nrow=2, byrow=TRUE)
beta=Ginv(t(X)%*%X)%*%t(X)%*%y
#C*%beta
SCH=t(C*%beta)%*%solve(C*%Ginv(t(X)%*%X)%*%t(C))%*%(C*%beta)
glh=R(C*%Ginv(t(X)%*%X)%*%t(C))
SCE=t(y)%*%(diag(nrow(X))-X*%Ginv(t(X)%*%X)%*%t(X))%*%y
n=nrow(X)
lambda=(SCE/(SCE+SCH))^(n/2)
Tc=-2*log(lambda); Tc
```

```
##           [,1]
## [1,] 0.8597066
```

```
alfa=0.05
```

Ejemplo LRT: con datos CBR decline

codigo en R para cálculos de ejemplo

```
cbr=read.csv("cbr.csv")
library(sasLM)
library(matlib)
cbr$Setting=as.factor(cbr$Setting);cbr$Effort=as.factor(cbr$Effort)

lambda=(SCE/(SCE+SCH))^(n/2)
Tc=-2*log(lambda); Tc
```

```
##           [,1]
## [1,] 0.8597066
```

```
alfa=0.05
qchisq((1-alfa), df=glh) ## valor de tablas F
```

```
## [1] 5.991465
```

```
pchisq(T, df=glh, lower.tail = F) ## Pvalue
```

```
## [1] 0.6065307
```


Ejemplo LRT: con datos CBR decline

Calculo directo usan lm de R

```
cbr=read.csv("cbr.csv")
cbr$Setting=as.factor(cbr$Setting);cbr$Effort=as.factor(cbr$Effort)
m1=lm(CBR~ Setting+ Effort, cbr)
logLik(m1)
```

```
## 'log Lik.' -61.98784 (df=6)
```

```
m2=lm(CBR~ Effort, cbr)
logLik(m2)
```

```
## 'log Lik.' -62.41769 (df=4)
```

```
Tc=2*(logLik(m1)-logLik(m2))
Tc
```

```
## 'log Lik.' 0.8597057 (df=6)
```