



Maxima Verosimilitud en el Modelo Lineal

Humberto Vaquera Huerta

Primavera 2024

Contenido

- 1** Introducción
- 2** Modelo lineal: Estimación máximo verosímil
- 3** Pruebas basadas en la verosimilitud
- 4** Pruebas usando Metodo Delta
- 5** Pruebas basadas en computo intensivo

¿Qué es la estimación por máxima verosimilitud?

La estimación de máxima verosimilitud es un método estadístico para estimar los parámetros de un modelo.

Elementos:

- 1 Suponer un modelo.
- 2 Derivar la función de verosimilitud para nuestros datos, dado nuestro modelo.
- 3 La estimación de máxima verosimilitud mediante la optimización.

Ventajas de la estimación por máxima verosimilitud

ventajas:

- 1 Si el modelo se asume correctamente, el estimador de máxima verosimilitud es el estimador más eficiente.
- 2 Proporciona un enfoque coherente pero flexible que lo hace adecuado para una amplia variedad de aplicaciones, incluidos los casos en que se violan los supuestos de otros modelos.
- 3 Da como resultado estimaciones insesgadas en muestras grandes.

Desventajas de la estimación de máxima verosimilitud

- 1 Se supone un modelo y la derivación de la función de verosimilitud (a veces difícil).
- 2 En la optimización, la estimación de MV puede ser sensible a la elección de los valores iniciales.
- 3 Dependiendo de la complejidad de la función de verosimilitud, la estimación numérica puede resultar computacionalmente costosa.
- 4 Las estimaciones pueden estar sesgadas en muestras pequeñas.

Metodo de Maxima Verosimilitud

La estimación de máxima verosimilitud es un marco probabilístico para resolver el problema de la estimación de la densidad. Implica maximizar una función de probabilidad para encontrar la distribución de probabilidad y los parámetros que mejor expliquen los datos observados.

- 1 la función de log-verosimilitud y estimadores por el método de máxima verosimilitud.
- 2 El concepto de verosimilitud fue propuesto por Fisher en el contexto de estimación de parámetros.

Función de verosimilitud

La función de verosimilitud para un vector de parámetros θ dada una muestra aleatoria $\mathbf{x} = (x_1, \dots, x_n)^\top$ con una distribución dada se define como:

$$L(\theta|\mathbf{x}) = \prod_{i=1}^n f(x_i|\theta), \quad (1)$$

donde $\mathbf{x}_i$ representa uno de los elementos de la muestra aleatoria y $f(\cdot)$ es la función de densidad de la distribución de la cual se obtuvo $\mathbf{x}$.

Función de log-verosimilitud

La función de log-verosimilitud $l(\theta|\mathbf{x})$ se define como el logaritmo de la función de verosimilitud $L(\theta|\mathbf{x})$, es decir

$$l(\theta|\mathbf{x}) = \log L(\theta|\mathbf{x}) = \sum_{i=1}^n \log f(x_i|\theta) \quad (2)$$

Método de máxima verosimilitud para estimar parámetros

El método de máxima verosimilitud se usa para estimar los parámetros de una distribución. El objetivo de este método es encontrar los valores de θ que maximizan a $L(\theta|\mathbf{x})$ o a $l(\theta|\mathbf{x})$, los valores encontrados se representan usualmente por $\hat{\theta}$.

Método de máxima verosimilitud para estimar parámetros


Asumiendo un modelo estadístico parametrizado por una cantidad fija y desconocida θ , la verosimilitud $L(\theta)$ es la probabilidad de los datos observados x como una función de θ . Si la variable de interés es discreta se usa la probabilidad y si es continua se usa la densidad para obtener la verosimilitud.

Ejemplo: Distribución normal

Considere la distribución normal

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right], \quad -\infty < x < \infty$$

pdf $N(\mu, \sigma^2)$



Funcion de Verosimilitud de la Normal

$$\mathcal{L} = f(x_1, x_2, \dots, x_n | \sigma, \mu) = \prod_{i=1}^n \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$\mathcal{L} = f(x_1, x_2, \dots, x_n | \sigma, \mu) = \left(\frac{1}{\sigma \sqrt{2\pi}} \right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}$$

Funcion de log verosimilitud de la Normal

$$\log L = \log(\mathcal{L}) = \log\left(\left(\frac{1}{\sigma\sqrt{2\pi}}\right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}\right)$$

$$\log L = n \log \frac{1}{\sigma\sqrt{2\pi}} - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

$$\log L = -\frac{n}{2} \log(2\pi) - n \log \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

Usando derivadas parciales:

$$\frac{d\log L}{d\mu} = -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \Big|_{\mu} = 0$$

$$\frac{1}{2\sigma^2} \sum_{i=1}^n (2\hat{\mu} - 2x_i) = 0$$

$$\frac{d\log L}{d\sigma} = -\frac{n}{\sigma} + \sum_{i=1}^n (x_i - \mu)^2 \sigma^{-3} = 0$$

Estimadores de maxima verosimilitud de μ y σ^2

Estimador de μ



$$\hat{\mu} = \frac{\sum_{i=1}^n x_i}{n}$$

Estimador de σ^2



$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (x_i - \hat{\mu})^2}{n}$$

Son los estimadores de maxima verosimilitud

Ejemplo estimacion por Maxima Verosimilitud en la Normal


Un estudio estima el ingreso familiar anual promedio para familias que viven en viviendas públicas en Chicago. Para muestra aleatoria de 30 familias, los ingresos anuales (en cientos de dólares) son:

133	140	127	150	133	114	128	142	123	172
146	110	135	136	158	120	189	106	144	134
161	143	170	120	142	150	174	109	162	129

Ejemplo Normal

Distribucion de ingresos

Histograma y densidad



Ejemplo: Usando código directo

```
y= c(133,140,127,150,133,114,128,142,123,172,146,110,135,  
      136,158,120,189,106,144,134,161,143,170,120,142, 150,174,109,162,129)  
y=as.matrix(y)  
n<-nrow(y)  
## función de verosimilitud  
normal.lik1<-function(param,y)  
{  
  mu<-param[1]  
  sigma2<-param[2]  
  logl<- -.5*n*log(2*pi) -.5*n*log(sigma2) - (1/(2*sigma2))*sum((y-mu)**2)  
  return(-logl)  
}  
#usando optim para resolver en forma numerica  
optim(c(100,200),normal.lik1,y=y,hessian=T )
```

```
## $par  
## [1] 140.0006 413.3573  
##  
## $value  
## [1] 132.9199  
##  
## $counts  
## function gradient  
##      59      NA  
##  
## $convergence  
## [1] 0  
##  
## $message
```

Ejemplo: Usando código directo

Inversa de la Hessiana

```
#usando optim para resolver en forma numérica  
ajuste=optim(c(100,200),normal.lik1,y=y,hessian=T )  
solve(ajuste$hessian)  
  
##           [,1]      [,2]  
## [1,] 13.77857459 1.787249e-02  
## [2,]  0.01787249 1.140961e+04
```

Note que podemos usar H^{-1} ' para estimar varianzas de los estimadores de MV

$$\text{Var}(\hat{\mu}) = 13.7785$$
$$\text{Var}(\hat{\sigma}^2) = 11409.61$$

Obtención de estimdores usando fitdistr

A continuación el código usado.


```
require(MASS) # El paquete ya está instalado, solo se debe cargar
res <- fitdistr(x=y, densfun='normal')
res
```

```
##          mean          sd
## 140.000000    20.322401
## ( 3.710346) ( 2.623611)
```

Gráfica de la log verosimilitud con firdisplus

```
library(fitdistrplus)
x= c(133,140,127,150,133,114,128,142,123,
     172,146,110,135,136,158,120,189,106,144,134,161,143,170,
     120,142, 150,174,109,162,129)
fsal <- fitdist(x, "norm")
llplot(fsal, fit.show = TRUE)
llplot(fsal, fit.show = TRUE, loglik = FALSE)
```

Gráfica de la log verosimilitud con firdisplus



Conceptos de la función Score y la Información de Fisher.

Score e Información de Fisher en el caso univariado.

La **función Score** denotada por $S(\theta)$ se define como la primera derivada de la función de log-verosimilitud así:

$$S(\theta) \equiv \frac{\partial}{\partial \theta} l(\theta)$$

y el estimador de máxima verosimilitud $\hat{\theta}$ se encuentra solucionando la igualdad

$$S(\theta) = 0$$

Score e Información de Fisher en el caso univariado.

En el valor máximo $\hat{\theta}$ la curva $l(\theta)$ es cóncava hacia abajo y por lo tanto la segunda derivada es negativa, así la curvatura $I(\theta)$ se define como

$$I(\theta) \equiv -\frac{\partial^2}{\partial \theta^2} l(\theta)$$

Score e Información de Fisher en el caso univariado.

Una curvatura grande $I(\hat{\theta})$ está asociada con un gran pico en la función de log-verosimilitud y eso significa una menor incertidumbre sobre el parámetro θ . En particular la varianza del estimador de máxima verosimilitud está dada por

$$\text{Var}(\hat{\theta}) = I^{-1}(\hat{\theta})$$

Invarianza de los EMV (MLE)

Supongamos que deseamos estimar la función $g = G(\theta)$ y no θ en sí mismo.

Intuitivamente podríamos intentar

$$\hat{g} = G(\hat{\theta})$$

donde $\hat{\theta}$ es el MLE de θ .

Sorprendentemente, resulta que $\hat{g}$ es el MLE de g .

Este principio de invarianza se resume en el siguiente

Teorema: Invarianza del MLE

Sea $\hat{\theta}$ el MLE de θ . Entonces $\hat{g} = G(\hat{\theta})$ es el MLE de $g = G(\theta)$

Contenido

- 1 Introducción
- 2 Modelo lineal: Estimación máximo verosímil
- 3 Pruebas basadas en la verosimilitud
- 4 Pruebas usando Metodo Delta
- 5 Pruebas basadas en computo intensivo

Modelo lineal: Estimación máximo verosímil

Suponga el modelo

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2 I)$$

es decir

$$\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2 I)$$

El estimador de MCO de β es:

$$\hat{\beta}|\mathbf{X} \sim \mathcal{N}\left(\beta, \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}\right)$$

La distribución normal multivariada de $\mathbf{Y}$

$$\mathbf{Y}|\mathbf{X} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I})$$

$$\mathbb{E}(\mathbf{Y}|\mathbf{X}) = \mathbb{E}(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}|\mathbf{X}) = \mathbb{E}(\mathbf{X}\boldsymbol{\beta}|\mathbf{X}) = \mathbf{X}\boldsymbol{\beta}$$

$$\mathbb{V}\text{ar}(\mathbf{Y}|\mathbf{X}) = \mathbb{V}\text{ar}(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}|\mathbf{X}) = \mathbb{V}\text{ar}(\boldsymbol{\varepsilon}|\mathbf{X}) = \sigma^2\mathbf{I}$$

$$f_{\mathbf{Y}|\mathbf{X}}(\mathbf{y}|\mathbf{x}) = \frac{1}{(2\pi)^{N/2}(\sigma^2)^{N/2}} \exp \left[-\frac{1}{2} (\mathbf{y} - \mathbf{x}\boldsymbol{\beta})^\top (\sigma^2\mathbf{I})^{-1} (\mathbf{y} - \mathbf{x}\boldsymbol{\beta}) \right]$$

Modelo lineal: Estimación máximo verosímil

■ La función de verosimilitud

$$\mathcal{L}(\beta, \sigma^2 | \mathbf{y}, \mathbf{X}) = \frac{1}{(2\pi)^{N/2} (\sigma^2)^{N/2}} \exp \left[-\frac{1}{2} (\mathbf{y} - \mathbf{X}\beta)^\top (\sigma^2 \mathbf{I})^{-1} (\mathbf{y} - \mathbf{X}\beta) \right]$$

■ Función de log verosimilitud

$$\begin{aligned} \ell(\beta, \sigma^2 | \mathbf{y}, \mathbf{X}) &= \log \left(\mathcal{L}(\beta, \sigma^2 | \mathbf{y}, \mathbf{X}) \right) \\ &= -\frac{N}{2} \log(2\pi) - N \log(\sigma) - \frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) \end{aligned}$$

Obtencion de los estimadores de MV para β y σ^2

Tomando derivadas de la funcion ℓ

$$\frac{\partial \ell}{\partial \beta^\top} = -\frac{1}{2\sigma^2} (-2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X}\beta) = 0$$

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{N}{2} \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) = 0$$

$$\mathbf{X}^{\top} \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^{\top} \mathbf{y}$$

Estimadores de MV para $\boldsymbol{\beta}$ y σ^2 caso rango incompleto en X

$$\hat{\boldsymbol{\beta}}_{\text{ML}} = (\mathbf{X}^{\top} \mathbf{X})^{-} \mathbf{X}^{\top} \mathbf{Y}$$

Modelo lineal: Estimación máximo verosímil

Estimadores de MV para β y σ^2 caso rango completo en X

$$\hat{\beta}_{\text{ML}} = (\mathbf{X}^{\top} \mathbf{X})^{-1} \mathbf{X}^{\top} \mathbf{Y}$$

$$\hat{\sigma}^2 = \frac{1}{N} (\mathbf{y} - \mathbf{X}\hat{\beta}_{\text{ML}})^{\top} (\mathbf{y} - \mathbf{X}\hat{\beta}_{\text{ML}})$$

Note que son similares a MCO excepto por denominador de $\hat{\sigma}^2$

Matriz de informacion de Fisher

La matriz de información de Fisher es solo el valor esperado del negativo de la matriz de Hessiana de $l(\beta)$. Entonces,

$$H(\beta) = \frac{\partial}{\partial \beta^T} \frac{(y - X^T \beta)X}{\sigma^2} = \frac{\partial X y}{\partial \beta^T} - \frac{\partial X^T X \beta}{\partial \beta^T} = \frac{-X^T X}{\sigma^2},$$

La matriz de Informacion de Fisher es:

$$I(\beta) = -E_{\beta} H(\beta) = \frac{X^T X}{\sigma^2}.$$

Estimación de Matriz de varianzas covarianzas

$$\text{Var}(\hat{\beta}) = I(\hat{\beta})^{-1}$$
$$\hat{\text{Var}}(\hat{\beta}) = \hat{\sigma}^2 (X^T X)^{-1}$$

usando $\hat{\sigma}^2$

$$\hat{\sigma}^2 = \frac{1}{N} (\mathbf{y} - \mathbf{X}\hat{\beta}_{\text{ML}})^T (\mathbf{y} - \mathbf{X}\hat{\beta}_{\text{ML}})$$

Método de máxima verosimilitud en modelos Lineales

Estimación los parámetros de un modelo de regresión.

Ejemplo: Superficie de respuesta

La Dureza, y_i , de yeso fue medida para cada una de las 9 combinaciones de contenido de **arena** y contenido de **fibra**. El contenido de arena (S_i) se configuró en uno de los 3 niveles, al igual que el contenido de fibra (f_i). Se probaron todas las combinaciones posibles, cada una en dos lotes de yeso. datos:

Sand	Fibre	Hardness
0	0	61
0	0	63
15	0	67
15	0	69
30	0	65
30	0	74
0	0.25	69
0	0.25	69
15	0.25	69
15	0.25	74
30	0.25	74
30	0.25	72
0	0.5	67
0	0.5	69
15	0.5	69
15	0.5	74
30	0.5	74
30	0.5	74

Modelo:

$$y_i = \beta_0 + \beta_1 S_i + \beta_2 S_i^2 + \beta_3 f_i + \beta_4 f_i^2 + \beta_5 S_i f_i + \varepsilon_i$$

con $\varepsilon_i \sim n(0, \sigma^2)$

Ejemplo: Superficie de respuesta MLE

```
yeso=read.csv("yeso.csv")
sresp=glm(Hardness~Sand+I(Sand^2) +Fibre+I(Fibre^2)+Sand*Fibre,family=gaussian, data=yeso)
summary(sresp)
```

```
##
## Call:
## glm(formula = Hardness ~ Sand + I(Sand^2) + Fibre + I(Fibre^2) +
##     Sand * Fibre, family = gaussian, data = yeso)
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -4.4306  -1.6076   0.4653   1.1111   4.5694
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  62.847222   1.651547  38.054 6.98e-14 ***
## Sand         0.363889   0.190704   1.908  0.0806 .
## I(Sand^2)    -0.004815   0.005783  -0.833  0.4213
## Fibre        29.500000  11.442253   2.578  0.0242 *
## I(Fibre^2)   -37.333333  20.818439  -1.793  0.0981 .
## Sand:Fibre   -0.100000   0.245348  -0.408  0.6908
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for gaussian family taken to be 6.771991)
##
##      Null deviance: 276.278  on 17  degrees of freedom
## Residual deviance:  81.264  on 12  degrees of freedom
## AIC: 92.214
```

Ejemplo: Superficie de respuesta MCO

```
yeso=read.csv("yeso.csv")
sresp2=lm(Hardness~Sand+I(Sand^2)+Fibre+I(Fibre^2)+Sand*Fibre,data=yeso)
summary(sresp2)
```

```
##
## Call:
## lm(formula = Hardness ~ Sand + I(Sand^2) + Fibre + I(Fibre^2) +
##     Sand * Fibre, data = yeso)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.4306 -1.6076  0.4653  1.1111  4.5694
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  62.847222   1.651547  38.054 6.98e-14 ***
## Sand         0.363889   0.190704   1.908  0.0806 .
## I(Sand^2)    -0.004815   0.005783  -0.833  0.4213
## Fibre       29.500000  11.442253   2.578  0.0242 *
## I(Fibre^2)  -37.333333  20.818439  -1.793  0.0981 .
## Sand:Fibre  -0.100000   0.245348  -0.408  0.6908
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.602 on 12 degrees of freedom
## Multiple R-squared:  0.7059, Adjusted R-squared:  0.5833
## F-statistic: 5.759 on 5 and 12 DF,  p-value: 0.006147
```

```
##log-verosimilitud
```

```
loglik(sresp2)
```

Contenido

- 1 Introducción
- 2 Modelo lineal: Estimación máximo verosímil
- 3 Pruebas basadas en la verosimilitud
- 4 Pruebas usando Metodo Delta
- 5 Pruebas basadas en computo intensivo

Pruebas basadas en la verosimilitud

Se pueden utilizar varios procedimientos de prueba diferentes basados en estimadores MV.

- 1 Prueba de **razón de verosimilitudes**
- 2 Prueba de **Wald**
- 3 Prueba del **multiplicador de Lagrange**

La prueba de razón de verosimilitud (LRT)

Prueba de Razón de Verosimilitud Generalizada

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población con función de densidad de probabilidad multiparamétrica dada por $f_X(x; \theta)$ con $\theta = (\theta_1, \dots, \theta_m)$. Si $\theta \in \Theta_0$ en que Θ_0 es el correspondiente espacio paramétrico bajo H_0 es decir deseamos probar:

$$\begin{cases} H_0 : & \theta \in \Theta_0 \\ H_1 : & \theta \notin \Theta_0 \end{cases}$$

Entonces, el estadístico $T(X) = -2\log(\lambda)$ tiene distribución asintótica $\chi^2_{(m-r)}$, donde r es el número de parámetros de θ que ha sido completamente especificado en la hipótesis nula y λ tiene la siguiente expresión:

$$\lambda = \left(\frac{\max_{\theta \in \Theta_0} \mathcal{L}(\theta)}{\max_{\theta \in \Theta} \mathcal{L}(\theta)} \right) = \left(\frac{\mathcal{L}(\hat{\theta}_0)}{\mathcal{L}(\hat{\theta})} \right)$$

Donde $\mathcal{L}(\theta) = \prod_{i=1}^n f_{X_i}(x_i; \theta) = f_{X_1}(x_1; \theta) \cdots f_{X_n}(x_n; \theta)$ es la función de verosimilitud.

■ Se rechaza H_0 si $T(X) = -2\log(\lambda) > \chi^2_{(m-r), \alpha}$

Prueba LRT en modelos lineales

Definición: Considere el modelo lineal $y = X\beta + \varepsilon$ y deseamos probar la hipótesis $H_0 : C\beta = m$, el estadístico de prueba de razón de verosimilitud, λ , para probar está dado por:

$$\lambda = \frac{\max_{H_0} \mathcal{L}(\beta, \sigma^2, y)}{\max_{\beta, \sigma^2} \mathcal{L}(\beta, \sigma^2, y)}$$

Donde :

$$\blacksquare \max_{\beta, \sigma^2} \mathcal{L}(\beta, \sigma^2, y) = \frac{1}{(2\pi\tilde{\sigma}^2)^{\frac{n}{2}}} e^{-\frac{n}{2}}$$

$$\blacksquare \max_{H_0} \mathcal{L}(\beta, \sigma^2, y) = \frac{2\pi}{n} [(y - X\hat{\beta}_r)^t (y - X\hat{\beta}_r)]^{-n/2} e^{-\frac{n}{2}}$$

con $\hat{\beta}_r = \hat{\beta} - (X^t X)^{-1} C^t (C(X^t X)^{-1} C^t)^{-1} (C\hat{\beta} - m)$ y $\tilde{\sigma}^2 = (y - X\hat{\beta})^t (y - X\hat{\beta}) / n$

note que:

$$\lambda = \frac{\frac{2\pi}{n} [(y - X\hat{\beta}_r)^t (y - X\hat{\beta}_r)]^{-n/2} e^{-\frac{n}{2}}}{\frac{1}{(2\pi(y - X\hat{\beta})^t (y - X\hat{\beta}) / n)^{\frac{n}{2}}} e^{-\frac{n}{2}}} = \left(\frac{(y - X\hat{\beta})^t (y - X\hat{\beta})}{(y - X\hat{\beta}_r)^t (y - X\hat{\beta}_r)} \right)^{n/2}$$
$$\lambda = \left(\frac{(y - X\hat{\beta})^t (y - X\hat{\beta})}{(y - X\hat{\beta})^t (y - X\hat{\beta}) + (C\hat{\beta} - m)^t (C(X^t X)^{-1} C^t)^{-1} (C\hat{\beta} - m)} \right)^{n/2}$$

Rechazo $H_0 : C\beta = m$, si $-2\log(\lambda)$ es mayor que un valor de tablas $\chi_{r(C), \alpha}^2$

Ejemplo LRT: con datos CBR decline

Modelo propuesto:

$$y_{ijk} = \mu + \alpha_i + \beta_j + \varepsilon_{ijk}$$

- y_{ijk} representa CBR decline,
- μ representa un valor de referencia,
- α_i representa el efecto del i-ésimo nivel del entorno social y
- β_j representa el efecto del j-ésimo nivel del esfuerzo.
- $\varepsilon_{ijk} \sim N(0, \sigma^2)$.

Datos:

Setting	Effort	CBR
1	1	1
1	1	0
1	1	7
1	2	21
1	2	13
1	2	4
1	2	7
2	1	10
2	1	6
2	1	7
2	2	0
2	3	25
3	1	9
3	2	11
3	3	29
3	3	29
3	3	40
3	3	21
3	3	22
3	3	29

Ejemplo LRT: con datos CBR decline

Deseamos probar el **entorno social** influye en el CBR decline..

$$H_0 : C\beta - m = \begin{pmatrix} 0 & 1 & -1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} - \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Utilice una prueba de razon de verosimilitudes con nivel de significancia $\alpha = 0.05$

■ Obtención de:

$$\lambda = \left(\frac{(y - X\hat{\beta})^t (y - X\hat{\beta})}{(y - X\hat{\beta})^t (y - X\hat{\beta}) + (C\hat{\beta} - m)^t (C(X^t X)^{-1} C^t)^{-1} (C\hat{\beta} - m)} \right)^{n/2} = \left(\frac{SCE}{SCE + SCH} \right)^{n/2}$$

Ejemplo LRT: con datos CBR decline

codigo en R para calculos de ejemplo

```
cbr=read.csv("cbr.csv")
library(sasLM)
library(matlib)
cbr$Setting=as.factor(cbr$Setting);cbr$Effort=as.factor(cbr$Effort)
y=as.matrix(cbr$CBR)
X=ModelMatrix(CBR~ Setting+ Effort, cbr)$X
C=matrix( c(0 ,1, -1, 0, 0, 0,0,
            0 ,1, 0, -1, 0, 0,0), nrow=2, byrow=TRUE)
beta=Ginv(t(X)%*%X)%*%t(X)%*%y
#C%*%beta
SCH=t(C%*%beta)%*%solve(C%*%Ginv(t(X)%*%X)%*%t(C))%*%(C%*%beta)
glh=R(C%*%Ginv(t(X)%*%X)%*%t(C))
SCE=t(y)%*%(diag(nrow(X))-X%*%Ginv(t(X)%*%X)%*%t(X))%*%y
n=nrow(X)
lambda=(SCE/(SCE+SCH))^(n/2)
Tc=-2*log(lambda); Tc
```

```
##           [,1]
```

```
## [1,] 0.8597066
```

```
alfa=0.05
```

```
qchisq((1-alfa), df=(glh)) ## valor de tablas F
```

```
## [1] 5.991465
```

```
pchisq(Tc, df=(glh), lower.tail = F) ## Pvalue
```

```
##           [,1]
```

```
## [1,] 0.6506045
```

Ejemplo LRT: con datos CBR decline

Calculo directo usando lm de R

```
cbr=read.csv("cbr.csv")
cbr$Setting=as.factor(cbr$Setting);cbr$Effort=as.factor(cbr$Effort)
m1=lm(CBR~ Setting+ Effort, cbr)
logLik(m1)
```

```
## 'log Lik.' -61.98784 (df=6)
```

```
m2=lm(CBR~ Effort, cbr)
logLik(m2)
```

```
## 'log Lik.' -62.41769 (df=4)
```

```
Tc=2*(logLik(m1)-logLik(m2))
Tc
```

```
## 'log Lik.' 0.8597057 (df=6)
```

```
library(lmtest) ## Usando librería lmtest
lrtest(m1,m2)
```

```
## Likelihood ratio test
##
## Model 1: CBR ~ Setting + Effort
## Model 2: CBR ~ Effort
##   #Df LogLik Df  Chisq Pr(>Chisq)
## 1    6 -61.988
## 2    4 -62.418 -2  0.8597    0.6506
```

La prueba de Wald

Un problema de la prueba de razón de verosimilitud es que por lo general requiere estimación de los vectores de parámetros restringidos y no restringidos. La obtención de los estimadores de MV en algun modelo puede ser muy difícil de calcular. la prueba de Wald evitan este problema. En particular, la prueba de Wald implica sólo la estimación no restringida de θ y, en consecuencia, es conveniente cuando la restricción la estimación de θ es difícil de calcular.

La prueba de Wald

Deseamos probar

$$H_0 : \mathbf{g}(\boldsymbol{\theta}) = \mathbf{h} \text{ vs } H_a : \mathbf{g}(\boldsymbol{\theta}) \neq \mathbf{h}$$

El estadístico de Wald es:

$$W = (\mathbf{g}(\hat{\boldsymbol{\theta}}) - \mathbf{h})' [\mathbf{G}(\hat{\boldsymbol{\theta}}) \mathcal{I}(\hat{\boldsymbol{\theta}})^{-1} \mathbf{G}(\hat{\boldsymbol{\theta}})']^{-1} (\mathbf{g}(\hat{\boldsymbol{\theta}}) - \mathbf{h})$$

■ La Matriz $\mathbf{G} = \frac{\partial \mathbf{g}(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}}|_{\hat{\boldsymbol{\theta}}}$ con $r \times k$, $r \leq k$, rango r

■

$$\mathcal{I}(\hat{\boldsymbol{\theta}}) = \left(\left[-\frac{\partial^2}{\partial \theta_i \partial \theta_j} \ell(\boldsymbol{\theta}, \mathbf{Y}) \right]_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}_n} \right)^{-1}$$

■ Bajo H_0 $W \sim \chi_r^2$

Ejemplo Wald Test: con datos CBR decline

Deseamos probar el **entorno social** influye en el CBR decline usando Wald.

$$H_0 : C\beta - m = \begin{pmatrix} 0 & 1 & -1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} - \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

El estadístico de Wald es:

$$W = (C\hat{\theta})' [C\mathcal{I}(\hat{\theta})^{-1}C']^{-1} (C\hat{\theta})$$

$$W = (C\hat{\theta})' [\hat{\sigma}^2 C(X^t X)^{-1} C']^{-1} (C\hat{\theta})$$

$$\text{Note } \hat{\sigma}^2 = \frac{1}{N} (\mathbf{y} - \mathbf{X}\hat{\beta})^t (\mathbf{y} - \mathbf{X}\hat{\beta})$$

$$\text{Bajo } H_0 \quad W \sim \chi^2_{r=\text{rango}(C)}$$

Ejemplo Wald Test: con datos CBR decline

```
cbr=read.csv("cbr.csv")
library(sasLM);library(matlib)
cbr$Setting=as.factor(cbr$Setting);cbr$Effort=as.factor(cbr$Effort)
y=as.matrix(cbr$CBR)
X=ModelMatrix(CBR~ Setting+ Effort, cbr)$X
C=matrix( c(0 ,1, -1, 0, 0, 0,0,
            0 ,1, 0, -1, 0, 0,0), nrow=2, byrow=TRUE)
beta=Ginv(t(X)%*%X)%*%t(X)%*%y;n=nrow(X)
sigma2=(t(y)%*%(diag(nrow(X))-X%*%Ginv(t(X)%*%X)%*%t(X))%*%y)/n
W=(t(C%*%beta)%*%solve(C%*%Ginv(t(X)%*%X)%*%t(C))%*%(C%*%beta))/sigma2
gl=R(C%*%Ginv(t(X)%*%X)%*%t(C)); gl
```

```
## [1] 2
```

```
W # Wald Stat
```

```
## [1]
```

```
## [1,] 0.8784516
```

```
alfa=0.05; qchisq((1-alfa), df=gl) ## valor de tablas F
```

```
## [1] 5.991465
```

```
pchisq(W, df=gl, lower.tail = F) ## Pvalue
```

```
## [1]
```

```
## [1,] 0.6445352
```

```
F=(W*(n-R(X)))/(R(t(C))*n) ## F test
```

```
F
```

```
## [1]
```

```
## [1,] 0.3294194
```

Ejemplo Wald Test: con datos CBR decline

```
cbr=read.csv("cbr.csv")
cbr$Setting=as.factor(cbr$Setting);cbr$Effort=as.factor(cbr$Effort)
m1=lm(CBR~ Setting+ Effort, cbr)
m2=lm(CBR~ Effort, cbr)
library(lmtest) ## Usando librería lmtest
waldtest(m1,m2)
```

```
## Wald test
##
## Model 1: CBR ~ Setting + Effort
## Model 2: CBR ~ Effort
##   Res.Df Df      F Pr(>F)
## 1      15
## 2      17 -2 0.3294 0.7244
```

Ejemplo de Hipotesis no lineal usando Wald

considere un modelo $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$

$$H_0: \mathbf{g}(\hat{\beta}) = \begin{bmatrix} \hat{\beta}_1/\hat{\beta}_2 \\ (\hat{\beta}_2)^2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

$$\hat{\beta} = \begin{bmatrix} 0.5 \\ 1.5 \end{bmatrix}, \hat{\mathbf{V}} = \begin{bmatrix} 1 & -0.5 \\ -0.5 & 2 \end{bmatrix}, \mathbf{g}(\hat{\beta}) = \begin{bmatrix} \hat{\beta}_1/\hat{\beta}_2 \\ (\hat{\beta}_2)^2 \end{bmatrix}$$

$$\frac{\partial}{\partial \beta} \mathbf{g}(\hat{\beta}) = \begin{bmatrix} 1/\hat{\beta}_2 & -\hat{\beta}_1/(\hat{\beta}_2)^2 \\ 0 & 2\hat{\beta}_2 \end{bmatrix}$$

$$\hat{\mathbf{V}}_{\mathbf{g}(\beta)} = \begin{bmatrix} 1/1.5 & -0.5/(1.5)^2 \\ 0 & 2 \cdot 1.5 \end{bmatrix} \begin{bmatrix} 1 & -0.5 \\ -0.5 & 2 \end{bmatrix} \begin{bmatrix} 1/1.5 & -0.5/(1.5)^2 \\ 0 & 2 \cdot 1.5 \end{bmatrix}' = \begin{bmatrix} 0.691 & -2.3 \\ -2.3 & 18 \end{bmatrix}$$

$$W_n = \left(\begin{bmatrix} 1/3 \\ 2.25 \end{bmatrix} - \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right)' \hat{\mathbf{V}}_{\mathbf{g}(\beta)}^{-1} \left(\begin{bmatrix} 1/3 \\ 2.25 \end{bmatrix} - \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right) \approx 1.038$$

p-value 0.60

Multiplicador de Lagrange (Score Tests)

- $\hat{\theta}$ es el estimador de MV de θ , de $k \times 1$
- $\hat{\theta}_0$ es el estimador de MV bajo H_0 , de $k \times 1$
- $\mathbf{u}(\theta) = (\frac{\partial \ell}{\partial \theta_1}, \dots, \frac{\partial \ell}{\partial \theta_k})'$ es el gradiente.
- $\mathbf{u}(\hat{\theta}) = 0$
- Si H_0 es cierta, $\mathbf{u}(\hat{\theta}_0)$ debe ser aprox. cero.
- Bajo H_0 para N grande, $\mathbf{u}(\hat{\theta}_0) \sim N_k(\mathbf{0}, \mathcal{J}(\theta))$, aproximadamente.
- y, $S = \mathbf{u}(\hat{\theta}_0)' \mathcal{J}(\hat{\theta}_0)^{-1} \mathbf{u}(\hat{\theta}_0) \sim \chi^2(r)$

donde r es el numero de restricciones impuestas en H_0

$$\mathcal{I}(\hat{\theta}_0) = \mathcal{J}(\hat{\theta}_0)$$

Prueba del Multiplicador de Lagrange en el ML

El estimador de MV restringido

$$\min_{\beta} S(\beta) = (y - X\beta)^t (y - X\beta) \text{ sujeto a } C\beta = m$$

Una funcion Lagrangeana es;

$$L(\beta; \lambda) = (y - X\beta)^t (y - X\beta) + 2\lambda^t (C\beta - m)$$

resulta;

$$\hat{\beta}_r = \hat{\beta} - (X^t X)^{-1} C^t [C(X^t X)^{-1} C^t]^{-1} (C\hat{\beta} - m)$$

con

$$\hat{\sigma}_r^2 = \frac{(y - X\hat{\beta}_r)^t (y - X\hat{\beta}_r)}{n}$$

$$H_0 : C\beta = m$$

$$LM = (C\hat{\beta} - m) [\hat{\sigma}_r^2 C(X^t X)^{-1} C^t]^{-1} (C\hat{\beta} - m)$$

donde $LM \sim \chi_{r=\text{rango}(C)}^2$

Ejemplo Multiplicador de Lagrange: con datos CBR decline

```
cbr=read.csv("cbr.csv")
library(sasLM);library(matlib)
cbr$Setting=as.factor(cbr$Setting);cbr$Effort=as.factor(cbr$Effort)
y=as.matrix(cbr$CBR)
X=ModelMatrix(CBR~ Setting+ Effort, cbr)$X
C=matrix( c(0 ,1, -1, 0, 0, 0,0,0 ,1, 0, -1, 0, 0,0), nrow=2, byrow=TRUE)
beta=Ginv(t(X)%*%X)%*%t(X)%*%y
beta_r=beta-Ginv(t(X)%*%X)%*%t(C)%*%solve(C%*%Ginv(t(X)%*%X)%*%t(C)) %*%(C%*%beta)
#C%*%beta
n=nrow(X)
sigma2_r=t(y-X%*%beta_r)%*%(y-X%*%beta_r)/n
LM=(t(C%*%beta)%*%solve(C%*%Ginv(t(X)%*%X)%*%t(C))%*%(C%*%beta))/sigma2_r
gl=R(C%*%Ginv(t(X)%*%X)%*%t(C))
gl
```

```
## [1] 2
```

```
LM # ML test
```

```
## [1]
```

```
## [1,] 0.841491
```

```
alfa=0.05; qchisq((1-alfa), df=gl) ## valor de tablas F
```

```
## [1] 5.991465
```

```
pchisq(LM, df=gl, lower.tail = F) ## Pvalue
```

```
## [1]
```

```
## [1,] 0.6565572
```

Contenido

- 1 Introducción
- 2 Modelo lineal: Estimación máximo verosímil
- 3 Pruebas basadas en la verosimilitud
- 4 Pruebas usando Metodo Delta
- 5 Pruebas basadas en computo intensivo

Metodo Delta

El Método Delta establece que podemos aproximar el comportamiento asintótico de funciones sobre una variable aleatoria, si la variable aleatoria X es en sí misma asintóticamente normal. En la práctica, este teorema nos dice que incluso si no conocemos el valor esperado y la varianza de la función $g(X)$, aún podemos aproximarnos razonablemente.

Metodo Delta

Teorema del Metodo delta

Supongamos que tenemos alguna secuencia de variables aleatorias X_n , tal que como $n \rightarrow \infty$
Si

$$\sqrt{n}(X_n - \mu) \rightarrow N(0, \sigma^2)$$

Sea g es una función continua, entonces el Método Delta establece que:

$$\frac{\sqrt{n}(g(X_n) - g(\mu))}{|g'(\mu)|\sigma} \approx N(0, 1),$$

donde g' es la primera derivada de g . Reordenando

$$g(X_n) \approx N\left(g(\mu), \frac{g'(\mu)^2 \sigma^2}{n}\right).$$

Lo anterior se basa en la expansion de series de Taylor

$$g(X_n) = g(\mu) + g'(\mu)(X_n - \mu) + g''(\mu) \frac{(X_n - \mu)^2}{2!} + \dots, \text{ eliminado termonos de alto orden}$$

$$g(X_n) \approx g(\mu) + g'(\mu)(X_n - \mu) \text{ note que } E(g(X_n)) = g(\mu) \text{ y } \text{Var}(g(X_n)) = g'(\mu)^2 \text{Var}(X_n) = \frac{g'(\mu)^2 \sigma^2}{n}$$

Metodo Delta multivariado

Proposición:

Ahora, tenemos un vector, $\mathbf{X}_n$, que se puede aproximar asintóticamente a una normal multivariada: $\mathbf{X}_n \rightarrow N(\theta, \Sigma)$, Para una función g dada y un valor específico de θ , suponga que $g'(\theta)$ existe y no es 0.

$$g(\mathbf{X}_n) \rightarrow N(g(\theta), [g'(\theta)]^t \Sigma [g'(\theta)])$$

programa Metodo Delta en Regresion multiple

Year	Month	Interest_Rate	Unemployment_Rate	Stock_Index_Price
2017	12	2.75	5.3	1464
2017	11	2.5	5.3	1394
2017	10	2.5	5.3	1357
2017	9	2.5	5.3	1293
2017	8	2.5	5.4	1256
2017	7	2.5	5.6	1254
2017	6	2.5	5.5	1234
2017	5	2.25	5.5	1195
2017	4	2.25	5.5	1159
2017	3	2.25	5.6	1167
2017	2	2	5.7	1130
2017	1	2	5.9	1075
2016	12	2	6	1047
2016	11	1.75	5.9	965
2016	10	1.75	5.8	943
2016	9	1.75	6.1	958
2016	8	1.75	6.2	971
2016	7	1.75	6.1	949
2016	6	1.75	6.1	884
2016	5	1.75	6.1	866
2016	4	1.75	5.9	876
2016	3	1.75	6.2	822
2016	2	1.75	6.2	704
2016	1	1.75	6.1	719

Regresión $y = \text{Stock_Index_Price}$ con predictores $x_1 = \text{Interest_Rate}$ y $x_2 = \text{Unemployment_Rate}$

$$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$$

Ejemplo Metodo Delta en Regresion

- Combinado método delta y MLE - Estimadores MLE $\hat{\beta}$

```
## # A tibble: 3 x 5
```

```
##   term          estimate std.error statistic p.value
##   <chr>          <dbl>     <dbl>     <dbl>   <dbl>
## 1 (Intercept)    1798.       899.        2.00  0.0586
## 2 TI              346.       111.        3.10  0.00539
## 3 TD            -250.       118.       -2.12  0.0460
```

- Matrix de varianzas covarianzas de $\hat{\beta}$

```
##           (Intercept)      TI      TD
## (Intercept)  808647.1 -95940.60 -105551.99
## TI           -95940.6  12402.59  12161.22
## TD          -105552.0  12161.22  13912.17
```

Deseamos encontrar la distribución de

$$g(\hat{\beta}) = \frac{\hat{\beta}_1}{\hat{\beta}_2}$$

Note que

$$\begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} \rightarrow N\left(\begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix}, \begin{pmatrix} V(\hat{\beta}_1), \text{Cov}(\hat{\beta}_1, \hat{\beta}_2) \\ \text{Cov}(\hat{\beta}_1, \hat{\beta}_2), V(\hat{\beta}_2) \end{pmatrix}\right)$$

Calculo de : $\text{Var}\left(\frac{\hat{\beta}_1}{\hat{\beta}_2}\right) = [g'(\beta)]^t \Sigma [g'(\beta)]$

Ejemplo Metodo Delta en Regresion

$$g'(\beta) = \left(\frac{1}{\beta_2}, \frac{-\beta_1}{\beta_2^2} \right)$$

$$\text{Var}\left(\frac{\hat{\beta}_1}{\hat{\beta}_2}\right) = \begin{pmatrix} \frac{1}{\hat{\beta}_2} & \frac{-\hat{\beta}_1}{\hat{\beta}_2^2} \end{pmatrix} \begin{pmatrix} V(\hat{\beta}_1), \text{Cov}(\hat{\beta}_1, \hat{\beta}_2) \\ \text{Cov}(\hat{\beta}_1, \hat{\beta}_2), V(\hat{\beta}_2) \end{pmatrix} \begin{pmatrix} \frac{1}{\hat{\beta}_2} \\ \frac{-\hat{\beta}_1}{\hat{\beta}_2^2} \end{pmatrix}$$

$$\widehat{\text{Var}}\left(\frac{\hat{\beta}_1}{\hat{\beta}_2}\right) = \frac{V(\hat{\beta}_1)}{\hat{\beta}_2^2} - 2 \frac{\sqrt{V(\hat{\beta}_1)\text{Cov}(\hat{\beta}_1, \hat{\beta}_2)}}{\hat{\beta}_2^3} + \frac{\hat{\beta}_1^2 V(\hat{\beta}_2)}{\hat{\beta}_2^4}$$

$$\widehat{\text{Var}}\left(\frac{\hat{\beta}_1}{\hat{\beta}_2}\right) = \frac{12402.59}{-250^2} - 2 \frac{\sqrt{12402.59 \times 12161.22}}{-250^3} + \frac{346^2 \times 13912.17}{-250^4}$$

Por lo tanto usando el Método delta:

$$\frac{\hat{\beta}_1}{\hat{\beta}_2} \rightarrow N\left(\frac{\beta_1}{\beta_2}, \left(\frac{V(\beta_1)}{\beta_2^2} - 2 \frac{\sqrt{V(\beta_1)\text{Cov}(\hat{\beta}_1, \hat{\beta}_2)}}{\beta_2^3} + \frac{\beta_1^2 V(\hat{\beta}_2)}{\beta_2^4}\right)\right)$$

Un Intervalo de confianza del $(1 - \alpha)\%$ se obtiene;

$$\frac{\hat{\beta}_1}{\hat{\beta}_2} \pm Z_{\alpha/2} \times \sqrt{\frac{V(\hat{\beta}_1)}{\hat{\beta}_2^2} - 2 \frac{\sqrt{V(\hat{\beta}_1)\text{Cov}(\hat{\beta}_1, \hat{\beta}_2)}}{\hat{\beta}_2^3} + \frac{\hat{\beta}_1^2 V(\hat{\beta}_2)}{\hat{\beta}_2^4}}$$

resulta $(-3.491738, 0.7290369)$ con $\alpha = 0.05$

Programa Metodo Delta en Regresion multiple

Codigo en R usandolo libreria alr3

```
## Year <- c(2017,2017,2017,2017,2017,2017,2017,2017,2017,2017,2017,
## 2017,2016,2016,2016,2016,2016,2016,2016,2016,2016,2016,2016,2016)
## Month <- c(12, 11,10,9,8,7,6,5,4,3,2,1,12,11,10,9,8,7,6,5,4,3,2,1)
## Interest_Rate <- c(2.75,2.5,2.5,2.5,2.5,2.5,2.5,2.5,2.25,2.25,2.25,2,2,
## 1.75,1.75,1.75,1.75,1.75,1.75,1.75,1.75,1.75,1.75,1.75)
## Unemployment_Rate <- c(5.3,5.3,5.3,5.3,5.4,5.6,5.5,5.5,5.5,5.6,5.7,5.9,6,5.9,5.8,6.1,
## 6.2,6.1,6.1,6.1,5.9,6.2,6.2,6.1)
## Stock_Index_Price <- c(1464,1394,1357,1293,1256,1254,1234,1195,1159,1167,1130,1075,1047,
## 965,943,958,971,949,884,866,876,822,704,719)
## y=Stock_Index_Price
## x1=Interest_Rate
## x2=Unemployment_Rate
## # metodo delta
## #install.packages("alr3", repos="http://R-Forge.R-project.org")
## library(alr3)
## library(broom)
## m2 <- lm(y ~ x1 + x2 )
## tidy(m2)
## delta.method(m2,g="x1/x2")
##
```

Programa Metodo Delta en Regresion multiple

Deseamos Probar la hipótesis **no lineal**:

$$H_0 : \frac{\beta_1}{\beta_2} = 1 \text{ vs } H_a : \frac{\beta_1}{\beta_2} \neq 1$$

Usando el Metodo Delta.

term	estimate	std.error	statistic	p.value
(Intercept)	1798.4040	899.2481	1.999898	0.0586119
x1	345.5401	111.3669	3.102717	0.0053892
x2	-250.1466	117.9499	-2.120787	0.0460127

	Estimate	SE	2.5 %	97.5 %
x1/x2	-1.38135	1.076748	-3.491738	0.7290369

Acepto H_0


Contenido

- 1 Introducción
- 2 Modelo lineal: Estimación máximo verosímil
- 3 Pruebas basadas en la verosimilitud
- 4 Pruebas usando Metodo Delta
- 5 Pruebas basadas en computo intensivo

Metodos de resmuestreo

- Los métodos de **remuestreo** tratan una muestra observada como una población finita, y generan muestras aleatorias a partir de ella para estimar características poblacionales y hacer inferencia sobre la población muestreada
- Los métodos **bootstrap** son una clase de métodos Monte Carlo no paramétricos que pretenden estimar la distribución de una población mediante re muestreo, estos métodos se usan cuando no se conoce la distribución de la población objetivo, de modo que la muestra es la única información disponible.
- Los métodos de **Monte Carlo** que implican el muestreo a partir de una distribución de probabilidad completamente especificada, son conocidos como bootstrap paramétrico. En el caso no paramétrico la distribución no se especifica.

Bootstrap




Programa Bootstrap en Regresion multiple

```
##          x1 x2    y
## 16      1.75 6.1  958
## 16.1    1.75 6.1  958
## 21      1.75 5.9  876
## 21.1    1.75 5.9  876
## 6       2.50 5.6 1254
## 4       2.50 5.3 1293
## 16.2    1.75 6.1  958
## 18      1.75 6.1  949
## 10      2.25 5.6 1167
## 11      2.00 5.7 1130
## 24      1.75 6.1  719
## 9       2.25 5.5 1159
## 17      1.75 6.2  971
## 6.1     2.50 5.6 1254
## 2       2.50 5.3 1394
## 20      1.75 6.1  866
## 16.3    1.75 6.1  958
## 4.1     2.50 5.3 1293
## 5       2.50 5.4 1256
## 8       2.25 5.5 1195
## 20.1    1.75 6.1  866
## 10.1    2.25 5.6 1167
## 9.1     2.25 5.5 1159
## 1       2.75 5.3 1464
## [1] 1806.682
## [1] 342.5982
## [1] -250.4502
```

Programa Bootstrap en Regresion multiple

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## -32.9287 -1.0911 -0.7231 -0.9033 -0.4637  0.2250
##           x2           x2
## -3.8153515 -0.7367468
```

Histogram of ind



Codigo Bootstrap

```
#programa para hacer Bootstrap en Regresion multiple
#H Vaquera
#Regresion y=Stock_Index_Price con predictoras x1=Interest_Rate y x2=Unemployment_Rate
Year <- c(2017,2017,2017,2017,2017,2017,2017,2017,2017,2017,2016,2016,2016,2016,2016,2016,2016,2016,2016,2016,2016)
Mendi <- c(12, 11,10,9,8,7,6,5,4,3,2,1,12, 11,10,9,8,7,6,5,4,3,2,1)
Interest_Rate <- c(2, 75,2,5,2,5,2,5,2,5,2,25,2,25,2,2,2,175,1,75,1,75,1,75,1,75,1,75,1,75,1,75,1,75)
Unemployment_Rate <- c(5,3,5,3,5,3,5,4,5,6,5,5,5,5,5,6,5,7,5,9,6,5,9,5,8,6,1,6,2,6,1,6,1,6,1,5,9,6,2,6,2,6,1)
Stock_Index_Price <- c(1464,1394,1357,1299,1256,1254,1234,1195,1159,1167,1180,1075,1047,965,949,968,971,949,884,866,876,822,704,719)
y=Stock_Index_Price
x1=Interest_Rate
x2=Unemployment_Rate
mimodelo <- lm(y ~ x1 + x2)
summary(mimodelo)

#coeficientes de regresion y CME
mimodelo$coefficients
b0=mimodelo$coefficients[1]
b1=mimodelo$coefficients[2]
b2=mimodelo$coefficients[3]
raiz_cme=summary(mimodelo)$sigma

#Bootstrap

data<-data.frame(cbind(x1,x2,y))
nrowof(data)
data[sample(nrow(data),size=nr,replace=TRUE),]

#remuestreo
beta0<-c()
beta1<-c()
beta2<-c()

NB00T <- 1000 ; ind <- NULL ; set.seed(9999)
for (i in 1:NB00T){
  datain<-data[sample(nrow(data),size=nr,replace=TRUE),]
  regres<-lm(y~x1+x2,data=datain)
  beta0<-append(beta0,regres$coefficients[1])
  beta1<-append(beta1,regres$coefficients[2])
  beta2<-append(beta2,regres$coefficients[3])
}

mean(beta0)
mean(beta1)
mean(beta2)
ind=beta2/beta1
summary(ind)
ls=sort(ind)[25]
ls=sort(ind)[975]
id95=c(ls,ls)
id95
hist(ind,50)
```

Programa MonteCarlo en Regresion multiple

```
#coeficientes de regresion y CME
mimodelo$coefficients

## (Intercept)          x1          x2
## 1798.4040      345.5401    -250.1466

b0e=mimodelo$coefficients[1]
b1e=mimodelo$coefficients[2]
b2e=mimodelo$coefficients[3]
raiz_cme=summary(mimodelo)$sigma
#simulaciones
pred<-data.frame(cbind(x1,x2))
nr=nrow(pred)
beta0<-c()
beta1<-c()
beta2<-c()
NREP <- 1000 ; ind <- NULL ; set.seed(9999)
for (i in 1:NREP){
  y=b0e+b1e*x1+b2e*x2+rnorm(nr,0,raiz_cme)
  regre<-lm(y~x1+x2)
  beta0<-append(beta0,regre$coefficients[1])
  beta1<-append(beta1,regre$coefficients[2])
  beta2<-append(beta2,regre$coefficients[3])
}
mean(beta0)

## [1] 1829.671
mean(beta1)

## [1] 343.0191
mean(beta2)
```

Programa MonteCarlo en Regresion multiple

```
#indice a estudiar beta2/beta1
```

```
ind=beta2/beta1
```

```
summary(ind)
```

```
##      Min.   1st Qu.   Median     Mean  3rd Qu.    Max.
## -24.3361  -1.2078   -0.7433   -0.9210  -0.4225   81.4351
```

```
li=sort(ind)[25]
```

```
ls=sort(ind)[975]
```

```
ic95=c(li,ls)
```

```
ic95
```

```
##           x2           x2
```

```
## -3.72511628 -0.01480134
```

```
hist(ind,50)
```

Histogram of ind

