



COLEGIO DE
POSTGRADUADOS

CAMPUS MONTECILLO

PSEI-ESTADÍSTICA Y CIENCIA DE
DATOS

TARE 5. MODELOS LINEALES

PROFESOR DR. HUMBERTO VAQUERA HUERTA

Al:

Guadalupe Monroy Hernández

Texcoco, Edo. México

Problema 1 (Distribucion de formas quadraticas)

1. Suponga que $X = \begin{pmatrix} X_1 \\ X_2 \\ X_3 \end{pmatrix}$ donde $X \sim N(\mu, \Sigma)$ donde $\mu = \begin{pmatrix} 3 \\ -2 \\ 1 \end{pmatrix}$, $\Sigma = \sigma^2 I = \begin{pmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \sigma_2^2 & 0 \\ 0 & 0 & \sigma_3^2 \end{pmatrix}$
 y $A = \frac{1}{3} \begin{pmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{pmatrix}$, $B = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 0 & -1 \end{pmatrix}$.

a. ¿Cuál es la distribución de $X^T A X / \sigma^2$?

Para $X \sim N_n(\mu, I)$, entonces:

$$X^t A X / \sigma^2 \sim X^2(r, \mu' A \mu / 2\sigma^2)$$

Lo anterior si A es simétrico e idempotente. Dado que Σ es una matriz diagonal.
 Prueba de idempotencia:

$$\begin{aligned} A^2 &= A A = A \\ &= \frac{1}{3} \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix} \frac{1}{3} \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix} \\ A^2 &= \begin{bmatrix} 2/3 & -1/3 & -1/3 \\ -1/3 & 2/3 & -1/3 \\ -1/3 & -1/3 & 2/3 \end{bmatrix} \begin{bmatrix} 2/3 & -1/3 & -1/3 \\ -1/3 & 2/3 & -1/3 \\ -1/3 & -1/3 & 2/3 \end{bmatrix} \\ &= \begin{bmatrix} 2/3 & -1/3 & -1/3 \\ -1/3 & 2/3 & -1/3 \\ -1/3 & -1/3 & 2/3 \end{bmatrix} = A \\ \therefore A &\text{ es idempotente, simétrica y con } r=2 \end{aligned}$$

$$X^t A X / \sigma^2 \sim X^2(r, \mu' A \mu / 2\sigma^2)$$

Se obtienen los parametros $\mu' A \mu / 2\sigma^2$

$$\mu' A \mu = \begin{bmatrix} 3 & -2 & 1 \end{bmatrix} \begin{bmatrix} 2/3 & -1/3 & -1/3 \\ -1/3 & 2/3 & -1/3 \\ -1/3 & -1/3 & 2/3 \end{bmatrix} \begin{bmatrix} 3 \\ -2 \\ 1 \end{bmatrix} = \frac{38}{3}$$

Por lo que $\mu' A \mu / 2\sigma^2$:

$$\mu' A \mu / 2\sigma^2 = \frac{38}{3} = \frac{19}{3\sigma^2}$$

La distribución es:

$$X^t A X / \sigma^2 \sim X^2(2, \frac{19}{3\sigma^2})$$

b. ¿Son X^TAX y BX independientes?

Haciendo uso de la propiedad: Si B es una matriz de constantes $k \times p$, A es una matriz simétrica de constantes $p \times p$, y $X \sim N_p(\mu, \Sigma)$, entonces BX y X^TAX son independientes si y solo si $B\Sigma A = 0$.

$$\begin{aligned} B\Sigma A &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & 0 & -1 \end{bmatrix} \begin{bmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \sigma_2^2 & 0 \\ 0 & 0 & \sigma_3^2 \end{bmatrix} \frac{1}{3} \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix} \\ &= \frac{1}{3} \begin{bmatrix} \sigma_1^2 & \sigma_2^2 & \sigma_3^2 \\ \sigma_1^2 & 0 & -\sigma_3^2 \end{bmatrix} \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix} \\ &= \frac{1}{3} \begin{bmatrix} 2\sigma_1^2 - \sigma_2^2 - \sigma_3^2 & -\sigma_1^2 + 2\sigma_2^2 - \sigma_3^2 & -\sigma_1^2 - \sigma_2^2 + 2\sigma_3^2 \\ 2\sigma_1^2 + \sigma_3^2 & -\sigma_1^2 + \sigma_3^2 & -\sigma_1^2 - 2\sigma_3^2 \end{bmatrix} \neq 0 \\ &\therefore \text{Por lo que no son independientes} \end{aligned}$$

c. ¿Son X^TAX y $X_1 + X_2 + X_3$ independientes?

Para definir si X^TAX y $X_1 + X_2 + X_3$ son independientes

d. Suponga $C = \frac{1}{3} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}$. ¿Cuál es la distribución de X^TCX/σ^2 ?

$$C = \frac{1}{3} \cdot \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}$$

Si $X \sim N_n(\mu, I)$, entonces

$$X^tAX/\sigma^2 \sim X^2(r, \mu' A \mu / 2\sigma^2)$$

Prueba de idempotencia

$$\begin{aligned} C^2 &= C \\ &= \frac{1}{3} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} \frac{1}{3} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} = \frac{1}{9} \begin{bmatrix} 3 & 3 & 3 \\ 3 & 3 & 3 \\ 3 & 3 & 3 \end{bmatrix} \\ &= \frac{1}{3} \cdot \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} = C \quad \therefore \text{es idempotente y de } r=1 \end{aligned}$$

Se obtiene la distribución $X^t CX/\sigma^2 \sim X^2(r, \mu' C \mu/2\sigma^2)$

$$\begin{aligned}\mu' C \mu/2\sigma^2 &= \frac{1}{2\sigma^2} \cdot [3 \quad -2 \quad 1] \cdot \begin{bmatrix} 1/3 & 1/3 & 1/3 \\ 1/3 & 1/3 & 1/3 \\ 1/3 & 1/3 & 1/3 \end{bmatrix} \cdot \begin{bmatrix} 3 \\ -2 \\ 1 \end{bmatrix} \\ &= \frac{1}{2\sigma^2} \cdot [2/3 \quad 2/3 \quad 2/3] \cdot \begin{bmatrix} 3 \\ -2 \\ 1 \end{bmatrix} = \frac{1}{2\sigma^2} \cdot \frac{4}{3} = \frac{2}{3\sigma^2}\end{aligned}$$

La distribución es:

$$\mu' C \mu/2\sigma^2 \sim X^2 \left(1, \frac{2}{3\sigma^2}\right)$$

e. ¿Son las formas cuadráticas $X^T A X$ y $X^T C X$ independientes?

$\mu' A \mu/2\sigma^2$ y $\mu' C \mu/2\sigma^2$ son independientes si $B \Sigma A = 0$

$$\begin{aligned}B \Sigma A &= \begin{bmatrix} 1/3 & 1/3 & 1/3 \\ 1/3 & 1/3 & 1/3 \\ 1/3 & 1/3 & 1/3 \end{bmatrix} \cdot \begin{bmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \sigma_2^2 & 0 \\ 0 & 0 & \sigma_3^2 \end{bmatrix} \cdot \begin{bmatrix} 2/3 & -1/3 & -1/3 \\ -1/3 & 2/3 & -1/3 \\ -1/3 & -1/3 & 2/3 \end{bmatrix} \\ &= \begin{bmatrix} 1/3\sigma_1^2 & 1/3\sigma_2^2 & 1/3\sigma_3^2 \\ 1/3\sigma_1^2 & 1/3\sigma_2^2 & 1/3\sigma_3^2 \\ 1/3\sigma_1^2 & 1/3\sigma_2^2 & 1/3\sigma_3^2 \end{bmatrix} \cdot \begin{bmatrix} 2/3 & -1/3 & -1/3 \\ -1/3 & 2/3 & -1/3 \\ -1/3 & -1/3 & 2/3 \end{bmatrix} \\ &= \begin{bmatrix} 2/9\sigma_1^2 - 1/9\sigma_2^2 - 1/9\sigma_3^2 & -1/9\sigma_1^2 + 2/9\sigma_2^2 - 1/9\sigma_3^2 & -1/9\sigma_1^2 - 1/9\sigma_2^2 + 2/9\sigma_3^2 \\ 2/9\sigma_1^2 - 1/9\sigma_2^2 - 1/9\sigma_3^2 & -1/9\sigma_1^2 + 2/9\sigma_2^2 - 1/9\sigma_3^2 & -1/9\sigma_1^2 - 1/9\sigma_2^2 + 2/9\sigma_3^2 \\ 2/9\sigma_1^2 - 1/9\sigma_2^2 - 1/9\sigma_3^2 & -1/9\sigma_1^2 + 2/9\sigma_2^2 - 1/9\sigma_3^2 & -1/9\sigma_1^2 - 1/9\sigma_2^2 + 2/9\sigma_3^2 \end{bmatrix} \neq 0\end{aligned}$$

Problema 2 (Teorema de Cochran).

Sean

$$B_1 = \frac{1}{6} \begin{bmatrix} 2 & 2 & -1 & -1 & -1 & -1 \\ 2 & 2 & -1 & -1 & -1 & -1 \\ -1 & -1 & 2 & 2 & -1 & -1 \\ -1 & -1 & 2 & 2 & -1 & -1 \\ -1 & -1 & -1 & -1 & 2 & 2 \\ -1 & -1 & -1 & -1 & 2 & 2 \end{bmatrix}, B_2 = \frac{1}{6} \begin{bmatrix} 1 & -1 & 1 & -1 & 1 & -1 \\ -1 & 1 & -1 & 1 & -1 & 1 \\ 1 & -1 & 1 & -1 & 1 & -1 \\ -1 & 1 & -1 & 1 & -1 & 1 \\ 1 & -1 & 1 & -1 & 1 & -1 \\ -1 & 1 & -1 & 1 & -1 & 1 \end{bmatrix}$$

$$B_3 = \frac{1}{6} \begin{bmatrix} 2 & -2 & -1 & 1 & -1 & 1 \\ -2 & 2 & 1 & -1 & 1 & -1 \\ -1 & 1 & 2 & -2 & -1 & 1 \\ 1 & -1 & -2 & 2 & 1 & 1 \\ -1 & 1 & -1 & 1 & 2 & -2 \\ 1 & -1 & 1 & -1 & -2 & 2 \end{bmatrix}, B_4 = \frac{1}{6} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 \end{bmatrix}$$

Establezca que las matrices anteriores satisfacen la hipótesis del Teorema de Cochran. Si $X \sim N(0, I_6)$

Propiedad: $Y \sim N(0, \Sigma)$ y suponga que $A_1, A_2, \dots, A_n$ son matrices simétricas e idempotentes con $r(A_i) = r_i$ y $A = \sum_{i=1}^n A_i$ con $r(A) = r$ entonces:

$$Y^t A Y \sim \chi^2_{(r_i, \frac{1}{2} \mu^t A_i \mu)}$$

$Y^t A_i Y$ y $Y^t A_j Y$ son independientes para $i \neq j$

- a) ¿Cuáles son las distribuciones de $X^t B_i X, i = 1, 2, 3, 4$ Para responder la pregunta se analiza: B_1, B_2, B_3, B_4 la cuales deben ser: simétricas ($B = B_i^t$), idempotentes ($B_i = B_i * B_i$)

$$B_1 = \frac{1}{6} \begin{bmatrix} 2 & 2 & -1 & -1 & -1 & -1 \\ 2 & 2 & -1 & -1 & -1 & -1 \\ -1 & -1 & 2 & 2 & -1 & -1 \\ -1 & -1 & 2 & 2 & -1 & -1 \\ -1 & -1 & -1 & -1 & 2 & 2 \\ -1 & -1 & -1 & -1 & 2 & 2 \end{bmatrix} = B_1^t$$

$$B_2 = \frac{1}{6} \begin{bmatrix} 1 & -1 & 1 & -1 & 1 & -1 \\ -1 & 1 & -1 & 1 & -1 & 1 \\ 1 & -1 & 1 & -1 & 1 & -1 \\ -1 & 1 & -1 & 1 & -1 & 1 \\ 1 & -1 & 1 & -1 & 1 & -1 \\ -1 & 1 & -1 & 1 & -1 & 1 \end{bmatrix} = B_2^t$$

$$B_3 = \frac{1}{6} \begin{bmatrix} 2 & -2 & -1 & 1 & -1 & 1 \\ -2 & 2 & 1 & -1 & 1 & -1 \\ -1 & 1 & 2 & -2 & -1 & 1 \\ 1 & -1 & -2 & 2 & 1 & 1 \\ -1 & 1 & -1 & 1 & 2 & -2 \\ 1 & -1 & 1 & -1 & -2 & 2 \end{bmatrix} = B_3^t$$

$$B_4 = \frac{1}{6} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 \end{bmatrix} = B_4^t$$

Prueba de idempotencia:

```
> #Idempotencia
> B12=B1%*%B1
> Idem_B1 = all.equal(B1, B12)
> Idem_B1
[1] TRUE
>
> B22=B2%*%B2
> Idem_B2 = all.equal(B2, B22)
> Idem_B2
[1] TRUE
```

```

>
> B32=B3%*%B3
> Idem_B3 = all.equal(B3, B32)
> Idem_B3
[1] TRUE
> B42=B4%*%B4
> Idem_B4 = all.equal(B4, B42)
> Idem_B4
[1] TRUE

```

Son idempotentes.

$r(A_i) = r_i$ y $A = \sum_{i=1}^n A_i$ con $r(A) = r$:

```

R(B1)
[1] 2
> R(B2)
[1] 1
> R(B3)
[1] 2
> R(B4)
[1] 1
> B=B1+B2+B3+B4
> R(B)
[1] 6

```

Por lo tanto:

$$\begin{aligned}
 *X^t B_1 X &\sim \chi^2_{(2, \frac{1}{2} \mu^t B_1 \mu)} \\
 *X^t B_2 X &\sim \chi^2_{(1, \frac{1}{2} \mu^t B_2 \mu)} \\
 *X^t B_3 X &\sim \chi^2_{(2, \frac{1}{2} \mu^t B_3 \mu)} \\
 *X^t B_4 X &\sim \chi^2_{(1, \frac{1}{2} \mu^t B_4 \mu)}
 \end{aligned}$$

b) ¿Son independientes?

- $X^t B_1 X y X^t B_2 X$ son independientes
- $X^t B_1 X y X^t B_3 X$ son independientes
- $X^t B_1 X y X^t B_4 X$ son independientes
- $X^t B_2 X y X^t B_3 X$ son independientes
- $X^t B_2 X y X^t B_4 X$ son independientes
- $X^t B_3 X y X^t B_4 X$ son independientes

Problema 3 1(Pruebas de Hipotesis).

En una prueba de alimentación de pollos de engorda, se probaron cinco suplementos proteicos. Los pesos finales a las 6 semanas se dan en la Tabla (Snedecor 1948, p. 214).

Protein Supplement.

Linseed	Soybean	Sunf lower	Meat	Casein
309	243	423	325	368
229	230	340	257	390
181	248	392	303	379
141	327	339	315	260
260	329	341	380	404
203	250	226	153	318
148	193	320	263	352
169	271	295	242	359
213	316	334	206	216
257	267	322	344	222
244	199	297	258	283
271	177	318		332
	158			
	248			

Final Weights (g) of Chicks at 6 Weeks

Considere el modelo: $y_{ij} = \mu + \alpha_i + \epsilon_{ij}$

- a. Pruebe que $H_0 : \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = \alpha_5$, vs H_a : al menos un α_i es diferente del resto. Use prueba de F con ANOVA.

La hipótesis $H_0 : \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = \alpha_5$ o

$$H_0 : \alpha_1 - \alpha_2 = 0, \alpha_1 - \alpha_3 = 0, \alpha_1 - \alpha_4 = 0, \alpha_1 - \alpha_5 = 0$$

$$H_0 : C\beta = \begin{pmatrix} 0 & 1 & -1 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 \\ 0 & 1 & 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

Estadístico de prueba $H_0 : C\beta = d$, es

$$F_c = \frac{\frac{(C\hat{\beta}-d)^t [C(X^tX)^{-1}C^t]^{-1} (C\hat{\beta}-d)}{m}}{\frac{y^t(I-X(X^tX)^{-1}X^t)y}{(n-k)}},$$

$F(m, n - k)$.

Es comprobable si $r(X) = r \begin{pmatrix} X \\ C \end{pmatrix}$

```
> modelo31 = ModelMatrix(Peso ~ Fuente, datos31)
> X = as.matrix(modelo31$X)
```

```

> y = as.matrix(datos31$Peso)
> C1 <- matrix( c(0, 1, -1, 0, 0, 0,
+                0, 1, 0, -1, 0, 0,
+                0, 1, 0, 0, -1, 0,
+                0, 1, 0, 0, 0, -1), nrow=4, byrow=TRUE)
> R(X)
[1] 5
> X_C=rbind(X,C1)
> R(X_C)
[1] 5
># Es comprobable
> beta <- Ginv(t(X)%*%X)%*%t(X)%*%y
> SCH <- t(C1)%*%beta)%*%solve(C1)%*%Ginv(t(X)%*%X)%*%t(C1))%*%(C1)%*%beta)
> glh <- R(C1)%*%Ginv(t(X)%*%X)%*%t(C1))
> SCE <- t(y)%*%(diag(nrow(X))-X)%*%Ginv(t(X)%*%X)%*%t(X))%*%y
> gle <- R(diag(nrow(X)))-R(X)%*%Ginv(t(X)%*%X)%*%t(X))
> FC <- (SCH/glh)/(SCE/gle)
># F calculada
> FC
      [,1]
[1,] 8.632355
> alfa=0.05
># tablas F
> qf((1-alfa), df1=glh, df2=gle)
[1] 2.536579
>## Pvalue
> pf(FC, df1=glh, df2=gle, lower.tail = F)
      [,1]
[1,] 1.684932e-05

```

$F_c = 8.632355$ y el valor de tablas es 2.536579, por lo que **se rechaza H_0 con una significancia de $\alpha = 0.05$.**

Al menos una fuente de proteína produce un efecto diferente en el peso.

b. Probar

$$H_0 : C\beta = \begin{pmatrix} 0 & 3 & -2 & -2 & -2 & 3 \\ 0 & 0 & 1 & -2 & -1 & 0 \\ 0 & 0 & -1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

¿Es comprobable?

Es comprobable si $r(X) = r \begin{pmatrix} X \\ C \end{pmatrix}$

```

> C2 <- matrix( c(0, 3, -2, -2, -2, 3,
+                0, 0, 1, -2, -1, 0,
+                0, 0, -1, 0, 1, 0,
+                0, 1, 0, 0, 0, -1), nrow=4, byrow=TRUE)
>

```



```
> R(X)
[1] 5
> X_C2=rbind(X,C2)
> R(X_C2)
[1] 6
> #no es comprobable
```

Probar la hipótesis.

```
> beta <- Ginv(t(X)%*%X)%*%t(X)%*%y
> SCH2 <- t(C2)%*%beta)%*%solve(C2)%*%Ginv(t(X)%*%X)%*%t(C2))%*%(C2)%*%beta)
> glh2 <- R(C2)%*%Ginv(t(X)%*%X)%*%t(C2))
> SCE2 <- t(y)%*%(diag(nrow(X))-X)%*%Ginv(t(X)%*%X)%*%t(X))%*%y
> gle2 <- R(diag(nrow(X)))-R(X)%*%Ginv(t(X)%*%X)%*%t(X))
> FC2 <- (SCH2/glh2)/(SCE2/gle2)
> # F calculada
> FC2
      [,1]
[1,] 8.632355
>
> alfa=0.05
> ## valor de tablas F
> qf((1-alfa), df1=glh2, df2=gle2)
[1] 2.536579
> ## Pvalue
> pf(FC2, df1=glh2, df2=gle2, lower.tail = F)
      [,1]
[1,] 1.684932e-05
```

De igual manera, se rechaza H_0 con $\alpha = 0.05$.

Para probar **contrastes ortogonales** (combinaciones lineales).

- c. Suponga que el investigador quiere probar si el efecto en el peso es el mismo si se usan fuentes proteicas de origen animal y vegetal es decir $2\alpha_1 + 2\alpha_2 + 2\alpha_3 - 3\alpha_4 - 3\alpha_5 = 0$. Pruebe $H_0 : 2\alpha_1 + 2\alpha_2 + 2\alpha_3 - 3\alpha_4 - 3\alpha_5 = 0$ vs $H_a : 2\alpha_1 + 2\alpha_2 + 2\alpha_3 - 3\alpha_4 - 3\alpha_5 \neq 0$ usando un $\alpha = 0.05$.

La hipótesis $H_0 : 2\alpha_1 + 2\alpha_2 + 2\alpha_3 - 3\alpha_4 - 3\alpha_5 = 0$

$$H_0 : \lambda^t \beta = (0 \quad 2 \quad 2 \quad 2 \quad -3 \quad -3) \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \end{pmatrix} = 0$$

En el caso es pecial en el que $C = \lambda^t$, un estadístico de prueba para

$$H_0 : \lambda^t \beta = d \quad vs \quad H_a : \lambda^t \beta \neq d$$

Se contruye el estadístico de prueba.

$$F_c = \frac{(\lambda^t \hat{\beta} - d)^t [\lambda^t (X^t X)^{-1} \lambda]^{-1} (\lambda^t \hat{\beta} - d)}{\frac{1}{y^t (I - X(X^t X)^{-1} X^t) y}},$$

$F(1, n - k)$.

Es comprobable si $r(X) = r \begin{pmatrix} X \\ C \end{pmatrix}$

```
> C <- matrix(c(0,2,2,2,2,-3,-3))
>
> R(X)
[1] 5
> X_C3=rbind(X,t(C))
> R(X_C3)
[1] 5
> # La hipotesis es comprobable
> # Prueba de hipotesis con la prueba F
>
> beta <- Ginv(t(X)%*%X)%*%t(X)%*%y
> SCH3 <- t(t(C)%*%beta)%*%solve(t(C)%*%Ginv(t(X)%*%X)%*%C)%*%(t(C)%*%beta)
> glh3 <- R(t(C)%*%Ginv(t(X)%*%X)%*%C)
> SCE3 <- t(y)%*%(diag(nrow(X))-X)%*%Ginv(t(X)%*%X)%*%t(X))%*%y
> gle3 <- R(diag(nrow(X)))-R(X)%*%Ginv(t(X)%*%X)%*%t(X))
> FC3 <- (SCH3/glh3)/(SCE3/gle3)
> # F calculada
> FC3
      [,1]
[1,] 1.006223
>
> alfa=0.05
> # valor de tablas F
> qf((1-alfa), df1=glh3, df2=gle3)
[1] 4.012973
> # Pvalue
> pf(FC3, df1=glh3, df2=gle3, lower.tail = F)
      [,1]
[1,] 0.3201242
```

$F_c = 1.006223$ y el valor de tablas es 4.012973, por lo que no se rechaza H_0 con $\alpha = 0.05$.

De manera que podemos concluir que el efecto en el peso es el mismo usando fuentes proteicas de origen animal o usando fuentes de origen vegetal.

Problema 3 2

Considere el siguiente modelo ANOVA de dos vías:

$$y_{ijk} = \mu + \alpha_i + \beta_j + \epsilon_{ijk}$$

Suponga que los valores de respuesta se dan en la siguiente tabla:

		Factor B		
		1	2	3
Factor A	1	17, 20	15	20
	2	12		11,14
	3	6		17
	4	9	4, 6	19

Tenga en cuenta que las celdas vacías significan que no hay observación.

Inciso a

a). Usando una prueba de F general muestre que $H_0 : \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4$ es comprobable y pruebe H_0 con un nivel de significancia del 5%.

Modelo:

`X=ModelMatrix(Respuesta~A+B,datos3)$X`

$$y = X\beta + \epsilon$$

$$\begin{bmatrix} y_{111} \\ y_{112} \\ y_{121} \\ y_{131} \\ y_{211} \\ y_{231} \\ y_{232} \\ y_{311} \\ y_{331} \\ y_{411} \\ y_{421} \\ y_{422} \\ y_{431} \end{bmatrix} = \begin{bmatrix} 17 \\ 20 \\ 15 \\ 20 \\ 12 \\ 11 \\ 14 \\ 6 \\ 17 \\ 9 \\ 4 \\ 6 \\ 19 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix} + \begin{bmatrix} \epsilon_{111} \\ \epsilon_{112} \\ \epsilon_{121} \\ \epsilon_{131} \\ \epsilon_{211} \\ \epsilon_{231} \\ \epsilon_{232} \\ \epsilon_{311} \\ \epsilon_{331} \\ \epsilon_{411} \\ \epsilon_{421} \\ \epsilon_{422} \\ \epsilon_{431} \end{bmatrix}$$

$H_0 : \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4$ o $H_0 : \alpha_1 - \alpha_2 = 0, \alpha_1 - \alpha_3 = 0, \text{ y } \alpha_1 - \alpha_4 = 0$

$$H_0 = C\beta = \begin{bmatrix} 0 & 1 & -1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & -1 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Es comprobable si $r(X) = r \begin{pmatrix} X \\ C \end{pmatrix}$

```
> #Es comprobable
> R(X)
[1] 6
```

```

> C1<-c(0,1,-1,0,0,0,0,0)
> C2<-c(0,1,0,-1,0,0,0,0)
> C3<-c(0,1,0,0,-1,0,0,0)
> C<-rbind(C1,C2,C3)
> X_R=rbind(X,C)
> R(X_R)
[1] 6

```

Es comprobable.

Estadístico F:

$$F_c = \frac{(\mathbf{C}\hat{\beta} - \mathbf{d})^t [\mathbf{C}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{C}^t]^{-1} (\mathbf{C}\hat{\beta} - \mathbf{d})}{\frac{\mathbf{y}^t (\mathbf{I} - \mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t) \mathbf{y}}{(n - k)}} \sim F_{(m, n-k)}$$

```

> beta=Ginv(t(X)%*%X)%*%t(X)%*%y
> #C%*%beta
> SCH=t(C%*%beta)%*%solve(C%*%Ginv(t(X)%*%X)%*%t(C))%*%(C%*%beta)
> glh=R(C%*%Ginv(t(X)%*%X)%*%t(C))
> SCE=t(y)%*%(diag(nrow(X))-X%*%Ginv(t(X)%*%X)%*%t(X))%*%y
> gle=R(diag(nrow(X)))-R(X%*%Ginv(t(X)%*%X)%*%t(X))
> # F calculada
> FC=(SCH/glh)/(SCE/gle)
> FC
      [,1]
[1,] 6.080275
> # valor de tablas F
> alfa=0.05
> qf((1-alfa), df1=glh, df2=gle)
[1] 4.346831
> # Pvalue
> pf(FC, df1=glh, df2=gle, lower.tail = F)
      [,1]
[1,] 0.02314921

```

Dado que el p value es menor a $\alpha = 0.05$ se rechaza H_0

b. Usando una prueba de F general pruebe que $H_0 : \beta_1 = \beta_2 = \beta_3$ es comprobable y pruebe H_0 con un nivel de significancia del 5

$H_0 : \beta_1 = \beta_2 = \beta_3$ 0 $H_0 : \beta_1 - \beta_2 = 0$, y $\beta_1 - \beta_3 = 0$

$$H_0 = C\beta = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & -1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Es comprobable si $r(X) = r \begin{pmatrix} X \\ C \end{pmatrix}$

```
> R(X)
[1] 6
> C1<-c(0,0,0,0,0,1,-1,0)
> C2<-c(0,0,0,0,0,1,0,-1)
> C<-rbind(C1,C2)
> X_R=rbind(X,C)
> R(X_R)
[1] 6
>#Es comprobable
```

Es comprobable.

Estadístico F:

$$F_c = \frac{(\mathbf{C}\hat{\beta} - \mathbf{d})^t [\mathbf{C}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{C}^t]^{-1} (\mathbf{C}\hat{\beta} - \mathbf{d})}{\frac{m}{\mathbf{y}^t (\mathbf{I} - \mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t) \mathbf{y}} (n - k)} \sim F_{(m, n-k)}$$

```
> beta=Ginv(t(X)%*%X)%*%t(X)%*%y
> #C*%beta
> SCH=t(C*%beta)%*%solve(C*%Ginv(t(X)%*%X)%*%t(C))%*%(C*%beta)
> glh=R(C*%Ginv(t(X)%*%X)%*%t(C))
> SCE=t(y)%*%(diag(nrow(X))-X*%Ginv(t(X)%*%X)%*%t(X))%*%y
> gle=R(diag(nrow(X)))-R(X*%Ginv(t(X)%*%X)%*%t(X))
> # Fcalculada
> FC=(SCH/glh)/(SCE/gle)
> FC
      [,1]
[1,] 7.229337
> #F de tablas
> alfa=0.05
> qf((1-alfa), df1=glh, df2=gle)
[1] 4.737414
> # pvalue
> pf(FC, df1=glh, df2=gle, lower.tail = F)
      [,1]
[1,] 0.01982591
```

Dado que el valor del p_value es menor a $\alpha = 0.05$, hay evidencia suficiente para rechazar H_0 .

c. Muestre que $\alpha_i - \alpha_{i'}$ y $\beta_j - \beta_{j'}$ son estimables para $i \neq i', j \neq j'$.

Para α :

$$\begin{aligned}
E(y_{111} - y_{211}) &= (\mu + \alpha_1 + \beta_1) - (\mu + \alpha_2 + \beta_1) = \alpha_1 - \alpha_2 && \text{La función es estimable.} \\
E(y_{111} - y_{311}) &= (\mu + \alpha_1 + \beta_1) - (\mu + \alpha_3 + \beta_1) = \alpha_1 - \alpha_3 && \text{La función es estimable.} \\
E(y_{111} - y_{411}) &= (\mu + \alpha_1 + \beta_1) - (\mu + \alpha_4 + \beta_1) = \alpha_1 - \alpha_4 && \text{La función es estimable.} \\
E(y_{211} - y_{311}) &= (\mu + \alpha_2 + \beta_1) - (\mu + \alpha_3 + \beta_1) = \alpha_2 - \alpha_3 && \text{La función es estimable.} \\
E(y_{211} - y_{411}) &= (\mu + \alpha_2 + \beta_1) - (\mu + \alpha_4 + \beta_1) = \alpha_2 - \alpha_4 && \text{La función es estimable.} \\
E(y_{311} - y_{411}) &= (\mu + \alpha_3 + \beta_1) - (\mu + \alpha_4 + \beta_1) = \alpha_3 - \alpha_4 && \text{La función es estimable.}
\end{aligned}$$

Para β :

$$\begin{aligned}
E(y_{111} - y_{121}) &= (\mu + \alpha_1 + \beta_1) - (\mu + \alpha_1 + \beta_2) = \beta_1 - \beta_2 && \text{La función es estimable.} \\
E(y_{111} - y_{131}) &= (\mu + \alpha_1 + \beta_1) - (\mu + \alpha_1 + \beta_3) = \beta_1 - \beta_3 && \text{La función es estimable.} \\
E(y_{211} - y_{131}) &= (\mu + \alpha_1 + \beta_2) - (\mu + \alpha_1 + \beta_3) = \beta_2 - \beta_3 && \text{La función es estimable.}
\end{aligned}$$

e. Usando modelo completo $y_{ijk} = \mu + \alpha_i + \epsilon_{ijk}$ y reducido $y_{ijk} = \mu + \epsilon_{ijk}$ Pruebe la hipótesis $H_0 : \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4$ usando la f parcial, compare con el inciso a.

Modelo completo: $y = X\beta + \epsilon$

Modelo reducido: $y = X_1\mu + \epsilon$

$H_0 = \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = 0$.

```

> SCX_cX1 = t(y)%*(Xc%*Ginv(t(Xc)%*Xc)%*t(Xc)-X1%*Ginv(t(X1)%*X1)%*t(X1))%*y
> glX_cX1 = qr(Xc)$rank-qr(X1)$rank
> #modelo completo
> SCE = t(y)%*(diag(nrow(Xc)) - Xc%*Ginv(t(Xc)%*Xc)%*t(Xc))%*y
> glE = nrow(Xc)-qr(Xc)$rank
> # Cuadrados Medios:
> CMX_cX1 = SCX_cX1/glX_cX1
> CME = SCE/glE
> # F calculada
> FC=CMX_cX1 / CME
> FC
      [,1]
[1,] 2.147736
> # F de tablas
> alpha = 0.05
> qf(1-alpha, glX_cX1, glE)
[1] 3.862548
> # Pvalue
> pf(FC, df1=glX_cX1, df2=glE, lower.tail = F)
      [,1]
[1,] 0.164224

```

Dado que el valor del p-value es mayor a $\alpha = 0.05$, no hay evidencia suficiente para rechazar H_0 .

Comparando con el resultado en a), se concluye que el factor A es significativo sólo si el factor B está presente.

f. Obtenga la sumas de cuadrados tipo II y Tipo III para los factores A y B, e interprete las pruebas de F.

Tipo II: prueba cada efecto principal después del otro efecto principal.

Tipo III: prueba la presencia de un efecto principal después del otro efecto principal e interacción.

```
> GLM(Respuesta~ A+ B, datos3)$'Type II'
  Df Sum Sq Mean Sq F value    Pr(>F)
A   3 183.75   61.250   6.0803 0.02315 *
B   2 145.65   72.826   7.2294 0.01983 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> GLM(Respuesta~ A+ B, datos3)$'Type III'
  Df Sum Sq Mean Sq F value    Pr(>F)
A   3 183.75   61.250   6.0803 0.02315 *
B   2 145.65   72.826   7.2294 0.01983 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Los resultados para las suma de cuadrados tipo II y tipo III tienen los mismos resultados.

Como conclusión las pruebas F indican que el efecto del factor A después del efecto del factor B es significativo y pasa lo mismo de manera inversa.

Problema 4 Mosteller and Tukey (1977) reported data on verbal test scores for sixth graders. They used a sample of 20 Mid Atlantic and New England schools taken from The Coleman Report.

- The dependent variable y was the mean verbal test score for each school.
- The predictor variables were:

x_1 = staff salaries per pupil.

x_2 = percent of sixth grader's fathers employed in white collar jobs.

x_3 = a composite score measuring socioeconomic status,

x_4 = the mean score on a verbal test administered to teachers, and

x_5 = one-half of the sixth grader's mothers' mean number of years of schooling

Suponga que deseamos ajustar el modelo:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \beta_5 x_{i5} + \epsilon_i$$

x1	x2	x3	x4	x5	y
3.83	28.87	7.2	26.6	6.19	37.01
2.89	20.1	-11.71	24.4	5.17	26.51
2.86	69.05	12.32	25.7	7.04	36.51
2.92	65.4	14.28	25.7	7.1	40.7
3.06	29.59	6.31	25.4	6.15	37.1
2.07	44.82	6.16	21.6	6.41	33.9
2.52	77.37	12.7	24.9	6.86	41.8
2.45	24.67	-0.17	25.01	5.78	33.4
3.13	65.01	9.85	26.6	6.51	41.01
2.44	9.99	-0.05	28.01	5.57	37.2
2.09	12.2	-12.86	23.51	5.62	23.3
2.52	22.55	0.92	23.6	5.34	35.2
2.22	14.3	4.77	24.51	5.8	34.9
2.67	31.79	-0.96	25.8	6.19	33.1
2.71	11.6	-16.04	25.2	5.62	22.7
3.14	68.47	10.62	25.01	6.94	39.7
3.54	42.64	2.66	25.01	6.33	31.8
2.52	16.7	-10.99	24.8	6.01	31.7
2.68	86.27	15.03	25.51	7.51	43.1
2.37	76.73	12.77	24.51	6.96	41.01

a. Considere el modelo $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \beta_5 x_{i5} + \epsilon_i$. Ajuste el modelo de regresión y pruebe $H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = 0$ usando la prueba de F, usando $\alpha = 0.05$.

Prueba de estimabilidad.

$H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = 0$, o bien que : $\beta_1 - \beta_2 = 0$

$\beta_1 - \beta_3 = 0$

$\beta_1 - \beta_4 = 0$

$\beta_1 - \beta_5 = 0$

$$H_0 : C\beta = \begin{bmatrix} 0 & 1 & -1 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 \\ 0 & 1 & 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} \mu \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \\ \beta_5 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

$E(y_{11} - y_{21}) = (\mu + \beta_1) - (\mu + \beta_2) = \beta_1 - \beta_2 \therefore$ es una función estimable.

$E(y_{11} - y_{31}) = (\mu + \beta_1) - (\mu + \beta_3) = \beta_1 - \beta_3 \therefore$ es una función estimable.

$E(y_{11} - y_{41}) = (\mu + \beta_1) - (\mu + \beta_4) = \beta_1 - \beta_4 \therefore$ es una función estimable.

$E(y_{11} - y_{51}) = (\mu + \beta_1) - (\mu + \beta_5) = \beta_1 - \beta_5 \therefore$ es una función estimable.

Prueba de rango para saber si es estimable mediante R.

$$r(X) = r \begin{bmatrix} X \\ C \end{bmatrix}$$

```
> model4=ModelMatrix(y~x1+x2+x3+x4+x5,datos)
```



```

> X=as.matrix(model4$X)
> dim(X)
[1] 20 6
> R(X)
[1] 6
> C1<-c(0,1,-1,0,0,0)
> C2<-c(0,1,0,-1,0,0)
> C3<-c(0,1,0,0,-1,0)
> C4<-c(0,1,0,0,0,-1)
> C<-rbind(C1,C2,C3,C4)
> X_n=rbind(X,C)
> R(X)
[1] 6
> R(X_n)
[1] 6
>#Es estimable

```

Ajuste del modelo:

```

> model4_c=lm(y~x1+x2+x3+x4+x5,data =datos)
> summary(model4_c)

```

Call:

```
lm(formula = y ~ x1 + x2 + x3 + x4 + x5, data = datos)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-3.9497	-0.6174	0.0623	0.7343	5.0018

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	19.94857	13.62755	1.464	0.1653
x1	-1.79333	1.23340	-1.454	0.1680
x2	0.04360	0.05326	0.819	0.4267
x3	0.55576	0.09296	5.979	3.38e-05 ***
x4	1.11017	0.43377	2.559	0.0227 *
x5	-1.81092	2.02739	-0.893	0.3868

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.074 on 14 degrees of freedom

Multiple R-squared: 0.9063, Adjusted R-squared: 0.8728

F-statistic: 27.08 on 5 and 14 DF, p-value: 9.927e-07

$$F = 27.08 \quad p - \text{valor} = 9.927e - 07$$

Dado que el valor del p-value es menor a $\alpha = 0.05$, hay evidencia suficiente para rechazar H_0 .
Lo que implica que existe una $\beta \neq 0$

b. Realice una prueba de F parcial para probar $H_0 : \beta_1 = 0, \beta_2 = 0 \mid x_3, x_4, x_5$. Indique cuál es su modelo completo y modelo reducido. Construya la F parcial y concluya usando $\alpha = 0.05$.

Se tiene que el modelo completo y el modelo parcial se encuentra definido por:

Modelo completo: $y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \beta_5 x_{i5} + \epsilon_i$

Modelo parcial: $y_i = \beta_3 x_{i3} + \beta_4 x_{i4} + \beta_5 x_{i5} + \epsilon_i$

```
model4_c=lm(y~x1+x2+x3+x4+x5,data =datos)
summary(model4_c)
anova(model4_c)
#Modelo reducido
model4_red=lm(y~x3+x4+x5,data =datos)
summary(model4_red)
anova(model4_red)
anova(model4_c,model4_red)
> anova(model4_c,model4_red)
Analysis of Variance Table
```

```
Model 1: y ~ x1 + x2 + x3 + x4 + x5
Model 2: y ~ x3 + x4 + x5
      Res.Df    RSS Df Sum of Sq      F Pr(>F)
1         14 60.238
2         16 71.483 -2   -11.245  1.3067 0.3018
```

Dado que el p values es mayor a $\alpha = 0.05$, no hay evidencia suficiente para rechazar H_0 , por lo tanto las variables X_1, X_2 no contribuye significativamente a la explicación de y .

c. Realice una prueba de razón de verosimilitudes para probar $H_0 : \beta_1 = 0, \beta_2 = 0 \mid x_3, x_4, x_5$. Indique cuál es su modelo completo y modelo reducido. Obtenga el estadístico de prueba y concluya usando $\alpha = 0.05$.

Se desea probar $H_0 : C\beta = m$, el estadístico de prueba de razón de verosimilitud, λ , para probar está dado por:

$$\lambda = \frac{\max_{H_0} L(\beta, \sigma^2, y)}{\max_{\beta, \sigma^2} L(\beta, \sigma^2, y)}$$

Regla de desición: se rechaza H_0 , si $T(X) = -2\log(\lambda) > X_{(m-r), \alpha}^2$.

```
logm1=logLik(model4_c)
> logm1
'log Lik.' -39.40446 (df=7)
> logm2=logLik(model4_red)
> logm2
'log Lik.' -41.11601 (df=5)
> glh=7-5
> logLik(model4_c)-logLik(model4_red)
'log Lik.' 1.711554 (df=7)
```

```

> Tc=2*(logLik(model4_c)-logLik(model4_red))
> Tc
'log Lik.' 3.423108 (df=7)
> pvalor=pchisq(T,df=glh,lower.tail = F)
> pvalor
[1] 0.6065307

```

Dado que el valor del p-value es menor, hay evidencia suficiente para rechazar H_0 . Donde H_0 , representa el modelo más simple (modelo reducido), este modelo indica que es suficiente para explicar los datos observados. Sin embargo, según el resultado anterior, se puede interpretar que el resultado de la prueba F parcial presenta un mejor desempeño en modelos no lineales.

Problema 5 (Pruebas de razón de verosimilitudes y Lagrange).

Production Data for Primary Metals, 27 Statewide Observations Source: Greene, W. (2012) Econometric Analysis. 7th Edition, Prentice Hall, Upper Saddle River. Data are per establishment, labor is a measure of labor input, and capital is the gross value of plant and equipment. A scale factor used to normalize the capital figure in the original study has been omitted.

- Obs = Observation number
- Valueadd = Value added,
- Labor = Labor input,
- Capital = Capital stock.

OBS	VALUEADD	LABOR	CAPITAL
1	657.29	162.31	279.99
2	935.93	214.43	542.5
3	1110.65	186.44	721.51
4	1200.89	245.83	1167.68
5	1052.68	211.4	811.77
6	3406.02	690.61	4558.02
7	2427.89	452.79	3069.91
8	4257.46	714.2	5585.01
9	1625.19	320.54	1618.75
10	1272.05	253.17	1562.08
11	1004.45	236.44	662.04
12	598.87	140.73	875.37
13	853.1	145.04	1696.98
14	1165.63	240.27	1078.79
15	1917.55	536.73	2109.34
16	9849.17	1564.83	13989.55
17	1088.27	214.62	884.24
18	8095.63	1083.1	9119.7
19	3175.39	521.74	5686.99
20	1653.38	304.85	1701.06
21	5159.31	835.69	5206.36
22	3378.4	284	3288.72
23	592.85	150.77	357.32
24	1601.98	259.91	2031.93
25	2065.85	497.6	2492.98
26	2293.87	275.2	1711.74
27	745.67	137	768.59

Considerare el **modelo 1**:

$$\log(valueadd) = \beta_1 + \beta_2 \log(labor) + \beta_3 \log(capital) + \beta_4 \frac{1}{2} \log^2(labor) + \beta_5 \frac{1}{2} \log^2(capital) + \beta_6 (\log(labor) \times \log(capital)) + \epsilon$$

Considerare el **modelo 2**:

$$\log(valueadd) = \theta_1 + \theta_2 \log(labor) + \theta_3 \log(capital) + \epsilon$$

resolver

- a) Probar $H_0 : \beta_4 = \beta_5 = \beta_6 = 0$ usando una prueba de razón de verosimilitudes (LRT) con $\alpha = 0.05$.

Se desea probar

$$H_0 : C\beta = m,$$

$$C = \begin{bmatrix} 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \\ \beta_5 \\ \beta_6 \end{bmatrix}, \quad m = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

El estadístico de prueba de razón de verosimilitud $Y = X\beta + \epsilon$

$$\lambda = \left(\frac{(y - X\hat{\beta})^t(y - X\hat{\beta})}{(y - X\hat{\beta})^t(y - X\hat{\beta}) + (C\hat{\beta} - m)^t(C(X^tX)^{-1}C^t - C)^{-1}(C\hat{\beta} - m)} \right)^{n/2} = \left(\frac{SCE}{SCE + SCH} \right)^{n/2}$$

Regla de decisión: Se rechaza $H_0 : C\beta = m$, si $T_c = -2\log(\lambda)$ es mayor que un valor de tablas $\chi^2_{r(C),\alpha}$

```
y <- log(datos5$VALUEADD)
> x1 <- rep(1, 27)
> x2 <- log(datos5$LABOR)
> x3 <- log(datos5$CAPITAL)
> x4 <- (1/2)*x2^2
> x5 <- (1/2)*x3^2
> x6 <- x2*x3
> X_1 <- cbind(x1,x2,x3,x4,x5,x6) # Matriz diseño m1
> X_2 <- cbind(x1,x2,x3)         # Matriz diseño m2
> y <- as.matrix(y)
```

La matriz y se construye el estadístico de prueba:

```
> C <- matrix( c(0, 0, 0, 1, 0, 0,
+               0, 0, 0, 0, 1, 0,
+               0, 0, 0, 0, 0, 1), nrow=3, byrow=TRUE)
> beta1 <- Ginv(t(X_1)%*%X_1)%*%t(X_1)%*%y
> SCH <- t(C)%*%beta1)%*%solve(C)%*%Ginv(t(X_1)%*%X_1)%*%t(C))%*%(C)%*%beta1)
> glh <- R(C)%*%Ginv(t(X_1)%*%X_1)%*%t(C))
> SCE <- t(y - X_1)%*%beta1)%*%(y - X_1)%*%beta1)
> n <- nrow(X_1)
> lambda1 <- (SCE/(SCE+SCH))^(n/2)
> Tc <- -2*log(lambda1); Tc
      [,1]
[1,] 6.07935
> alfa=0.05
>## valor de tablas F
> qchisq((1-alfa), df=(glh))
[1] 7.814728
> pchisq(Tc, df=(glh), lower.tail = F) ## Pvalue
      [,1]
[1,] 0.1078129
```

Regla de decisión: Se rechaza $H_0 : C\beta = m$, si $T_c = -2\log(\lambda)$ es mayor que un valor de tablas $\chi^2_{r(C),\alpha}$

Dado que el valor del T calculado es menor al de tablas, no hay evidencia suficiente para rechazar H_0 .

- b) Probar simultáneamente $H_0 : \beta_2 + \beta_3 = 1$ y $\beta_4 + \beta_5 + 2\beta_6 = 0$ usando la prueba del multiplicador de Lagrange con $\alpha = 0.05$.

$$H_0 : C\beta = m$$

$$C = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 & 2 \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \\ \beta_5 \\ \beta_6 \end{bmatrix}, \quad m = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

El estadístico de prueba del multiplicador de Lagrange:

$$LM = (C\hat{\beta} - m)^t [\hat{\sigma}_r^2 C(X^t X)^{-1} C^t]^{-1} (C\hat{\beta} - m),$$

donde

$$\hat{\sigma}_r^2 = \frac{(y - X\hat{\beta}_r)^t (y - X\hat{\beta}_r)}{n}$$

y

$$\hat{\beta}_r = \hat{\beta} - (X^t X)^{-1} C^t [C(X^t X)^{-1} C^t]^{-1} (C\hat{\beta} - m)$$

```
> C_L <- matrix( c(0, 1, 1, 0, 0, 0,
+                 0, 0, 0, 1, 1, 2), nrow=2, byrow=TRUE)
>
> m2 <- as.matrix(c(1,0))
>
> beta1=Ginv(t(X_1)%*%X_1)%*%t(X_1)%*%y
> beta_L=beta1-Ginv(t(X_1)%*%X_1)%*%t(C_L)%*%solve(C_L)%*%Ginv(t(X_1)%*%X_1)%*%t(C_L)
> n=nrow(X_1)
> sigma2_r=t(y-X_1)%*%beta_L)%*%(y-X_1)%*%beta_L)/n
> LM=(t(C_L)%*%beta1 - m2)%*%solve(C_L)%*%Ginv(t(X_1)%*%X_1)%*%t(C_L))%*%(C_L)%*%beta1
> gl=R(C_L)%*%Ginv(t(X_1)%*%X_1)%*%t(C_L))
> gl
[1] 2
> LM
      [,1]
[1,] 4.136164
> alfa=0.05
> #valor de tablas F
> qchisq((1-alfa), df=gl)
[1] 5.991465
> ## Pvalue
> pchisq(LM, df=gl, lower.tail = F)
      [,1]
[1,] 0.126428
```

$$LM = 4.136164 \text{ y } \chi_{r(C), \alpha}^2 = 5.991465$$

$$LM \not\geq \chi_{r(C), \alpha}^2$$

Dado que el valor de LM es menor a $\alpha = 0.05$, no hay evidencia suficiente para rechazar H_0 .

- c) Probar del modelo 2 $H_0 : \theta_2 + \theta_3 = 1$ usando la prueba del multiplicador de Lagrange con $\alpha = 0.05$.

$$H_0 : C\beta = m,$$

con

$$C = \begin{bmatrix} 0 & 1 & 1 \end{bmatrix}, \quad \beta = \begin{bmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \end{bmatrix}, \quad m = 1$$

Se construye el estadístico de prueba.

```
> X_2 <- cbind(x1,x2,x3)
> C3 <- matrix( c(0, 1, 1), nrow=1, byrow=TRUE)
>
> m3 <- 1
>
> beta2=Ginv(t(X_2)%*%X_2)%*%t(X_2)%*%y
> beta_L2=beta2-Ginv(t(X_2)%*%X_2)%*%t(C3)%*%solve(C3)%*%Ginv(t(X_2)%*%X_2)
%*%t(C3)) %*%(C3)%*%beta2 - m3)
> n=nrow(X_2)
> sigma2_r2=t(y-X_2)%*%beta_L2)%*%(y-X_2)%*%beta_L2)/n
> LM2=(t(C3)%*%beta2 - m3)%*%solve(C3)%*%Ginv(t(X_2)%*%X_2)%*%t(C3))
%*%(C3)%*%beta2 - m3))/sigma2_r2
> gl2=R(C3)%*%Ginv(t(X_2)%*%X_2)%*%t(C3))
> gl2
[1] 1
> LM2
      [,1]
[1,] 0.1295886
> alfa_2=0.05;
> # valor de tablas F
> qchisq((1-alfa_2), df=gl2)
[1] 3.841459
```

$LM = 0.1295886$ y $\chi^2_{r(C),\alpha} = 3.841459$, es decir,

$$LM \not\geq \chi^2_{r(C),\alpha}$$

Dado que el valor de LM es menor a $\alpha = 0.05$, no hay evidencia suficiente para rechazar H_0 .

Problema 6 (Hipotesis no lineales Wald y Simulacion).

Macroeconomics Data Set, Quarterly, 1950I to 2000IV, 204 Quarterly Observations, Source: Department of Commerce, BEA website and www.economagic.com

- Year = Date
- Qtr = Quarter

- Realgdp = Real GDP (*bil*)
- Realcons = Real consumption expenditures
- Realinvs = Real investment by private sector
- Realgovt = Real government expenditures
- Realdpi = Real disposable personal income
- CPI_U = Consumer price index
- M1 = Nominal money stock
- Tbilrate = Quarterly average of month end 90 day t bill rate
- Unemp = Unemployment rate
- Pop = Population, mil. interpolate of year end figures using constant growth rate per quarter
- Infl = Rate of inflation (first observation is missing)
- Realint = Ex post real interest rate = Tbilrate - Infl. (First observation missing)

Descarga de:

<http://www.stern.nyu.edu/~wgreene/Text/Edition7/TableF5-2.txt>

Considere el modelo;

$$\log(\text{realconst}) = \beta_1 + \beta_2 \log(\text{realdpit}) + \beta_3 \log(\text{realcons}_{t-1}) + \epsilon_t$$

con $\epsilon_t \sim n(0, \sigma^2)$ son iid.

1. (a) Se desea probar $H_0 : \beta_2/(1 - \beta_3) = 1$ utilizando la prueba de Wald con $\alpha = 0.05$.

Se desea probar $H_0 : g(\theta) = h$ vs $H_a : g(\theta) \neq h$

El estadístico de Wald está dado por: $W = (g(\hat{\theta}) - h)'[G(\hat{\theta})I(\hat{\theta})^{-1}G(\hat{\theta})']^{-1}(g(\hat{\theta}) - h)$

En este caso:

donde: $H_0 : \beta_2/(1 - \beta_3) = 1$ vs $H_a : \beta_2/(1 - \beta_3) \neq 1$

$$g(\hat{\beta}) = \beta_2/(1 - \beta_3) = 1 \text{ y } \left[\frac{\partial g(\hat{\beta})}{\partial \beta_1}, \frac{\partial g(\hat{\beta})}{\partial \beta_1} \right] = \left[\frac{1}{(1 - \beta_3)}, \frac{\beta_2}{(1 - \beta_3)^2} \right]$$

```
> #regresion con glm
> #columna realcons t-1
> realconst_1 = c(NA, datos$realcons[-nrow(datos)])
> #modelo
> model1<-glm(log(realcons)~log(realdpi)+log(realconst_1), data = datos)
```



```

> #guardamos los betas
> beta_hat <- matrix(coef(model1), ncol=1,
+                     dimnames=list(names(coef(model1)), NULL))
> beta_hat
              [,1]
(Intercept) 0.003141571
log(realdpi) 0.074957871
log(realconst_1) 0.924624597
> #G(theta) matriz de derivadas
> G_derv<-t(matrix(c(1/(1-beta_hat[3]),beta_hat[2]/((1-beta_hat[3])^2))))
> G_derv
              [,1]      [,2]
[1,] 13.26693 13.19344
> #I_theta estimado
> Vest<-vcov(model1)[2:3,2:3]
> Vest
              log(realdpi) log(realconst_1)
log(realdpi) 0.0008252215 -0.0008206806
log(realconst_1) -0.0008206806 0.0008176008
> #Matriz Vestimado de beta de G I t(G)
> V_est_g_beta<-G_derv%*%Vest%*%t(G_derv)
> V_est_g_beta
              [,1]
[1,] 0.0002675836
#h_0: g(\beta)
> h0<-beta_hat[2]/(1-beta_hat[3])
> #Estadistico W
> Wn<-t(h0-1)%*%solve(V_est_g_beta)%*%(h0-1)
> alfa=0.05
> chi_tab<-qchisq((1-alfa), df=1) ## valor de tablas
> p_value<-pchisq(Wn, df=1, lower.tail = F) ## Pvalue
> data.frame(Wn,chi_tab,p_value)
              Wn  chi_tab  p_value
1 0.1146728 3.841459 0.7348857

```

Dado que el valor del p-value es mayor a $\alpha = 0.05$, no hay evidencia suficiente para rechazar H_0 . Por lo que se concluye que $H_0 : \beta_2/(1 - \beta_3) = 1$

- (b) Usando el Método Delta y estimadores de Máxima Verosimilitud obtenga la distribución asintótica de $\hat{\beta}_2/(1 - \hat{\beta}_3)$

Proposición:

Ahora, tenemos un vector, X_n , que se puede aproximar asintóticamente a una normal multivariada: $X_n \rightarrow N(\theta, \Sigma)$, Para una función g dada y un valor específico de θ , suponga que $g'(\theta)$ existe y no es 0.

$$g(X_n) \rightarrow N(g(\theta), [g'(\theta)]^t \Sigma [g'(\theta)])$$

```
> #-----b-----
> #modelo
> model1<-glm(log(realcons)~log(realdpi)+log(realconst_1), data = datos)
> #guardamos los betas
> beta_hat <- matrix(coef(model1), ncol=1,
+                    dimnames=list(names(coef(model1)), NULL))
> beta_hat
               [,1]
(Intercept)  0.003141571
log(realdpi)  0.074957871
log(realconst_1) 0.924624597
> #G(theta) matriz de derivadas
> G_derv<-t(matrix(c(1/(1-beta_hat[3]),beta_hat[2]/((1-beta_hat[3])^2))),
> G_derv
               [,1]      [,2]
[1,] 13.26693 13.19344
> #I_theta estimado (Varianzas y covarianzas)
> Vest<-vcov(model1)[2:3,2:3]
> Vest
               log(realdpi) log(realconst_1)
log(realdpi)    0.0008252215   -0.0008206806
log(realconst_1) -0.0008206806    0.0008176008
> #Matriz Vestimado (Varianza)
> Varianza<-G_derv%*%Vest%*%t(G_derv)
> #h_0: g(\beta)=mu
> mu<-beta_hat[2]/(1-beta_hat[3])
> data.frame(mu,Varianza)
               mu      Varianza
1 0.9944606 0.0002675836
```

La distribución asintótica es:

$$\frac{\beta_2}{(1 - \beta_3)} \sim N(0.9944606, 0.0002675836)$$

- (c) Use Simulación MonteCarlo y Bootstrap para obtener un intervalo de Confianza del 95% para $\beta_2/(1 - \beta_3)$ interprete y compare con a).

```
# Simulación Bootstrap:
beta1<-c()
beta2<-c()
beta3<-c()
```

```

nr=nrow(datos)
NBOOT <- 1000 ; ind <- NULL ; set.seed(1234)
for (i in 1:NBOOT){
  datam<-datos[sample(nrow(datos),size=nr,replace=TRUE),]
  datos_new = data.frame(
    realconst = datam$realcons,
    realdpi = datam$realdpi,
    realconst_1 = c(NA, datam$realcons[-nrow(datam)])
  )
  regre<-lm(log(realconst) ~ log(realdpi) + log(realconst_1), data=datos_new)
  beta1<-append(beta1,regre$coefficients[1])
  beta2<-append(beta2,regre$coefficients[2])
  beta3<-append(beta3,regre$coefficients[3])
}
# índice a estudiar:
ind= beta2/(1- beta3)
# Intervalos:
li=sort(ind)[25]
ls=sort(ind)[975]
data.frame(li,ls)

          li          ls
log(realdpi) 0.9934588 1.011578

```

```

## Simulación MonteCarlo:
logrealconst = log(datos_new$realconst)
logrealdpi = log(datos_new$realdpi)
logrealconst_1 = log(datos_new$realconst_1)

# Modelo:
modelo = lm(log(realconst) ~ log(realdpi) + log(realconst_1), datos_new)
# Coeficientes:
b1 = modelo$coefficients[1]
b2 = modelo$coefficients[2]
b3 = modelo$coefficients[3]
raiz_cme = summary(modelo)$sigma
# Simulaciones
pred <- data.frame(cbind(log(datos_new$realdpi), log(datos_new$realconst_1)))
nr = nrow(pred)
nr = nrow(datos_new)
beta1 <- c()
beta2 <- c()
beta3 <- c()
NREP <- 10000 ; ind <- NULL ; set.seed(9999)
for (i in 1:NREP){
  y = b1 + b2*logrealdpi + b3*logrealconst_1 + rnorm(nr, 0, raiz_cme)
  regre <- lm(y ~ logrealdpi + logrealconst_1)
  beta1 <- append(beta1, regre$coefficients[1])
  beta2 <- append(beta2, regre$coefficients[2])
}

```

```

    beta3 <- append(beta3, regre$coefficients[3])
  }
# Indice a estudiar:
ind=beta2/(1-beta3)
# Intervalos:
l ii=sort(ind)[25]
l ss=sort(ind)[975]
data.frame(l ii,l ss)
logrealdpi 0.9782328 1.03473

```

Bootstrap y MonteCarlo.

Para el caso de Bootstrap y MonteCarlo, dado que el intervalo contiene al 1, no hay evidencia suficiente para rechazar H_0 . Por lo que se concluye que $H_0 : \beta_2/(1 - \beta_3) = 1$, esto coincide con la conclusión del inciso a.

Problema 7 (Para datos y modelo del problema 6).

- a) Obtenga los estimadores de Bayes para los coeficiente de regresión y σ e intervalos de credibilidad.

```

#Con Stan
bayes = stan_glm(log(realconst)~log(realdpi) + log(realconst_1),
                  data=datos_new)
> print(bayes, digits= 4)
stan_glm
family:      gaussian [identity]
formula:     log(realconst) ~ log(realdpi) + log(realconst_1)
observations: 203
predictors:  3
-----
              Median MAD_SD
(Intercept)   0.0033 0.0105
log(realdpi)   0.0728 0.0298
log(realconst_1) 0.9269 0.0299


Auxiliary parameter(s):
              Median MAD_SD
sigma 0.0088 0.0004
-----
* For help interpreting the printed output see ?print.stanreg
* For info on the priors used see ?prior_summary.stanreg
> # Intervalos de credibilidad
> posterior_interval(bayes)
              5%          95%
(Intercept) -0.01412853 0.020353679
log(realdpi)  0.02531731 0.120694472

```

```
log(realconst_1) 0.87891205 0.973704427
sigma            0.00810180 0.009573501
```


b) Obtenga las distribuciones posteriores

```
# distribución posterior
describe_posterior(bayes, centrality = "mean")
library(bayesplot)
mcmc_dens(bayes)
```



c) Obtenga la distribución posterior de $\beta_2/(1 - \beta_3)$ y un intervalo de credibilidad del 95%.

```
summary(hipotesis, c(0.025, 0.975))
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-5.8327  0.9823  0.9946  0.9912  1.0058  3.6823
```



Dado que el intervalo contiene al 1, no hay evidencia suficiente para rechazar H_0 . Por lo

que se concluye que $H_0 : \beta_2/(1 - \beta_3) = 1$, esto coincide con la conclusión del ejercicio 6.

Problema 8 (Regresion Bayesiana).

Del artículo:

Ellison, A. M. (2004). Bayesian inference in ecology. Ecology letters, 7(6), 509-520.

<https://onlinelibrary.wiley.com/doi/pdf/10.1111/j.1461-0248.2004.00603.x>

1. (a) Realice el analisis de regresión clasico para datos de hormigas.

El modelo que se propone en el artículo es:

$$\log(\hat{S}_i) = \hat{\beta}_0 + \hat{\beta}_1 * latitude_i + \hat{\beta}_2 * elevation_i + \hat{\beta}_3 habitat_i$$

```
> #Modelo de regresión simple
> model_reg= lm(log(Species.richness) ~ Latitude + Elevation
+ habitat,data=datos8)
> summary(model_reg)

Call:
lm(formula = log(Species.richness) ~ Latitude + Elevation + habitat,
    data = datos8)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1.10279	-0.23082	0.01417	0.25020	0.92499

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	10.3180285	2.6101963	3.953	0.000306 ***
Latitude	-0.2007838	0.0609920	-3.292	0.002085 **
Elevation	-0.0010856	0.0004049	-2.681	0.010610 *
habitatForest	0.6898845	0.1269432	5.435	2.94e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.421 on 40 degrees of freedom

Multiple R-squared: 0.5625, Adjusted R-squared: 0.5297

F-statistic: 17.14 on 3 and 40 DF, p-value: 2.595e-07

- (b) Realice el análisis bayesiano propuesto en el paper para datos de hormigas. Use el software que considere conveniente no solo Bugs.

```
#Modelo Bayesiano con brm
model_bayes <- brm(log(Species.richness) ~ Latitude + Elevation
+ habitat, data = datos8)
> print(model_bayes, digits = 6)
Family: gaussian
Links: mu = identity; sigma = identity
```

Formula: $\log(\text{Species.richness}) \sim \text{Latitude} + \text{Elevation} + \text{habitat}$
 Data: datos8 (Number of observations: 44)
 Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
 total post-warmup draws = 4000

Regression Coefficients:

	Estimate	Est.Error	l-95% CI	u-95% CI	Rhat
Intercept	10.333886	2.744553	4.851067	15.606958	1.002378
Latitude	-0.201223	0.064082	-0.325076	-0.073709	1.001961
Elevation	-0.001073	0.000421	-0.001913	-0.000243	1.000672
habitatForest	0.690287	0.129543	0.428947	0.942747	1.002618

	Bulk_ESS	Tail_ESS
Intercept	3288	2407
Latitude	3316	2504
Elevation	4050	2824
habitatForest	3139	1939

Further Distributional Parameters:

	Estimate	Est.Error	l-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
sigma	0.434155	0.049426	0.349372	0.544991	0.999932	2749	2145

Draws were sampled using sampling(NUTS). For each parameter, Bulk_ESS and Tail_ESS are effective sample size measures, and Rhat is the potential scale reduction factor on split chains (at convergence, Rhat = 1).

#con INLA

```
inlamod <- inla(log(Species.richness) ~ Latitude + Elevation
               + habitat, data = datos8, family="gaussian")
> inlamod$summary.fixed[,1:2]
```

	mean	sd
(Intercept)	10.318001469	2.6118938902
Latitude	-0.200783076	0.0610316371
Elevation	-0.001085631	0.0004051898
habitatForest	0.689873401	0.1270249233

#Con Stan

```
model_bayes<- stan_glm(log(Species.richness) ~ Latitude + Elevation
                       + habitat, data = datos8, seed=111)
> print(model_bayes, digits = 3)
```

Family: gaussian

Links: mu = identity; sigma = identity

Formula: $\log(\text{Species.richness}) \sim \text{Latitude} + \text{Elevation} + \text{habitat}$

Data: datos8 (Number of observations: 44)

Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
 total post-warmup draws = 4000

Regression Coefficients:

	Estimate	Est.Error	l-95% CI	u-95% CI	Rhat	Bulk_ESS
Intercept	10.334	2.745	4.851	15.607	1.002	3288
Latitude	-0.201	0.064	-0.325	-0.074	1.002	3316

Elevation	-0.001	0.000	-0.002	-0.000	1.001	4050
habitatForest	0.690	0.130	0.429	0.943	1.003	3139
Tail_ESS						
Intercept	2407					
Latitude	2504					
Elevation	2824					
habitatForest	1939					

Further Distributional Parameters:

	Estimate	Est.Error	l-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
sigma	0.434	0.049	0.349	0.545	1.000	2749	2145

Draws were sampled using `sampling(NUTS)`. For each parameter, `Bulk_ESS` and `Tail_ESS` are effective sample size measures, and `Rhat` is the potential scale reduction factor on split chains (at convergence, `Rhat` = 1).

En ambos modelos, tanto de regresión simple como de regresión bayesiana se obtienen valores de los estimadores muy similares.